

Estadística para gerentes

ESTADÍSTICA PARA GERENTES

Francisco Javier Jaramillo Álvarez

Docente Institución Universitaria CEIPA

Especialista en Estadística de la Universidad Nacional

Magíster en Educación y nuevas tecnologías de la Universidad a distancia de Madrid

Ingeniero de alimentos de la Corporación Universitaria Lasallista

Año: 2017

TABLA DE CONTENIDO

1. Técnicas descriptivas

Estadística

Población

Muestra

Variable

1.1 Variables cualitativas

1.1.1 Tablas de frecuencia

1.1.2 Gráficos

1.1.3 Análisis numérico

1.2. Variables cuantitativas

1.2.1 Tablas de frecuencia

1.2.2 Gráficos

1.2.3 Análisis numérico

1.2.3.1 Medidas de localización

1.2.3.1.1 Medidas de tendencia central

1.2.3.1.2. Medidas de posición

1.2.3.2 Medidas de variabilidad o dispersión

1.3 Diagrama de caja y bigotes

1.4 Otros gráficos:

1.5 Minería de datos y big data

[Ejercicios resueltos](#)

[Ejercicios propuestos](#)

[Notas complementarias: Sesgo](#)

2. Probabilidades

[2.1. Conceptos básicos](#)

[2.1.1 ¿Qué es?](#)

[2.1.2 Experimento](#)

[2.1.3 Espacio muestral \(s\)](#)

[2.1.4 Punto muestral](#)

[2.1.5 Evento o suceso \(e\)](#)

[2.1.6 Evento aleatorio](#)

[2.2 Maneras de describir un espacio muestral](#)

[2.2.1 Tabla de contingencia](#)

[2.2.2 Diagrama de árbol](#)

[2.2.3 Combinaciones y permutaciones](#)

[2.3 Probabilidad marginal, condicional y conjunta](#)

[2.4 Distribuciones de probabilidad](#)

[2.4.1 Distribución binomial](#)

[2.4.2 Distribución hipergeométrica](#)

[2.4.3 Distribución de Poisson](#)

[2.4.4 Distribución normal](#)

[2.4.5 Distribución exponencial](#)

[Ejercicios resueltos](#)

[Ejercicios propuestos](#)

[3. Estadística inferencial](#)

[3.1 Estimación](#)

[3.1.1 Estimación de la media de una población](#)

[3.1.2 Estimación de la proporción poblacional](#)

[3.2 Pruebas de hipótesis con una población](#)

[3.3 Pruebas de hipótesis con dos poblaciones](#)

[3.3.1 Pruebas de hipótesis de la diferencia de proporciones](#)

[3.3.2 Pruebas de hipótesis de la diferencia de medias](#)

[3.3.2.1 Diseño de muestras pareadas](#)

[3.3.2.2 Diseño de muestras independientes](#)

[Ejercicios resueltos](#)

[Ejercicios propuestos](#)

[4. Regresión y correlación](#)

[4.1 Regresión lineal simple](#)

[4.2 Otros modelos](#)

[4.3 Regresión lineal múltiple](#)

[4.4 Series cronológicas](#)

[4.4.1 Importancia de las series cronológicas](#)

[4.4.2 Componentes de una serie de tiempo](#)

[4.4.3 Empleo del análisis de regresión en pronósticos](#)

[4.4.4 Otras herramientas para hacer pronósticos](#)

[4.4.4.1 Variación porcentual](#)

[4.4.4.2 Media móvil](#)

[4.4.4.3 Métodos cualitativos](#)

[Ejercicios resueltos](#)

[Ejercicios propuestos](#)

[Notas complementarias: Números índice](#)

[Respuestas a ejercicios propuestos](#)

[Referencias bibliográficas](#)

INTRODUCCIÓN

“Un administrador debe contar con un ‘pensamiento estadístico’ como herramienta de gestión de procesos para ser competitivos” (Barbieri)

Este libro presenta los fundamentos generales de la estadística, de forma tal que puedan ser de utilidad para cualquier estudiante del área gerencial, independientemente de su campo de especialización.

Se pretende que el lector obtenga una apreciación sobre la utilidad del método estadístico en su campo profesional, que adquiera una buena comprensión de los parámetros o estadísticos básicos y la lógica que refuerza la aplicación de las herramientas estadísticas, que sea capaz de seleccionar la técnica estadística apropiada y de realizar los cálculos necesarios, así como interpretar y comprender los resultados de su estudio. Por eso, en aras de la claridad y la practicidad, en este libro se sacrifica el rigor matemático.

La mayoría de textos de estadística incluyen ejemplos que son descontextualizados y desactualizados; por eso uno de los objetivos de este texto es adaptar las herramientas estadísticas a casos empresariales o económicos actuales.

El Informe Horizon 2017 (New Media Consortium [NMC], 2017) menciona que “En la educación superior se hace hincapié en los enfoques de aprendizaje más profundo, definido como el dominio del contenido que involucra a los estudiantes en el pensamiento crítico, la resolución de problemas, la colaboración y el aprendizaje autodirigido” (párr. 6). Este texto trata de contribuir a ello.

La estadística es una herramienta esencial en la formación profesional de un gerente; toda persona responsable de la toma de decisiones debe tener una formación muy sólida en fundamentos de estadística, ya que ella interactúa directamente con la investigación, el mercadeo, el control de calidad, las ventas, la producción, el área financiera, etc. En el campo empresarial la estadística es una herramienta analítica muy poderosa que puede servir como base para tomar decisiones inteligentes y que marquen la diferencia, encontrar soluciones a problemas y hacer predicciones sobre el futuro; el problema es que si no se maneja adecuadamente, las decisiones que de allí surjan estarán completamente erradas y en lugar de ayudar a la compañía la pueden perjudicar más.

La labor a desarrollar en una organización requiere de personas con una alta dosis de creatividad, asertividad, sentido común y con un conocimiento profundo de técnicas administrativas y de análisis, entre otras. Cotidianamente un profesional del ámbito administrativo enfrenta situaciones donde se requiere la utilización de métodos y procedimientos que faciliten la organización, análisis y representación de las informaciones. Este texto aspira a aportar luces que logren ese fin.

Los capítulos son:

1. Técnicas descriptivas
2. Probabilidades
3. Estadística inferencial

4. Análisis de regresión y correlación

Los objetivos de aprendizaje pueden resumirse como:

- Procesar en forma clara y precisa la información objeto de estudio.
- Adquirir la capacidad de interpretar adecuadamente los resultados de un reporte estadístico.
- Modelar y predecir el comportamiento de variables para apoyar la toma de decisiones administrativas.
- Utilizar el concepto de probabilidad en la toma de decisiones administrativas en condiciones de incertidumbre.
- Modelar situaciones administrativas mediante las distribuciones especiales de probabilidades.
- Efectuar estimaciones y probar hipótesis estadísticas para apoyar científicamente la toma de decisiones administrativas.
- Realizar proyecciones por medio de ecuaciones de ajuste.
- Encontrar e interpretar la correlación entre variables.

El autor considera que para aprender estadística son mucho más trascendentales el sentido común, el pensamiento crítico y el análisis que la aplicación mecánica de fórmulas y cálculos.

La inmensa mayoría de los libros de estadística hacen un énfasis exclusivo en la parte numérica; es innegable que lo cuantitativo constituye una fracción indispensable de la Estadística porque, de hecho, es una rama de las Matemáticas, pero también es cierto que la parte matemática puede desarrollarse con la ayuda de un software, mientras que la comprensión íntegra de los conceptos y su aplicación práctica es irremplazable. Por eso este libro hace especial énfasis en la parte conceptual, mientras que la porción matemática se desarrolla con un software; existen muchos programas estadísticos interesantes, pero teniendo en cuenta el alcance del libro y la facilidad de acceso a los programas se decidió presentar todo en Excel. Se usará la versión 2013 de Excel; otras versiones contienen algunas diferencias, pero estas son generalmente sutiles y pueden descubrirse de manera fácil en casi todas las situaciones.

En cada uno de los temas desarrollados en el libro se encontrará un contenido conceptual, acompañado de videos cortos (hay más de 5 horas de video), ejemplos, ejercicios resueltos en video, ejercicios propuestos y preguntas adicionales; todas esas partes son necesarias para una comprensión integral del tema.

Todas las tablas y figuras contenidas en este libro fueron realizadas por el autor.

1. TÉCNICAS DESCRIPTIVAS

En este capítulo se estudiarán técnicas adecuadas para el manejo de la información, según el tipo de variable que se evalúe; esto constituye una labor enriquecedora para la vida profesional y el adecuado desarrollo de una organización.

En este primer capítulo se abordarán las técnicas y herramientas estadísticas para la recolección de información, identificación de tendencias y comportamiento de los datos. A lo largo de la vida de las empresas, estas se ven rodeadas por datos, variables y comportamientos que pueden o no regirse por ciertos patrones. En ese sentido, es necesario que el profesional del área administrativa posea todas las herramientas de tipo estadístico que le permitan recolectar, ordenar, representar y analizar estos datos, con el fin de tomar decisiones acertadas en favor del progreso de las organizaciones.

Es muy común que cuando se hace una investigación sea necesario el desarrollo de una encuesta o cualquier otra herramienta de recolección de datos; el procesamiento inicial de los datos que se hace tras dicha recolección se realiza a través de las técnicas que se trabajan en este capítulo; de ahí la importancia de su estudio. Sin embargo, es muy importante resaltar que la Estadística Descriptiva describe y analiza un conjunto de datos sin pretender sacar conclusiones generales; eso significa que las conclusiones que se deriven de un estudio descriptivo son solamente aplicables a los elementos de los cuales se tienen datos, aunque puede reportar comportamientos específicos.

También es muy importante adquirir la capacidad de interpretar adecuadamente los resultados de un reporte estadístico, lo que implica que es trascendental comprender cómo se elaboran, pero también cómo interpretarlos.

Todas las herramientas que aquí se mencionarán se convierten en base fundamental para enfrentar los temas de los otros capítulos, para finalmente utilizar la información de manera oportuna para el desarrollo de estrategias y aprovechar así el enorme poder de los datos para aplicar en la empresa una gestión inteligente.

Se empezará por definir algunos conceptos elementales que son básicos para una comprensión integral de la estadística.

Estadística: es un conjunto de métodos científicos que estudian la recolección, resumen, análisis e interpretación de datos, para ayudar en la toma de decisiones informadas e inteligentes, o para explicar comportamientos de algún fenómeno o estudio, principalmente en aquellos casos en que hay incertidumbre.

Podríamos, entonces, definir la estadística como la herramienta que estudia cómo sacar provecho de la información y cómo sugerir una guía de acción en situaciones que implican incertidumbre.

Anderson, Sweeney y Williams (2016) dicen que:

En particular en los negocios y la economía, la información que se obtiene a partir de la recolección, el análisis, la presentación y la interpretación de los datos permite a los administradores o gerentes y a quienes toman decisiones comprender mejor los entornos económico y de los negocios, y por tanto tomar decisiones mejores y más informadas (p.3).

La estadística es muy importante en cualquier área de la administración:

Por ejemplo, en administración de mercadeo, cuando se pretende incursionar con un producto nuevo, no basta con que el producto cumpla especificaciones técnicas, sino que es indispensable conocer las tendencias del sector económico en el que se pretende incursionar, así como analizar el resultado de las encuestas de mercado, para medir el grado de aceptación del nuevo producto y tomar decisiones que nos ayuden a minimizar riesgos. Todo en una organización va articulado, por eso, del resultado de las encuestas aplicadas, dependerá una acertada proyección de ventas y de ella el presupuesto necesario para poner en funcionamiento dicho proyecto. Una vez la empresa esté posicionada en el mercado, cobra mucha más importancia los datos estadísticos para lograr su sostenibilidad y permanencia en el tiempo.

En la administración financiera la estadística es de vital importancia para la toma de decisiones correctas, puesto que es una herramienta que permite analizar datos y hacer correlaciones; le da mayor asertividad, confiabilidad y validez a la información que obtenemos para finalmente planear las estrategias adecuadas en los procesos, nos permite sugerirle a la empresa qué puede ser rentable y qué no para la misma, realizar proyectos de inversión, presupuestos, gestión de créditos entre otros.

Y así sucesivamente. Si recorremos área por área, en todas encontraremos aportes valiosos. Lo transcendental es entender que estadística no es solamente organizar unas cifras, lo principal es lo que se decida a partir de la información que ellas nos brinden.

La estadística no es la última palabra a la hora de tomar decisiones, pero sí se convierte en una excelente herramienta e instrumento a tener en cuenta para complementar y conformar un sólido argumento y una seria respuesta a muchas de las decisiones que a diario tiene que enfrentar una persona. Siempre debemos utilizar las herramientas estadísticas como guía o direccionamiento, pero no podemos pretender que proporcionen el único concepto válido, ya que es solamente una pequeña parte de todo un complejo.

La estadística se divide en:

- E. Descriptiva, que representa y analiza un grupo de datos utilizando métodos que sintetizan y presentan la información contenida en ellos mediante un orden lógico que logre revelar rápida y fácilmente el mensaje que contienen, ya que muchos datos desorganizados son de poco valor. En este caso, los resultados del análisis no pretenden ir más allá del conjunto de datos, lo que implica que no permite hacer generalizaciones y que sus conclusiones son válidas únicamente para el grupo analizado.

El objetivo de la Estadística descriptiva es presentar la información con un orden lógico. El método estadístico para resumir los datos y obtener información depende del tipo de variable que se evalúe. Análisis de este tipo se encuentran permanentemente en informes, artículos y estudios investigativos; por eso es muy importante comprender su elaboración y su interpretación.

- E. Inferencial, cuyo objetivo es la generalización acerca de las características de una población, a partir de los datos obtenidos de una muestra; para que dicha generalización sea válida se apoya en la teoría de probabilidades.

¡PIENSA!

¿Por qué y para qué la estadística en tu profesión?

Población: conjunto de elementos de interés en un determinado estudio; deben tener una característica común. Se trabaja con una población cuando nuestro estudio se basa en datos reunidos para todos los elementos que cumplen la característica definida.

El tamaño de la población se representa como N .

Muestra: subconjunto de la población; debe ser una porción representativa, tanto en cantidad como en calidad. Representativa en cantidad implica que no puede ser muy pequeña en relación a la población (hay métodos estadísticos para hallar el tamaño apropiado de muestra); representativa en calidad implica que la muestra sí sea reflejo de la población de la cual se extrae, lo que significa que, si por ejemplo se quiere sacar una conclusión para toda la población colombiana, en la muestra debe haber personas de diferentes regiones diferentes estratos sociales, hombres, mujeres...

Algunas razones por las cuales es necesario seleccionar una muestra son:

- El costo de estudiar a todos los integrantes de una población con frecuencia es muy alto.
- Frecuentemente el ponerse en contacto con toda la población supondría mucho tiempo.

- La idoneidad de los resultados de una muestra, ya que generalmente puede proporcionar información muy precisa sobre las principales propiedades de la población.
- La naturaleza destructiva de ciertas pruebas.
- La imposibilidad física de verificar todos los artículos de la población.

El tamaño de la muestra se representa como n .

Variable: es una característica que al ser evaluada puede adoptar valores diferentes. Las variables pueden ser:

- **Cualitativas:** etiquetas o nombres que se usan para identificar un atributo de un elemento, como por ejemplo la ciudad de origen de un grupo de empresas o la calificación como bueno, regular o malo del servicio que presta un negocio. Pueden ser numéricas o no numéricas, aunque es más común que no sean numéricas; para procesar datos cualitativos es frecuente codificar con números las diferentes categorías, pero esos números tienen únicamente un carácter representativo y, por lo tanto, las operaciones aritméticas carecen de sentido en este caso.

Los datos cualitativos se dan en algunos casos en una escala ordinal, es decir, aunque sea algo nominal puede tener un orden intrínseco (por ejemplo algo que tenga la escala Excelente, Bueno, Regular y Deficiente).

- **Cuantitativas:** siempre se expresan en escala numérica. Pueden ser: discretas (solamente pueden asumir ciertos valores –generalmente enteros– y hay “huecos” entre ellos; son el resultado de un conteo) o continuas (pueden tomar cualquier valor dentro de un rango específico y son resultado de una medición).

Un ejemplo de una variable discreta es el número de microempresas de cierto sitio que han iniciado el proceso de internacionalización (pueden ser 0, 1, 50..., pero no podrían ser 15,8 o 42,67).

Un ejemplo de una variable continua es el tiempo.

De acuerdo con el interés que se tenga, lo que originalmente es cuantitativo puede convertirse en cualitativo (cualificarse). Por ejemplo, podría preguntarse por el número de empleados que tienen un grupo de empresas y en este caso la variable es cuantitativa, pero podría clasificarse esa misma variable en Microempresas (10 trabajadores o menos), Pequeña empresa (entre 11 y 50), Mediana (entre 51 y 200) o Grande (más de 200) y ahí la variable se está cualificando.

Se denomina elementos a los individuos sobre los cuales se evalúa la variable (o variables) que se maneja (n).

Veamos los siguientes ejemplos:

"Se hizo una encuesta a mil empresas de alimentos de Medellín para averiguar, de acuerdo con su tamaño, si se sienten preparadas para enfrentar el Tratado de Libre Comercio con Estados Unidos"

Variables: Tamaño (cualitativa si se evalúa como "grande" o "pequeña", cuantitativa si se evalúa según el número de empleados o el área de su planta en cifras) y nivel de preparación para enfrentar TLC con USA (cualitativa si se evalúa como "sí está preparada" o "no está preparada"; cuantitativa si, por ejemplo, se asigna una calificación de qué tan preparada está la empresa).

Elementos: Empresas de alimentos de Medellín.

"Se tiene duda de invertir en acciones, CDT o en una cuenta de ahorros; para decidirlo se evaluaron las tasas de rentabilidad mensual promedio de cada uno durante los últimos meses"

Variable: Tasa de rentabilidad mensual promedio (cuantitativa).

Elementos: acciones, CDT y cuentas de ahorro.

"Algunas pequeñas y medianas empresas antioqueñas exportan parte de su producción a países del Grupo Andino. Para estimar el monto de esas exportaciones se hizo un muestreo entre cien empresas y se investigó a cuánto ascendían sus exportaciones en el último mes"

Variable: Monto de exportaciones en el último mes (cuantitativa).

Elementos: Pequeñas y medianas empresas antioqueñas.

En cualquier situación es necesario tener presente que lo primordial no es la cantidad de información, sino lo que se hace con ella y que realmente sirva para plantear estrategias que permitan mantener lo bueno o corregir lo malo. La información es un activo muy valioso para cualquier empresa.

Sin embargo, sería poco práctico presentar todo tipo de informes, cuadros y planteamientos que muestren las dificultades que tenga la empresa si los resultados se quedan únicamente en el papel y no se materializan las soluciones presentadas.

Para el desarrollo de los diferentes temas de Técnicas descriptivas se evaluará el siguiente caso:

Hace 18 años en el municipio de La Ceja, Antioquia, nació una pequeña fábrica de embutidos llamada *La Reyna*. En el 2013 esa empresa lanzó su línea de productos light: jamón Reyna Oro, salchicha Reyna y mortadela Reyna.

La empresa no vende directamente sus productos, sino que se comercializan en diferentes supermercados de Medellín.

Los clientes han hecho continuos reclamos por bajo contenido y por problemas en las propiedades organolépticas (características del producto que pueden ser percibidas por los órganos de los sen-

tidos). La bodega realizó una inspección y tomó el peso de 50 unidades de cada producto; igualmente, en la base de datos se refleja la cantidad de reclamos recibidos en uno de los supermercados durante el mes anterior.

Ejercicio General Capítulo 1

¡PIENSA!

De acuerdo con los datos, ¿qué observaciones crees que podrían ser importantes?

¡PIENSA!

¿Cómo puede la Empresa apoyarse en estadística para solucionar el problema y qué podría pasar si no se fundamenta en información estadística para buscar una solución?

Como se dijo inicialmente, el manejo de los datos se hace según el tipo de variable que se esté evaluando. Si la variable es cuantitativa se elaboran tablas, gráficos y análisis numérico; pero si la variable es cualitativa solamente se hacen tablas y gráficos, ya que en este caso el análisis numérico se reduciría a algo muy simple porque dicho análisis implica la utilización de operaciones aritméticas.

En la base de datos se encuentra una variable cuantitativa (peso) y una variable cualitativa (propiedad organoléptica por la que hacen reclamo).

1.1 VARIABLES CUALITATIVAS

1.1.1 TABLAS:

El medio más simple para resumir un conjunto de observaciones es una tabla; puede construirse una tabla de frecuencias (si se hace referencia a una variable) o una tabla de contingencia (si se evalúa el cruce de varias variables).

La tabla de frecuencias o distribución de frecuencias muestra qué tantos elementos pertenecen a cada una de las clases (resultados que toma la variable en el caso bajo estudio), dichas clases son por lo general mutuamente excluyentes (cada individuo pertenece únicamente a una categoría) y exhaustivas (cada individuo debe pertenecer a cualquiera de ellas); por esa razón, si es necesario, debe agregarse alguna clase llamada “otros” o “no responde” o algo similar. El objetivo de tal distribución es proporcionar una perspectiva de los datos.

Un caso en que las clases no son excluyentes y exhaustivas se da cuando una pregunta tiene múltiples respuestas posibles; en ese caso la suma de las frecuencias puede exceder el 100%. Por ejemplo, si se pregunta a una muestra de 50 personas por la marca de productos lácteos que le gusta, la respuesta de cada persona puede ser más de una y, entonces, los elementos “registrados” serían más de 50.

La distribución de frecuencias para una variable cualitativa está constituida por:

Frecuencia absoluta (n_i): indica cuántos elementos pertenecen a cada clase.

Frecuencia relativa (h_i): indica la proporción de elementos en cada clase, por lo tanto está dada por la razón entre la frecuencia absoluta de cada clase y el número total de observaciones.

Por razones obvias es mucho más común y práctico expresarlas como un porcentaje. No hay una norma universal para determinar cuántas cifras decimales usar cuando se usa un porcentaje, pero es apropiado usar por lo menos una cifra decimal, principalmente si el número total de elementos es grande; la cantidad apropiada de cifras decimales depende principalmente de dos elementos:

- Magnitud de la unidad de medida: si, por ejemplo, la unidad de medida es millones de euros una décima representa cien mil euros, que es una considerable cuantía de dinero, pero si por ejemplo la unidad de medida es pesos colombianos, una décima significa 10 centavos, que es una cantidad insignificante de dinero.

- Tamaño de la cifra: si un número es muy pequeño, una décima o una centésima son muy significativas, pero si la cantidad es grande una décima o una centésima son poco importantes. Por ejemplo, la diferencia entre 0,1 y 0,2 es muy significativa y, de hecho, un número es el doble del otro, pero la diferencia entre 85000,1 y 85000,2 no es sustancial.

Si la variable cualitativa es ordinal, es decir, si sus valores tienen un orden lógico, pueden calcularse frecuencias acumuladas; cuando se mencionen las variables cuantitativas se hará más énfasis en ello.

Para hacer el conteo en Excel pueden utilizarse diferentes herramientas; entre ellas está el empleo de la función **CONTAR.SI**. Su uso se explica a continuación:

<https://www.youtube.com/watch?v=A23bFrjakL8>

También pueden hacerse tablas dinámicas; su desarrollo se explica en el siguiente video:

<https://www.youtube.com/watch?v=DU690dG34sA>

Archivo con los datos para practicar:

[Contar.si y Tabla dinámica 1](#)

EJEMPLO 1

Los clientes de La Reyna han hecho continuos reclamos por problemas en las propiedades organolépticas (características físicas del producto que pueden reconocerse por los órganos de los sentidos). En el archivo que se presenta a continuación se muestra un listado de dichos reclamos:

Ejemplo 1_Descriptiva

En el Departamento de Calidad deben elaborar una tabla resumen de la propiedad organoléptica por la que hacen reclamo en la salchicha para definir estrategias a partir de ella.

Se detecta entonces que, de acuerdo con los reclamos de los clientes, la propiedad organoléptica más afectada en la salchicha es el sabor con casi la mitad de los reclamos. Deben evaluarse los diferentes procesos (producción, transporte, empackado, etc.) para detectar posibles causas de los problemas.

Elabora las tablas de frecuencia para mortadela y jamón

¡PIENSA!

Determina posibles causas de los problemas y estrategias de mejoramiento a partir de lo observado en las tablas de frecuencia.

Cuando la variable cualitativa que se evalúa es ordinal, es decir, presenta un orden intrínseco, también se hallan frecuencias acumuladas, que son las sumas de las frecuencias (absolutas o relativas) de cada clase con las de las clases anteriores; se representan como N_i (frecuencia absoluta acumulada) y H_i (frecuencia relativa acumulada); se encuentran con el fin de mostrar la cantidad de elementos que están en la respectiva categoría o en una de las anteriores. Veamos el siguiente ejemplo:

Si el interés principal consiste en comprender la relación entre dos variables, para resumir los datos

se utiliza la tabulación cruzada; en ella, los encabezados de los márgenes izquierdo y superior definen las clases de las dos variables; dicha tabla se llama tabla de contingencia.

1.1.2 GRÁFICOS:

Una segunda manera de resumir y presentar información consiste en la utilización de gráficos; ellos deben diseñarse de tal forma que comuniquen de manera elemental los patrones generales de un conjunto de observaciones, para que puedan percibirse los hechos esenciales y sea fácil compararlos con otros.

La elaboración de un gráfico persigue uno o algunos de los siguientes objetivos: síntesis, descubrimiento, control, comparación y búsqueda de regularidades.

Cada vez es más habitual el uso de gráficos o imágenes para representar la información obtenida. No obstante hay que ser prudentes al elaborar o interpretar gráficos, puesto que una misma información puede representarse de formas muy diversas y no todas ellas son pertinentes, correctas o válidas.

El tipo de gráfico debe coincidir con el tipo de información o el objetivo que se persigue al representarla; de otra manera la representación gráfica se convierte en un instrumento ineficaz, que produce más confusión que otra cosa y podría ser innecesario o productor de interpretaciones equivocadas.

Debe tenerse presente que lo más importante no es presentar gráficos muy bonitos o análisis estadísticos muy rimbombantes, sino que a partir de la información que ellos brinden se busquen estrategias para dar solución a los problemas.

HAY QUE TENER EN CUENTA QUE LOS GRÁFICOS ESTADÍSTICOS SE UTILIZAN POR CONCISIÓN Y FACILIDAD DE INTERPRETACIÓN; SI NO SE HA DE LOGRAR ES MEJOR NO EMPLEARLOS.

Si la variable que se está analizando es cualitativa se utilizan principalmente los siguientes gráficos:

- **Diagrama de columnas:** En el eje horizontal de un diagrama de columnas se especifican los indicadores o nombres de cada clase y en el eje vertical se representa una escala de frecuencias, bien sea absoluta o relativa. Posteriormente, se traza una barra de un ancho igual para todas las clases sobre cada indicador de clase hasta llegar a la altura correspondiente a la frecuencia respectiva; las barras se separan para señalar que cada clase es una categoría independiente.

Un diagrama es un ente individual; eso significa que debe contener toda la información necesaria en su interior, incluyendo un título del gráfico adecuado según lo que se represente y un título de los ejes acompañado de la unidad de medida utilizada, independientemente de lo que lo acompañe, ya sea una tabla de datos o un texto.

Las barras también pueden trazarse horizontalmente, pero la filosofía de la gráfica es la misma. En Excel este diagrama se denomina Gráfico de barras.

Si se está haciendo el estudio conjunto de dos variables y ambas son cualitativas debe construirse un diagrama de barras compuestas; si por lo menos una de las variables es cuantitativa debe analizarse la posibilidad de cualificarla(s). El gráfico que se muestra a continuación es un ejemplo de ello; contiene una variable cualitativa (franquicia o no franquicia) y una variable cuantitativa (tiempo de supervivencia), pero esta última variable se cualificó en dos grupos (“10 años o más” y “menos de 10 años”).

Si las dos son cuantitativas y no es pertinente cualificarlas (o no quiere hacerse) debe construirse un diagrama de dispersión; en el último capítulo de este libro se estudiará este gráfico.

- **Diagrama circular o de sectores:** Es más apropiado para representar distribuciones de frecuencias relativas. Para trazarlo, se divide un círculo en tantas porciones como clases existan, de modo que a cada clase le corresponda un arco de círculo proporcional a su frecuencia.

1.1.3 ANÁLISIS NUMÉRICO

Lo que se busca con ellos es reducir la información a unas cuantas cifras que concentren la información más relevante; dichas cifras se denominan estadísticos de resumen o medidas de resumen.

Cuando la variable que se evalúa es cualitativa, el único estadístico de resumen útil es la moda, que es la clase que tiene mayor frecuencia; en el ejemplo bajo estudio, la moda es el sabor porque es la propiedad por la que más hicieron reclamos. Un conjunto de datos puede ser multimodal (varias modas), unimodal (una moda) o carecer de moda.

No puede utilizarse ninguna otra medida porque todas implican la realización de operaciones aritméticas.

1.2 VARIABLES CUANTITATIVAS

1.2.1 TABLAS DE FRECUENCIA: Si la variable es discreta y tiene pocos resultados posibles, la tabla de frecuencias se hace como la de cualitativas. Pero al igual que en las cualitativas ordinales, deben agregarse las frecuencias acumuladas con el fin de mostrar la cantidad de elementos menores o iguales a cada clase.

Cuando la variable es continua o es discreta con muchos resultados posibles se debe hacer un agrupamiento de los datos. Para ello debe emplearse cierto criterio, de tal forma que pueda desarrollarse un diagrama razonable (Montgomery y Runger, 1996, p. 8). En general, se recomienda usar entre 3 y 10 clases de igual ancho, según el tamaño de la muestra (a mayor tamaño de muestra, más clases); el número de clases debe ser suficiente para mostrar la variabilidad en los datos, pero no deben ser muchas porque no se cumpliría el objetivo de resumir la información –ya que no se tendrían grandes ventajas en comparación a los datos sin procesar– ni muy pocas porque se perdería gran cantidad de información.

Como regla general se recomienda utilizar el mismo ancho para todas las clases (salvo casos excepcionales), con el fin de facilitar la comparación entre clases y reducir la probabilidad de una interpretación errónea. Para determinar un ancho aproximado de clase se empieza por identificar el rango del conjunto de datos –dado por la diferencia entre el valor máximo y el mínimo– y se divide por la cantidad de clases que se quiera construir.

Notas:

- También suele calcularse la marca de clase, que es el promedio entre los límites de cada intervalo y es, por lo tanto, un valor representativo de todo el conjunto.
- No hay distribución óptima de frecuencias para determinado conjunto, ya que distintas personas pueden formar distribuciones diferentes, aunque todas ellas sean igualmente correctas; el objetivo es mostrar el agrupamiento natural y la variabilidad en los datos. Existen algunas fórmulas para determinar el número apropiado de intervalos, pero el analista puede seleccionar ese número de manera subjetiva.
- Es conveniente aclarar si los límites de los intervalos son abiertos o cerrados, de manera que quede claro a cuál intervalo pertenece un valor igual a uno de los límites. No es conveniente crear espacios entre cada intervalo, especialmente si la variable es continua. Si no se aclara forma de los intervalos (abierto o cerrado) se asume que el valor de un límite de intervalo se tiene en cuenta en el primer rango en que se encuentre.
- Si hay datos muy extremos se acostumbra utilizar clases abiertas, es decir, con un solo límite (“x o más”, “y o menos”).
- Al hacer la distribución de frecuencias se gana cierto tipo de información pero se pierde otra. Por ejemplo, si hay cierta tendencia en el tiempo, esta información se pierde en el resumen.

- **Polígono de frecuencias acumuladas (ojiva):** los límites de cada intervalo van en el eje x y las frecuencias acumuladas se muestran en el eje y. La ojiva comienza en el límite inferior de la primera clase, se traza otro punto en el cruce del límite superior y la frecuencia de esa clase, y así sucesivamente para cada límite superior y la frecuencia acumulada correspondiente. Finalmente, los puntos graficados se unen con rectas y el resultado es la ojiva.

1.2.3 ANÁLISIS NUMÉRICO

La tabla de frecuencias y la representación gráfica nos permiten tener una idea global de la distribución de los datos; pero esta idea es netamente cualitativa y también es de interés un resumen cuantitativo, de tal manera que sirva para estudios o conclusiones posteriores y para comparación con otras distribuciones. Su objetivo es sintetizar las características dominantes del conjunto de datos mediante el cálculo de unas cifras que sean representativas de la muestra o de la población.

Los estadísticos de resumen pueden ser muy engañosos cuando se mezclan distintas poblaciones (o poblaciones con subgrupos muy marcados), por lo que debe tenerse mucho cuidado. Si hay más de una variable, los estadísticos de resumen deben calcularse por separado para cada variable.

Existen varios tipos de estadísticos de resumen, pero este texto se centrará en el uso de medidas de localización y medidas de dispersión. Las medidas de localización se dividen en medidas de tendencia central (media, mediana y moda) y medidas de posición (percentiles y cuartiles); las principales medidas de dispersión son rango, varianza, desviación estándar y coeficiente de variación.

Para mostrar el ejemplo de los cálculos manuales se considerará el caso de los 10 primeros pesos de los paquetes de salchicha (en gramos) dentro de la muestra de 50 elementos, pero se presentarán únicamente cálculos manuales al introducir los conceptos.

1.2.3.1 MEDIDAS DE LOCALIZACIÓN

Son medidas que contribuyen a la ubicación de un valor determinado en un conjunto de datos. Entre ellos están:

1.2.3.1.1 MEDIDAS DE TENDENCIA CENTRAL

Son valores que se ubican aproximadamente en el centro del conjunto de datos.

- **Media aritmética (Promedio):** es la medida de localización central más empleada. Puede calcularse de forma simple o ponderada.

La media ponderada también puede utilizarse cuando se tienen datos continuos agrupados y no se conocen los datos individuales; en dicho caso se usa cada marca de clase como x_i . Pero si se conocen datos individuales, es mejor calcular el promedio simple, aunque los datos sean muchos.

La media aritmética tiene varias propiedades importantes:

1. La media actúa como centro de gravedad, ya que equilibra desviaciones positivas y negativas de los datos. Una desviación es la distancia entre cada dato y la media, es decir, $(x_i - \bar{X})$. Por ejemplo, si se tiene una muestra formada por los valores 6, 11, 8, 10 y 15, su media es 10 y las desviaciones de los datos con relación a la media son respectivamente -4, 1, -2, 0 y 5; sumando estas últimas cinco cifras se obtiene como resultado cero.
2. Es muy sensible a valores extremos.
3. Para calcularse se tienen en cuenta todos los valores.
4. Es única, lo que significa que un conjunto de datos tiene solamente una media.
5. Si debe ponderarse, la media se ve muy afectada por los valores con mayor peso (tienden a arrastrar a los demás).

Nota: Aunque una variable sea discreta, puede tener media (y, en general, cualquier medida de resumen) que no sea un valor entero.

Más adelante se explicará un método para obtener de forma instantánea la mayoría de los estadísticos de resumen, pero si quiere obtenerse una media en forma individual en Excel se emplea la función **PROMEDIO**. El único parámetro que debe ingresarse es el rango de datos; por ejemplo, si el intervalo A1:A50 contiene los datos, la fórmula =PROMEDIO(A1:A50) arroja la media aritmética de esos datos.

Cuando se interpreta un promedio deben aclararse espacio y tiempo. Por ejemplo, no debe decirse que las ventas de una empresa son en promedio 500 millones de pesos, sino que debe mencionarse que las ventas de la empresa X (con nombre) han sido en promedio 500 millones de pesos por mes durante los últimos dos años, es decir, ser muy específicos. Lo anterior demuestra que también es imprescindible que se mencione el período de ocurrencia, es decir, si el promedio es mensual, diario, anual, semestral..., ya que al mencionar el tiempo no tiene porqué deducirse inmediatamente el período; por ejemplo, decir que es un promedio de las ventas durante los últimos cinco años no implica que el promedio sea anual.

También es muy importante que se mencione si se trata de un promedio o no. Por ejemplo, es muy distinto decir que las ventas de cierta empresa son 500 millones de pesos por mes a decir que son en promedio de 500 millones de pesos por mes; lo primero implica que en todos los meses las ventas son exactamente por ese monto.

Por último, siempre que sea posible es indispensable utilizar la unidad de medida cuando se menciona un promedio (y en general cualquier medida de resumen).

- Mediana es el valor que supera a la mitad de los datos y es superado por la otra mitad (valor central). Para calcularla, se deben ordenar los valores de medida; la mediana es el valor que se encuentra en el centro, pero si n es par la mediana es el promedio de los dos valores centrales.

Si unos pocos valores son extremadamente grandes o extremadamente pequeños, la media aritmética puede no ser una cifra apropiada para representar los datos. Por el contrario, la mediana no se ve afectada por valores extremos y por eso es preferida en casos donde existen valores de este tipo; se dice que la mediana es robusta, lo que significa que es mucho menos sensible a los datos atípicos.

Cada una (media y mediana) tiene ventajas y desventajas según los datos y el objetivo perseguido; ambas medidas diferirán mucho cuando la distribución no es muy simétrica, lo que sugiere heterogeneidad en los datos.

Estrictamente hablando la mediana también es un promedio; solo que cotidianamente se habla de promedio como un equivalente de la media aritmética.

En Excel la mediana se calcula con la función **MEDIANA**; el único parámetro que debe ingresarse es el rango de datos

- **Moda (Mo):** es el valor de los datos que tiene mayor frecuencia. La moda es considerada una medida de tendencia central, pero no siempre está ubicada cerca del centro.

En el ejemplo la moda es 488 gramos porque es el único dato que se repite, aunque está solamente dos veces.

En versiones recientes de Excel se calcula con la función **MODA.VARIOS**; si un conjunto de datos tiene varias modas las presenta como una matriz vertical.

1.2.3.1.2 MEDIDAS DE POSICIÓN:

Determinan la ubicación de los valores que dividen un conjunto de datos en partes iguales porcentualmente.

- **Percentiles:** “el percentil p es un valor tal que por lo menos $p\%$ de las observaciones son menores o iguales que este valor y por lo menos $(100 - p)\%$ son mayores o iguales que este valor” (Anderson et al., 2016, p. 108). Por ejemplo, el valor de un percentil 80 es superado por el 20% de los datos del conjunto o es igual a algunos de ellos y es igual o superior al 80% de ellos.

Un percentil se calcula en Excel con la función **PERCENTIL.INC**; esta función pide dos argumentos: Matriz, que corresponde al rango de los datos, y k , que es un número de 0 a 100%, que corresponde al percentil que quiere calcularse. Por ejemplo, si quiere hallarse el percentil 70, k es 70% o 0,7.

En el ejemplo que viene desarrollándose el percentil 70 tiene aproximadamente el valor del séptimo dato una vez ordenados (70% del número de datos, es decir de 10). El cálculo exacto puede hacerse con un programa estadístico.

- **Cuartiles:** son simplemente percentiles específicos, resultado de dividir la distribución en cuatro partes iguales porcentualmente.

Por tal razón, el cuartil 1 (Q1) equivale al percentil 25, el cuartil 2 (Q2) corresponde al percentil 50 (mediana, y por lo tanto nunca se calcula) y el tercer cuartil (Q3) al percentil 75. Eso significa que el 25% de los elementos tienen un valor inferior al cuartil 1 mientras que el 75% de los elementos tienen un valor superior a él; del mismo modo, el 25% de los elementos tienen un valor superior al cuartil 3.

En el ejemplo que viene haciéndose, el cuartil 1 es aproximadamente el promedio entre los valores segundo y tercero, mientras que el cuartil 3 es aproximadamente igual al promedio entre los valores 7 y 8. Igualmente, puede calcularse de forma exacta con la ayuda de un programa estadístico.

En Excel, un cuartil se calcula con la función **CUARTIL.INC**; deben ingresarse dos argumentos: Matriz, que es el rango de datos, y Cuartil, que es 1 o 3, según el cuartil que desea calcularse; si en el espacio Cuartil se ingresa 0 se obtiene el valor mínimo, si se ingresa 4 se encuentra el valor máximo y con 2 se obtiene la mediana.

Aunque no corresponde exactamente con el concepto estadístico, es muy común mencionar cuartiles no como un valor, sino como un espacio que contiene el 25% de los datos; en ese caso se considera el cuartil 1 como el espacio que contiene la cuarta parte de los elementos con menor valor respecto a la variable que se está evaluando y el cuartil 4 como el espacio que contiene la cuarta parte de los elementos con mayor valor. Mirándolo de esta manera el cuartil 1 es la región comprendida entre el valor mínimo y el valor que estadísticamente se determina como Q1, el cuartil 2 es la región entre Q1 y mediana, el cuartil 3 está entre mediana y Q3, y el cuartil 4 está entre Q3 y el valor máximo.

1.2.3.2 MEDIDAS DE VARIABILIDAD O DISPERSIÓN

No siempre las medidas de localización suministran toda la información necesaria para describir adecuadamente unos datos; con las medidas de dispersión se muestra qué tan esparcidos están los datos. Dos conjuntos pueden diferir tanto en tendencia central como en variabilidad, pero también puede ocurrir que tengan medidas de tendencia central similares y ser diferentes en términos de dispersión; es por eso que una sola clase de medida es insuficiente.

Un valor pequeño en una medida de dispersión indica que los datos están estrechamente agrupados alrededor de la media; esto implica, entonces, que una medida de dispersión puede considerarse como medida del riesgo en los casos en que tiene sentido hablar de ello (Dispersión alta implica alto riesgo).

Se considerarán varias medidas de dispersión:

- **Rango (R):** es la medida de dispersión más sencilla pues, como ya se había dicho, es simplemente la diferencia entre los datos mayor y menor.

En el ejemplo, el rango es la diferencia entre 506 y 475 gramos, es decir, 31 gramos.

No es muy recomendable debido a que, al basarse únicamente en dos de los elementos, se ve muy influenciado por valores extremos, pero por su facilidad de cálculo es usado muchas veces para el control de procesos estadísticos. Para mitigar la posible influencia de valores extremos muchas veces se calcula el rango intercuartílico, que es la diferencia entre los cuartiles 3 y 1.

La forma más natural de medir dispersión toma la media como punto de referencia. Aparentemente lo más lógico sería calcular la diferencia de cada valor con respecto a la media (desviaciones) y promediarlos, pero la sumatoria de las desviaciones siempre es cero; por ello se han buscado otras alternativas para calcular la dispersión. Entre ellas están las medidas que se mencionan a continuación.

- **Varianza:** un método consiste en eliminar signos, empleando valores absolutos, pero esto no es lo más adecuado. Una segunda idea consiste en eliminar signos, pero sin emplear valores absolutos, sino elevando al cuadrado; de esa idea se deriva la varianza, que es el dato promedio de las desviaciones cuadráticas respecto a la media. La varianza de una población se representa como σ^2 (sigma al cuadrado) y la varianza muestral se representa con S^2 o σ_{n-1}^2 .

En Excel se emplean la función **VAR.P** si desea calcularse la varianza de una población o **VAR.S** si lo que quiere calcularse es la varianza de una muestra.

- **Desviación típica o estándar:** como las unidades de la varianza son cuadradas, es difícil formarse una idea intuitiva e interpretar su valor numérico. Por ello es más conveniente usar su raíz cuadrada positiva para medir variabilidad, lo que se conoce como desviación estándar. La desviación estándar poblacional se representa como σ (sigma) y la desviación estándar muestral se representa como S o s .

En Excel se calculan con las funciones **DESVEST.P** (si es poblacional) o **DESVEST.M** (si es muestral).

Una inmensa cantidad de los datos se encuentran en el rango $\text{Media} \pm 2(\text{Desviación estándar})$. Datos que caigan por fuera de este rango pueden considerarse como atípicos.

Al comparar dos grupos de datos, el grupo con la menor desviación estándar tiene las observaciones más homogéneas. Sin embargo, la magnitud real de la desviación estándar depende de los valores del conjunto de datos –lo que puede ser grande para un grupo de datos puede ser pequeño para otro–; además, como la desviación estándar tiene unidades de medición, comparar las desviaciones típicas de dos cantidades no relacionadas carece de significado.

- **Coefficiente de variación (CV):** es una medida relativa de variabilidad, que evalúa qué tan grande es la desviación estándar en relación con la media.

Como la desviación estándar y la media tienen las mismas unidades de medición, se cancelan y el coeficiente de variación es adimensional. Si se multiplica por 100 queda expresado en porcentaje.

Si se evalúa una sola muestra y el coeficiente de variación es pequeño (más o menos inferior a 10%), puede afirmarse que dicha muestra es muy homogénea; si es grande (superior al 30% aproximadamente) la muestra es muy heterogénea.

Es conveniente aclarar que si un proceso debe ser muy estandarizado, el coeficiente de variación debe ser muy cercano a 0, por lo cual si es de 2 o 3% ya está mostrando que hay variaciones significativas.

El coeficiente de variación es particularmente útil al comparar la variabilidad de dos o más grupos de datos que se expresan en diferentes unidades de medida o si la media es muy distinta (en estos casos las desviaciones estándar no son comparables). Si se están comparando dos o más grupos, un CV inferior a 10% puede considerarse indicativo de una alta dispersión si con el que es comparado es mucho menor.

Se revela que el promedio de los pesos de ninguno de los productos llega al peso que se registra en la etiqueta (según la base de datos es de 500 gramos para jamón y salchicha, y 250 gramos para la mortadela). Estas diferencias de 4 y 5 gramos podrían considerarse pequeñas si se tratara de uno o dos empaques, pero como se trata de los promedios de 50 paquetes de cada producto puede concluirse que hay un error sistemático en el proceso de empackado.

Los coeficientes de variación parecen cifras pequeñas, pero debe tenerse en cuenta que el empaclado es un proceso que debe ser muy estandarizado y esas cifras están mostrando que hay pesos diferentes en lo evaluado; por ejemplo se encontró un paquete de salchicha con un peso de 475 gramos y otro de 511 gramos. Lo ideal sería que el coeficiente de variación fuera 0% o muy cercano a ese valor (todos los pesos iguales o casi iguales) porque muchos paquetes con menos del contenido requerido pueden conducir a sanciones para la empresa, pero muchos paquetes con más del contenido requerido también revisten un problema porque implican pérdida de materia prima.

Los cuartiles 1 demuestran que la cuarta parte de los paquetes con menor peso de cualquiera de los productos tienen un peso muy inferior al requerido, mientras que los cuartiles 3 muestran que la cuarta parte de los paquetes con mayor peso de cualquiera de los productos ni llega o apenas sobrepasa los pesos requeridos; de allí puede deducirse que aproximadamente el 75% de los paquetes evaluados tienen un peso igual o inferior al mencionado en la etiqueta.

Las medianas muestran que más de la mitad de los paquetes de cada producto tienen un peso inferior al que revela la etiqueta.

Comparaciones:

De la tabla puede deducirse que la empresa que hizo mayores ventas durante los dos años fue la empresa C, que hizo ventas por 19955 millones de pesos (casi el doble de las ventas de la empresa B en ese tiempo y casi el cuádruple de las ventas de la empresa A). Eso implica que la empresa C tuvo un promedio de ventas mensuales de 831,46 millones de pesos ($19995/24$), obviamente los promedios de A y B están en la misma proporción porque para todos existe la misma cantidad de datos.

Puede observarse que la empresa que tuvo mayores ventas (C) es la que presenta menor dispersión (determinada por el coeficiente de variación), mientras que la empresa B es la que tiene mayor dispersión en las ventas mensuales durante los dos años, ya que su coeficiente de variación es el mayor, lo cual significa que hubo meses en que las ventas fueron mucho mayores que en otros (por ejemplo, en un mes se hicieron ventas por 115 millones de pesos, mientras que en otro mes se hicieron ventas por 300 millones de pesos; en la empresa C (la de menor coeficiente de variación) hubo la mayor regularidad en las ventas mensuales (siempre fue la más alta, pero no cambiaba mucho).

También puede deducirse que en la cuarta parte de los meses evaluados (6 meses) la empresa A hizo ventas por 196,5 millones de pesos o menos, mientras que hubo 6 meses en que las ventas fueron superiores a 250,5 millones de pesos. Algo similar puede interpretarse con los cuartiles en las empresas restantes; eso evidencia que las ventas para cada una de las empresas tuvieron marcadas diferencias, pues se observa que la cuarta parte de los meses en que A hizo mayores ventas se vendió menos que en la cuarta parte de los meses en que B registró menores ventas, mientras que en la cuarta parte de los meses en que B registró mayores ventas vendió menos que en la cuarta parte de los meses en que más mal le fue en ventas a C.

Es importante destacar que no necesariamente los que tienen una desviación absoluta mayor (desviación estándar) tienen una desviación relativa mayor (coeficiente de variación). Puede observarse que C tiene la menor desviación relativa, pero no la menor desviación absoluta.

En 12 de los 24 meses analizados C hizo ventas por 835,5 millones de pesos o menos, valor eviden-

ciado por la mediana. Algo similar se deduce de las medianas de las ventas de A y B.

El mayor rango se presentó en B, ya que hubo un mes en que hizo ventas por muy poco (204 millones de pesos), mientras hubo otro mes en que registró ventas mucho mayores (698 millones de pesos). El rango muestra una diferencia absoluta (en millones de pesos), que no necesariamente es proporcional a la diferencia relativa (en porcentaje).

1.3 DIAGRAMA DE CAJA Y BIGOTES

El gráfico más apropiado para representar las diferentes medidas de resumen es el diagrama de caja y bigotes, también denominado box plot, que es una potente herramienta que permite identificar en un mismo gráfico medidas de localización y dispersión de un conjunto de datos. De un solo vistazo permite detectar si el grupo es simétrico (si lo es, los bigotes son de aproximadamente igual longitud y los rectángulos alrededor de la mediana también lo son), si es muy disperso (si lo es, la caja es muy ancha o los bigotes son largos) y algunas características adicionales.

Este diagrama presenta sobre un rectángulo los cuartiles, la mediana y los valores máximo y mínimo.

Algunas veces, en un diagrama de caja se grafican también la media y los datos atípicos; en este caso los bigotes se extienden hasta 1,5 veces la diferencia entre ambos cuartiles (rango intercuartílico).

Este diagrama también puede tener un fuerte impacto visual al hacer comparaciones entre diferentes grupos de datos que se pretenda cotejar.

1.4 OTROS GRÁFICOS:

1.4.1 RADIAL: es un polígono de tantos lados como características quieran representarse. Permite mostrar la evaluación de uno o varios elementos respecto a varios factores. A continuación se muestra un gráfico radial y un video con el proceso para obtenerlo:

Archivo con los datos para practicar:

[Gráfico radial](#)

1.4.2 VELAS: es un gráfico muy usado en el análisis técnico bursátil (manejo de acciones).

Según información suministrada en mercadoforex.net (2007)

El gráfico de velas muestra información de precio de apertura, cierre, máximo y mínimo. Además utiliza colores para mostrar si el precio de cierre fue mayor o menor que el precio de apertura.

El cuerpo de la vela muestra la diferencia entre el precio de apertura y cierre, y los correspondientes valores. El color del cuerpo depende de si el precio de cierre fue mayor o menor al precio de apertura. Si el precio de cierre fue mayor al precio de apertura, generalmente se representa al cuerpo de la vela con un color verde; si el precio de cierre fue menor al precio de apertura, se representa el cuerpo de la vela con un color rojo.

1.4.3 ÁREAS: se usa este gráfico cuando se quieren resaltar volúmenes. Es también muy usado para mostrar tendencias en el tiempo, ya que permite resaltar la magnitud del cambio en el transcurso del tiempo. Además se usa también para graficar frecuencias acumuladas cuando se quiere resaltar el volumen. Este gráfico tiene la siguiente forma:

1.4.4 DIAGRAMA DE DISPERSIÓN: permite mostrar relación entre dos variables.

1.4.5 DIAGRAMA DE LÍNEAS: permite mostrar el comportamiento de una o varias conjuntos en el tiempo.

Los dos últimos gráficos serán ampliamente utilizados en el capítulo 4.

1.5 MINERÍA DE DATOS Y BIG DATA

Las empresas deben enfrentar hoy un enorme incremento en la cantidad de datos que deben manejar; eso incluye dos procesos: *big data* y *minería de datos*.

El concepto de *big data* supone grandes cantidades de datos junto con las técnicas necesarias para poder recolectarlos, almacenarlos, gestionarlos y analizarlos. La tasa de crecimiento de los datos generados crece hoy a un ritmo exponencial; en 2015 *ScienceDaily* publicó una noticia de que el 90% de los datos de hoy se ha generado en los últimos dos años (Yaqoob, 2016). Eso genera en las empresas actuales un enorme desafío.

López (2014) destaca en *El Economista* que “El objetivo de *Big Data*, al igual que los sistemas analíticos convencionales, es convertir el dato en información que facilita la toma de decisiones, incluso en tiempo real”.

De acuerdo con Chen (2015), la aplicación de *Big data* incluye la utilización de datos recopilados y creados dentro de cada organización, pero también por socios comerciales, clientes y, en general, por cualquier persona a través de cualquier medio.

Se habla de Big data cuando la cantidad de datos supera la capacidad de procesamiento del software estadístico cotidiano; por ejemplo, no puede trabajarse Big data con el uso de una hoja de Excel. Por otro lado está la minería de datos, que consiste en la exploración de datos (con frecuencia bases de datos grandes) que sí puede trabajarse con el software habitual.

Tanto la minería de datos como el *Big data* tratan de identificar patrones ocultos en los datos, de tal manera que se puedan predecir comportamientos futuros y se puedan transformar los datos en conocimientos proactivos; por ejemplo, definiendo características específicas de los consumidores o de los procesos, lo que finalmente redundará en el aumento de productividad y rentabilidad de las empresas.

Este libro no hace énfasis en estos temas, pero se invita a profundizar en ellos porque son temas de mucha actualidad.

EJERCICIOS RESUELTOS

Te invito a que, antes de estudiar los videos donde se desarrolla cada problema, intentes resolver los ejercicios. De esta manera podrás evaluar la comprensión de los temas.

1. En la siguiente base de datos se registra el destino de las exportaciones antioqueñas (Estados Unidos, Europa, Suramérica, otros países) y el sector al que pertenecen dichas exportaciones (agropecuario o no agropecuario)

a) Haz una tabla de frecuencia apropiada para la variable destino. Además, construye dos gráficos apropiados y haz comentarios al respecto.

b) Elabora una tabla que clasifique el sector de las exportaciones de acuerdo al lugar de destino. Haz un gráfico y saca conclusiones.

2. A continuación encuentras información de las utilidades de una empresa multicanal que opera en más de 150 países; dicha empresa comercializa productos de belleza y aseo.

En Colombia esta empresa está dividida en 5 zonas. En la siguiente base de datos se encuentran las utilidades en cada una de esas zonas en los días de marzo de este año.

a) Presenta una tabla que sintetice las utilidades en el mes por zona (tanto en cantidades absolutas como en porcentaje). Establece comparaciones.

b) Haz comparaciones en el contexto de los datos entre las zonas Centro y Sur en cuanto a promedio y coeficiente de variación.

Nota aclaratoria: Es muy importante no sacar conclusiones de variables diferentes a la evaluada. Por error, en el video se menciona algo sobre ventas cuando la variable que se estaba evaluando era la utilidad.

3. El *Endomarketing* se preocupa porque las empresas pongan en conocimiento de sus empleados sus planes y estrategias en cualquier área, sea producción, gestión humana, ventas, etc. Se hizo un sondeo entre empleados de diferentes empresas para estimar, según el tamaño de ellas, qué tan comprometida está su empresa con “el mercadeo hacia el interior”; para tal efecto se le pidió a una muestra de trabajadores de cada empresa de las reseñadas que calificara el compromiso de su em-

presa en esta área en una escala entre 0 (nada comprometida) y 5 (muy comprometida). En la base de datos se muestran los promedios de las calificaciones de cada empresa.

a) Los resultados del estudio se mostraron con una tabla cruzada con los siguientes rangos: (2-3), [3-4) y [4-5]; diseña dicha tabla y saca conclusiones.

b) Calcula la media para cada grupo y compara.

4. Una marca de café tiene tres tiendas en el país, pero su mercado está en un alto porcentaje en el exterior. A continuación se registran las ventas (en miles de dólares) en el país y fuera de él durante los últimos 18 meses.

a) Calcule medidas de resumen para las ventas nacionales y para las ventas internacionales. Compare.

b) Construya diagramas de caja comparativos. Concluya.

EJERCICIOS PROPUESTOS

Inmediatamente después de los planteamientos de los ejercicios se encuentra un archivo de Excel con sus soluciones.

1. En la elaboración de cierto estudio se hizo una encuesta a 165 empresas medianas de Antioquia y se les preguntó si creían estar preparadas para su internacionalización; también se registró el sector al que pertenece la empresa. Los resultados fueron los siguientes:

a) Elabora una tabla de frecuencias apropiada para mostrar qué tantas de las empresas evaluadas están preparadas para el proceso de internacionalización.

b) Elabora una tabla que clasifique si está preparada o no para el proceso de internacionalización de acuerdo con el sector.

¿Qué porcentaje de las empresas industriales evaluadas dicen estar preparadas para el proceso de internacionalización?

¿Qué porcentaje de las empresas comerciales evaluadas dicen estar preparadas para el proceso de internacionalización?

¿Qué puede concluirse?

2. *Tanzania* es una empresa familiar que nació hace 27 años en Envigado; el sabor casero de sus productos los hace diferentes. Tiene su línea propia, pero también opera como maquilador de una marca propia del supermercado más grande del país. *Tanzania* tiene cuatro sucursales ubicadas en Envigado, Bello, Sabaneta y Belén; cada una de esas sucursales registró ventas diarias durante el mes pasado por las cantidades que se registran a continuación:

a) Presenta una tabla que sintetice las ventas en el mes por sucursal (tanto en cantidades absolutas como en porcentaje). Establece comparaciones.

b) Haz comparaciones en el contexto de los datos entre las sucursales de Envigado y Belén en cuanto a promedio y coeficiente de variación.

3. Datos suministrados por el Banco Mundial detallan el Producto Interno Bruto per cápita –en dólares– de los países latinoamericanos en determinado año. A continuación se presentan los valores:

Calcula e interpreta medidas de resumen. Compara el caso colombiano con el resto de la zona.

4. Tú eres el Jefe de mercadeo y ventas de la empresa de confecciones *Zambia*, una empresa que fabrica calcetines. Para definir precios y unos programas de descuentos se registraron datos durante los últimos 15 meses acerca de las unidades producidas y los costos para producirlas (dados en millones de pesos) respecto a un tipo específico de calcetines.

a) Calcula e interpreta media, mediana y coeficiente de variación de las unidades producidas en los últimos 15 meses.

b) Calcula e interpreta media, mediana y coeficiente de variación de los costos mensuales de producción en los últimos 15 meses.

5. Eres el Gerente General de una de las tiendas online más grandes de Latinoamérica, llamada *El Congo*. La tienda tiene 4 áreas: TV, celulares y tabletas; Electrodomésticos; Ropa y calzado, y Hogar.

A continuación se presentan dos bases de datos: la primera contiene un listado de las ventas en cada una de las áreas en un determinado día; la otra contiene el número de celulares vendidos por mes.

a) Haz una tabla de frecuencia apropiada para la variable “Área” y construye un diagrama circular.

b) Halla e interpreta media, coeficiente de variación y mediana del número de celulares vendidos.

c) Haz una tabla de frecuencias apropiada para la variable “número de celulares vendidos”. Construye un histograma.

6. Las siguientes tablas presentan los montos de las exportaciones mensuales de Colombia y un país vecino (en millones de dólares FOB) durante los últimos 24 meses:

Calcula media, mediana y coeficiente de variación de cada grupo y establece comparaciones.

7. Se hizo una encuesta entre 500 mipymes del país para estimar la proporción de ellas que usan *factoring* como modelo de financiación. En esta base de datos se pueden observar las respuestas:

- a) De acuerdo con el estudio, ¿qué proporción de las mipymes evaluadas usa *factoring*?
- b) Si eres gerente de una financiera, ¿qué harías para hacer más popular el modelo?

8. Fomentar la libertad económica conduce a un mayor crecimiento económico. La siguiente base muestra los índices 2016 de Libertad económica de los países del mundo suministrados por *The Heritage Foundation* (2016); dicha calificación se da a los países teniendo en cuenta la carga fiscal, la intervención del gobierno en la economía, las restricciones a las inversiones extranjeras, el peso de las regulaciones, la protección de los derechos de propiedad, el grado de corrupción, etc.

- a) Calcula medias, coeficientes de variación y cuartiles 1 y 3 de cada región, de acuerdo con la clasificación hecha por *The Heritage Foundation*.

Establece comparaciones entre las regiones con base en esas medidas.

- b) Consulta ampliamente sobre el índice de Libertad económica. ¿Por qué para un empresario es importante conocer el índice de Libertad económica de los diferentes países?

9. Se hizo una encuesta a 150 clientes de cierta empresa para saber cómo califican el servicio recibido. La siguiente gráfica sintetiza las calificaciones dadas por los clientes:

Si se consideran como clientes insatisfechos los que calificaron el servicio como Malo o Regular, ¿cuál de las siguientes afirmaciones es verdadera? Justifica tu respuesta.

- a) Más de 70 clientes consideran que el servicio prestado por la empresa es bueno.
- b) Más de 80 clientes están satisfechos con el servicio ofrecido.
- c) Más de 40 clientes dicen que el servicio es excelente.
- d) Menos de 50 clientes están insatisfechos con el servicio.

10. En una empresa se hizo un sondeo entre algunos de sus empleados para evaluar su sentido de pertenencia. La escala fluctuaba entre 0 y 5, donde 5 implica un sentido de pertenencia absoluto. Los resultados se resumen así:

Media: 3,45	Mediana: 3,23	Moda: 3	Desviación estándar: 0,7
-------------	---------------	---------	--------------------------

Puede afirmarse lo siguiente:

- a) Todos los empleados de la empresa tienen un alto sentido de pertenencia.
- b) La muestra no es muy homogénea porque el coeficiente de variación es superior al 15%
- c) La muestra es muy homogénea porque el coeficiente de variación es inferior al 5%.

d) Muchos de los empleados calificaron su sentido de pertenencia con 0 o 1.

Justifica tu respuesta.

11. En la siguiente base de datos se encuentran los índices de competitividad 2016-2017 de los países del mundo, de acuerdo a la clasificación del *World Economic Forum* (2016):

a) Construye un diagrama de caja comparativo entre regiones (*areas*).

b) Consulta acerca del índice de competitividad y los subíndices y pilares que se utilizan para determinarlo. ¿Por qué para un empresario es importante conocer el índice de Competitividad en los diferentes países?

12. En la elaboración de cierto estudio se hizo un sondeo con 239 empresas colombianas de diferentes tamaños y se registró si en el año anterior presentaron utilidades o pérdidas. Los resultados fueron los siguientes:

a) Elabora una tabla de frecuencias que clasifique las empresas evaluadas según su tamaño. Haz comentarios al respecto.

b) Elabora una tabla de frecuencias que clasifique las empresas evaluadas según si tiene o no utilidades. ¿Por qué en la tabla a) es importante hallar frecuencias acumuladas y en esta no?

c) Elabora una tabla de contingencia de frecuencias absolutas que clasifique si las empresas evaluadas tuvieron o no utilidades, de acuerdo con su tamaño.

d) Elabora una tabla para determinar qué porcentaje de las empresas evaluadas de cada tamaño registraron utilidades en el año anterior. Haz comparaciones.

13. Se registraron las utilidades (en millones de pesos), según tamaño de las empresas, de un grupo de empresas que no tuvo pérdidas el año anterior de acuerdo con su tamaño, así:

a) Halla media, mediana, coeficiente de variación y cuartil 3 para las utilidades según cada tamaño de empresa.

b) Haz comparaciones según cada medida.

14. Se hizo una indagación a 500 Pymes antioqueñas sobre el sector donde está ubicada su planta de producción (Rural o Urbano) y si utiliza o no fuentes de energía renovable.

a) Elabora una tabla de frecuencias apropiada para mostrar qué tantas de las empresas evaluadas utilizan fuentes de energía renovable. Concluye.

b) Elabora una tabla de contingencia que clasifique si utiliza o no fuentes de energía renovable de acuerdo con el sector donde está ubicada su planta de producción. ¿Qué porcentaje de las empresas que tienen su planta en zona urbana utilizan fuentes de energía renovable? ¿Qué porcentaje de las empresas que tienen su planta en zona rural utilizan fuentes de energía renovable? ¿Qué puede concluirse?

15. En la siguiente tabla se detallan las ventas diarias promedio en unidades durante el mes anterior para diversos vendedores. Si se desea establecer un plan de incentivo para el 20% de los mejores vendedores, ¿a partir de qué cantidad de unidades vendidas debería establecerse la meta mínima a cumplir?

16. Cierta compañía tiene 50 representantes de ventas que venden un producto suyo en todo el territorio nacional; dichos representantes tienen como ciudad sede a Medellín, Bogotá o Cali, ciudades donde se encuentran las fábricas. A continuación se muestra el número de productos vendidos por cada representante durante el mes anterior, al igual que su ciudad sede y sus años de experiencia.

a) Construye la tabla de frecuencias de la variable “Ciudad sede”. Grafica dicha información.

b) Construye la tabla de frecuencias de la variable “Cantidad de productos vendidos” sin diferenciar la ciudad sede. Grafica dicha información.

c) Calcula estadísticos de resumen de la cantidad total de productos vendidos por los representantes de cada ciudad y establece comparaciones.

d) Elabora una tabla cruzada que muestre la cantidad de productos vendidos por los vendedores de cada ciudad y otra donde se muestren los promedios. Compara.

17. La siguiente base de datos corresponde a las ventas de la empresa Kinshasa; dicha empresa hace y comercializa ropa para niños y bebés y tiene cinco sucursales en el país: Centro Norte, Sur, Norte, Occidente y Oriente. Los datos corresponden a ventas durante el mes de junio de 2017.

Después de segmentar los datos en cuartiles, haz una tabla que muestre cuántos valores de ventas pertenecen a cada cuartil o grupo, de acuerdo con las sucursales. Presenta comparaciones.

18. La siguiente base de datos corresponde a las ventas de la empresa *Porto Novo*; dicha empresa hace y comercializa ropa para niños y bebés. Los datos corresponden a ventas durante el mes de junio de 2017

Elabora tablas para la siguiente información:

a) Montos de las ventas diarias.

b) Ventas en el mes por zona.

c) Cantidad de ventas por categoría.

d) Montos de ventas por categoría.

e) Tabla cruzada de montos de ventas por categoría y subcategoría.

Después de cada una debe aparecer un diagrama, según se estime conveniente; también debes mencionar después de cada una qué harías ante las evidencias si eres directivo de *Porto Novo*.

RESPUESTAS A EJERCICIOS PROPUESTOS

Notas complementarias: Sesgo

En el contenido principal del texto se habla únicamente de medidas de localización y medidas de dispersión, pero las diferentes medidas de resumen son calculadas bajo el supuesto de **Estimador Centrado o Insesgado**. Es por ello que es importante mencionar también la asimetría o sesgo, ya que para poder obtener conclusiones absolutamente valederas y poder tener credibilidad en nuestros indicadores de resumen es muy importante la presencia de simetría en los datos porque eso garantiza la ausencia de patrones de comportamiento que pudiésemos pasar desapercibidos.

Por ejemplo, unos datos pueden tener un promedio determinado y un coeficiente de variación aceptable, pero al presentar ausencia de simetría se pueden obtener interpretaciones incorrectas. Para curvas altamente sesgadas es mejor confiar en la mediana (más que en el promedio) o establecer la decisión de segmentar en dos o más grupos de estudios.

Con el Análisis de datos de Excel también se encuentra el coeficiente de asimetría, que es la principal medida de sesgo. Si la distribución de frecuencia no tiene sesgo el coeficiente de asimetría es cero (o muy cercano); en este caso el eje de simetría determinado por la media aritmética se encuentra en el centro, dividiendo a las observaciones en dos partes iguales y coincidiendo con la mediana y la moda.

Si una o más observaciones son extremadamente grandes, la media aritmética de la distribución será más grande que la mediana y la moda, ya que es influenciada por estos valores extremos. Para este caso se dice que la distribución es positivamente sesgada, lo que indica que la mayoría de los datos se encuentran acumulados hacia la zona inferior a la media aritmética. Para este caso, el Coeficiente de Asimetría determinado por Excel es mayor que cero.

Pero si se tienen una o más observaciones extremadamente pequeñas, la media aritmética es la más pequeña de las tres observaciones de tendencia central y eso indica que los datos se encuentran principalmente acumulados hacia la zona superior de la media aritmética; en ese caso la curva se denomina negativamente sesgada y el Coeficiente de Asimetría determinado por Excel es menor que cero.

2. PROBABILIDADES

El concepto de probabilidad ocupa un lugar importante en el proceso de toma de decisiones siempre que existe incertidumbre, independientemente del campo en que se maneje.

El objetivo de la teoría de probabilidades es poder tener un elemento de juicio más racional en la toma de decisiones, ya que si se pronostica qué tan probable es que algo ocurra se puede determinar si se toma el riesgo o no; además, se podrían utilizar algunas ventajas estratégicas al conocer qué puede ser más probable, aunque jamás podrá aseverarse algo con absoluta certeza acerca de un fenómeno que implique algún grado de incertidumbre.

Las decisiones en los negocios a menudo se deben tomar en un escenario de incertidumbre, es por ello que con frecuencia aparecen preguntas tales como ¿cuál es la probabilidad de que las ventas se reduzcan si se incrementan los precios?, ¿cuál es la probabilidad de terminar en la fecha estimada un proyecto en marcha?

La probabilidad es una medida numérica de la posibilidad de que un evento ocurra; por ello en este capítulo vamos a estudiar los conceptos, métodos y técnicas necesarios para apoyar la toma de decisiones en el ámbito administrativo cuando se tiene incertidumbre, con base en el concepto de probabilidad.

Todo eso deriva en la importancia de modelar los procesos que implican el uso de probabilidades; por eso se estudiarán también las principales distribuciones de probabilidad que, aunque sean modelos teóricos, son aplicables cuando se van a modelar procesos que involucren incertidumbre. Con frecuencia se debe recurrir a la formulación de modelos estadísticos que expliquen el comportamiento de ciertas variables de interés; si dicho comportamiento es aleatorio o incierto, entonces se hace necesario utilizar distribuciones de probabilidad que ofrezcan, con cierto grado de certeza, guías de comportamiento. En este capítulo se estudiará la formulación de distribuciones de probabilidad empíricas, las cuales pueden ser muy útiles para contrastar modelos especiales conocidos, que funcionarán como patrones que explican apropiadamente el comportamiento de las variables de estudio, para finalmente brindar herramientas para la toma de decisiones.

Siempre que haya incertidumbre va a existir riesgo, pero la teoría de probabilidades ayuda a mitigarlo.

El principal objetivo es, entonces, modelar situaciones administrativas mediante las distribuciones especiales de probabilidades para, de esta manera, reconducir a una distribución de probabilidades todas las ecuaciones cuyas relaciones representan la acción de los factores ignorados pero que efectivamente actúan y lograr así medir y gestionar el riesgo.

Los fenómenos pueden ser clasificados como determinísticos o aleatorios.

Es determinístico si origina un resultado seguro, es decir, si no hay incertidumbre acerca de su resultado cuando se repita; eso significa que, sin que sea necesario realizar un experimento, de antemano se sabe cuál será el resultado con ayuda de una ecuación matemática.

Es aleatorio si no puede predecirse exactamente su resultado aunque se repitan en forma similar; eso significa que implican algún grado de incertidumbre.

En estadística se manejan datos aleatorios; en ellos no es posible hacer predicciones exactas mediante el uso de modelos matemáticos, pero cuando son estudiados muchas veces bajo condiciones similares se encuentra que los resultados presentan cierta regularidad. Por lo tanto, nunca puede estarse seguro de lo que vaya a pasar, pero con base en la información del pasado puede predecirse con fundamentos.

Es acá donde entra en juego el concepto de probabilidad, ya que son muy pocas las situaciones donde haya que tomar una decisión sin encarar la incertidumbre. Es por eso que este concepto es tan importante en cualquier campo, por ejemplo en los negocios, la ingeniería, las ciencias sociales y hasta en la vida diaria.

El objetivo de la teoría de probabilidades es poder hacer predicciones y tener más elementos de juicio para tomar decisiones más fundamentadas (si se pronostica qué tan probable es que ocurra algo se puede determinar si se toma el riesgo o no).

Con la teoría de probabilidades se pueden construir modelos que describen adecuadamente la regularidad de los resultados aleatorios, de tal forma que se puedan hacer predicciones.

El concepto de probabilidad se aplica mucho en casos muy generales, pero igualmente puede aplicarse para definir estrategias administrativas, teniendo implícito siempre un nivel de riesgo.

2.1 CONCEPTOS BÁSICOS

2.1.1 ¿Qué es?: la probabilidad es una herramienta para medir la posibilidad de ocurrencia de un evento. Dicho de otra forma, es la medición de la incertidumbre acerca de la ocurrencia de determinada situación. Puede tomar un valor entre 0 y 1 (o entre 0 y 100%). Una probabilidad de 0 indica que algo es imposible y una probabilidad de 1 indica que algo es seguro (ninguna de las dos cosas se presenta si hay algún grado de incertidumbre)

Si un experimento puede tener como resultado cualquiera de N resultados diferentes, igualmente probables, y si exactamente n de esos resultados corresponden al evento A , entonces:

La probabilidad de que no ocurra es q , que es igual a $1 - p$, es decir, si p es 60%, q es 40%.

Una probabilidad también puede expresarse como p/q ($p:q$ o de p a q). Aparte de su valor en apuestas, esta manera de expresarla permite especificar una probabilidad muy pequeña (cerca de cero, como por ejemplo una probabilidad de 1 en 1000000) o una probabilidad grande (cerca de uno, como por ejemplo una probabilidad de 99999 en 100000); de esta manera se hacen las diferencias relativas más visibles.

Dicho de otra manera, el *enfoque clásico* calcula la probabilidad de un evento dividiendo el número de resultados favorables entre el número de posibles resultados.

El enfoque anterior supone que todos los resultados experimentales tienen la misma probabilidad de ocurrir (equiprobabilidad); eso es razonable si el caso es completamente aleatorio, como por ejemplo los juegos de azar, pero tiene muchos problemas cuando intentamos aplicarlo a los problemas de decisión menos ordenados que encontramos en la realidad. Por eso, en general, lo más apropiado es calcular la probabilidad experimentalmente, determinando la frecuencia con que algo ha sucedido en el pasado y mediante esa cifra predecir la probabilidad de que vuelva a ocurrir en el futuro; debido a ello, la probabilidad de un resultado puede interpretarse como el valor límite de la proporción de veces que el resultado aparece en n repeticiones del experimento aleatorio, a medida que n crece sin cota alguna.

Si n tiende a infinito, se da una estabilización de la frecuencia relativa (tiende a un límite fijo). Por ejemplo, al lanzar un dado, es casi imposible que un valor determinado resulte en $1/6$ de las observaciones; tampoco significa que si hacemos 600 observaciones, vamos a obtener exactamente 100 de cada especie; pero si se repite muchas veces, en promedio, los seis resultados posibles se presentarán con frecuencias prácticamente iguales. Si esto no sucede, debemos sospechar que otro factor está interviniendo en lo que observamos.

El enfoque clásico se aplica cuando no hay que hacer un experimento para determinar probabilidades; muy diferente es el enfoque frecuentista, que calcula la probabilidad de un evento mediante frecuencias relativas anteriores, lo cual implica hacer un experimento para determinarlas (por ejemplo mediante una encuesta o por resultados históricos). Puede citarse el caso de la moneda: si se hace un experimento que consista en lanzar 300 veces la moneda y mirar qué cae, estaría aplicando el enfoque frecuentista; pero si simplemente se asume que las probabilidades son 50% para cara y 50% para sello, estaría aplicando el enfoque clásico; en casos totalmente aleatorios como el de la moneda estaría bien asumir esto último, pero en casos gerenciales esto pocas veces tiene sentido.

La probabilidad puede también tener un enfoque subjetivo, es decir, basarse en lo que supone el que la determina, por lo que personas distintas pueden asignar distintas probabilidades a un mismo proceso. Para aplicar este método se puede usar cualquier dato disponible o la experiencia e intuición de la persona que evalúa; ello implicaría que se conozca muy bien el proceso evaluado.

El cálculo de probabilidades proporciona las reglas básicas para el estudio de experimentos aleatorios y esta es la base de Estadística inferencial.

2.1.2 Experimento: es cualquier acción cuyo resultado se registra como un dato. En estadística, la noción de experimento es distinta de la noción en ciencias físicas; en ellas, por lo general, un experimento se lleva a cabo en un laboratorio o en un ambiente controlado, para aprender acerca de un hecho científico, y cuando se repiten los experimentos bajo condiciones idénticas se espera obtener el mismo resultado. En los experimentos estadísticos, los resultados están determinados por el azar y aunque el experimento se repita exactamente en la misma forma, puede obtenerse un resultado diferente.

2.1.3 Espacio muestral (S): es el conjunto de todos los resultados posibles de un experimento estadístico. Solamente podría hablarse de imposibilidad de algo cuando el resultado buscado no está en el espacio muestral del experimento; por ejemplo si se quiere hallar la probabilidad de ser calificado con 12 en un proceso de evaluación al servicio de una empresa que es valorado entre 1 y 10. Igualmente, únicamente podría catalogarse como seguro si el resultado buscado incluye todo el espacio muestral; por ejemplo si se quiere hallar la probabilidad de elegir una bola negra que es extraída de un paquete que tiene solamente bolas negras.

2.1.4 Punto muestral: es cada resultado de un espacio muestral. Se pueden especificar por un diagrama de árbol, que es un dispositivo gráfico útil para visualizar un experimento de varias etapas y enumerar los resultados experimentales o mediante otras formas que se explicarán más adelante.

2.1.5 Evento o suceso (E): es cualquier subconjunto del espacio muestral (colección de puntos muestrales). Un evento es el elemento básico al cual se puede aplicar la probabilidad; un evento sucede o no sucede.

Con los eventos se pueden efectuar las operaciones comunes de conjuntos (intersección, unión y complemento) para describir cualquier caso en términos de eventos simples.

2.1.6 Evento aleatorio: se dice que un evento es aleatorio cuando no se tiene certeza de si ocurrirá o no en el momento de la observación. Un evento aleatorio puede ser:

- 100% aleatorio: todos los resultados posibles tienen la misma probabilidad de ocurrir. En este caso es aplicable el enfoque clásico y, por lo tanto, lo primero que debe hacerse si van a aplicarse probabilidades es calcular el tamaño del espacio muestral.

- Parcialmente aleatorio: no todos los resultados posibles tienen la misma probabilidad de ocurrir. En este caso son aplicables los enfoques frecuentista y subjetivo; si se van aplicar probabilidades deben tomarse como base características deseables.

Siempre deben satisfacerse dos requisitos básicos (axiomas de probabilidad):

(1) $0 \leq P(E) \leq 1$, es decir, la probabilidad de un evento siempre tomará un valor entre 0 y 1.

(2) $P(S) = 1$, lo que implica que la suma de todas las probabilidades de resultados experimentales debe ser 1. Por lo tanto, si un espacio muestral tiene k resultados experimentales:

Para el desarrollo de los diferentes temas de Probabilidades se estudiará el proceso de internacionalización de las empresas de Antioquia.

2.2 MANERAS DE DESCRIBIR UN ESPACIO MUESTRAL

2.2.1 TABLA DE CONTINGENCIA

Si en el experimento están incluidas dos o más variables el espacio muestral puede detallarse mediante una tabla de contingencia y dicho espacio está dado por las celdas de la tabla. Puede presentarse mediante porcentajes o con cantidades absolutas; para poder emplearla, todas las clases deben ser mutuamente excluyentes.

EJEMPLO 1

Se llevó a cabo una investigación sobre el proceso de internacionalización de las Pymes de Antioquia; en dicha investigación se evaluó si la formación académica de los dueños está relacionada con el inicio de dicho proceso. Se obtuvo la siguiente información sobre una muestra de 500 Pymes:

		Formación académica de los dueños		Total
		Sólida	Escasa	
Proceso de internacionalización	Iniciado	44	11	55
	No iniciado	138	307	445
	Total	182	318	500

(información detallada por cantidades)

		Formación académica de los dueños		Total
		Sólida	Escasa	
Proceso de internacionalización	Iniciado	8,8%	2,2%	11,0%
	No iniciado	27,6%	61,4%	89,0%
	Total	36,4%	63,6%	100,0%

(información detallada por porcentajes)

Nota: En la última tabla se sacaron todos los porcentajes con base en las 500 empresas. Por ejemplo, las empresas cuyos dueños tienen una sólida formación académica y que ya iniciaron el proceso de internacionalización fueron $44/500 \times 100$.


<https://www.youtube.com/watch?v=KCqaVM5OEI0>

Archivo con los datos para practicar:

[Tabla de contingencia Probabilidades](#)

2.2.2 DIAGRAMA DE ÁRBOL

Es una representación gráfica que permite visualizar un experimento de pasos múltiples o un experimento que incluya dos o más variables.



2.2.3 COMBINACIONES Y PERMUTACIONES:

- **Combinaciones:** procedimiento para contar el número de resultados experimentales cuando se seleccionan r elementos de un conjunto de tamaño n y no importa el orden. Eso se simboliza nCr y puede calcularse como:

$${}_nC_r = \frac{n!}{r!(n-r)!}$$

En Excel dicho cálculo puede hacerse con la función **COMBINAT**; los argumentos de esta función son Número (n) y Tamaño (r).

Cuando se hace un muestreo de una población finita de tamaño N , el número de posibles muestras diferentes de tamaño n que podrían seleccionarse se calcula mediante combinaciones.

EJEMPLO 2

En Colombia hay un juego de azar denominado Baloto. Hasta abril de 2017 el jugador debía selec-

cionar seis números de un conjunto de 45 y, para ganar, ellos deben coincidir con los elegidos. A partir de ese momento la persona que apuesta debe elegir cinco números de un conjunto de 43 y una “superbalota” con números del 1 al 16.

a) ¿Qué tan probable era ganar el premio mayor del Baloto si se compraba un boleto antes de abril de 2017?

b) ¿Qué tan probable es ganarlo ahora?

Solución:

a)

Función	COMBINAT
Número	45
Tamaño	6
Combinaciones posibles (respuesta)	8.145.060

Nota aclaratoria: se hacen combinaciones porque el orden de los números no importa.

$$\Rightarrow P(\text{ganar}) = \frac{1}{8145060} = 0,000000123$$

b)

Función	COMBINAT
Número	43
Tamaño	5
Combinaciones posibles (respuesta)	962.598

Este valor debe multiplicarse por 16 (números de la “superbalota”), por lo que el número de resultados posibles es 15.401.568.

$$P(\text{ganar}) = \frac{1}{15401568} = 0,0000000649285$$

Lo anterior demuestra que la probabilidad se reduce casi a la mitad.

- **Permutaciones:** procedimiento para contar el número de resultados experimentales cuando se seleccionan r elementos de un conjunto de tamaño n y el orden de selección es importante. Esto se representa como nPr y puede calcularse como:

$${}_nP_r = \frac{n!}{(n-r)!}$$

Dicho cálculo también puede desarrollarse directamente en una calculadora (con la función nPr) o en un programa estadístico. En Excel dicho cálculo puede hacerse con la función **PERMUTACIONES**; los argumentos de esta función son Número (n) y Tamaño (r).

EJEMPLO 3

¿Qué tan probable sería ganar el premio mayor del Baloto si se compra un boleto y los números se marcan de tal manera que tienen que coincidir con el orden en que salen en el sorteo?

Solución:

Función	PERMUTACIONES
Número	43
Tamaño	5
Formas posibles (respuesta)	115.511.760

Al multiplicar por 16 se obtienen 1.848.188.160

$$P(\text{ganar}) = \frac{1}{1848188160} = 0,00000000054107$$

Con las condiciones reales se hace casi imposible ganar, pero con estas condiciones esa probabilidad sería muchísimo menor.

2.3 PROBABILIDAD MARGINAL, CONDICIONAL Y CONJUNTA:

Estos conceptos son aplicables cuando se evalúan por lo menos dos variables simultáneamente.

- Probabilidad marginal es la probabilidad de un evento simple $[P(A), P(B)]$; es decir, es la probabilidad de que se presente un evento correspondiente a una variable, sin considerar la otra u otras variables.
- Probabilidad conjunta es la probabilidad de que varios eventos ocurran simultáneamente. Se expresa como $P(A \cap B)$ o $P(AB)$.
- La probabilidad condicional se representa como $P(B \setminus A)$, lo cual indica la probabilidad de que un evento B ocurra si ya se sabe que ocurrió el evento A. De la misma forma $P(A \setminus B)$ indica la probabilidad de que ocurra A dado que ocurrió B.

Las anteriores definiciones han sido expresadas para el caso de dos eventos, pero las mismas ideas pueden aplicarse para cualquier número de eventos.

La noción de probabilidad condicional proporciona la capacidad de reevaluar la idea de probabilidad de un evento a la luz de la información adicional.

Las probabilidades pueden calcularse fácilmente mediante reglas de tres simples si se presentan como una tabla de contingencia; para mayor facilidad puede asumirse un gran total de 100% y organizar la información en forma tabular, bien sea a partir de todos los datos (mediante una tabla dinámica) o a partir de una síntesis de ellos.

EJEMPLO 4

El 49% de las exportaciones antioqueñas tienen como destino Estados Unidos, 20% va a países de Suramérica, 16% a Europa y el resto a otros países. El 45% de lo que se exporta a Estados Unidos hace parte del sector agropecuario, al igual que 38% de lo que se exporta a países suramericanos, 60% de lo que se exporta a Europa y 50% de lo que se exporta a otros países.

a) ¿Qué proporción de las exportaciones antioqueñas es de productos agropecuarios?

b) Si una exportación es de productos que no son agropecuarios, ¿cuál es la probabilidad de que sea a Europa?

Solución:

		DESTINO				
		USA	Suramérica	Europa	Otros países	TOTAL
SECTOR	Agropecuario	22,05	7,6	9,6	7,5	46,75
	No agropecuario	26,95	12,4	6,4	7,5	53,25
TOTAL		49	20	16	15	100

a) 46,75%

b) $6,4/53,25 = 12\%$

2.4 DISTRIBUCIONES DE PROBABILIDADES

Con frecuencia, las observaciones que se generan en experimentos estadísticos tienen algunos tipos generales de comportamiento y por eso se pueden describir esencialmente con unas pocas distribuciones, que se representan mediante una ecuación.

Jaramillo (2003) menciona: “Frente a la complejidad de los fenómenos bajo estudio, el experimentador aproxima y hace algunos postulados tentativos acerca del mecanismo aleatorio y deriva un modelo por el empleo de esos postulados en combinación con las leyes de probabilidad”. Sin embargo,

no es propósito de este libro hacer una demostración matemática de las ecuaciones características de cada modelo.

Un modelo de probabilidad para la variable aleatoria X es una forma específica de distribución de probabilidades que es asumida para reflejar el comportamiento de dicha variable.

"EL MODELO DEBE SER COHERENTE CON LA REALIDAD"


A continuación se examinarán detalladamente algunas distribuciones específicas de probabilidad que han demostrado, empíricamente, ser modelos útiles para diversos problemas prácticos. Pero dichas distribuciones son teóricas porque sus funciones de probabilidad se deducen matemáticamente con base en ciertas hipótesis que se suponen válidas para esos fenómenos aleatorios. Dichas distribuciones son idealizaciones del mundo real, por lo tanto sus resultados no siempre coinciden con la realidad.

Los diferentes modelos dependen del tipo de variable que se evalúe. Recordemos que una variable aleatoria es discreta si puede asumir únicamente valores enteros y es continua cuando puede tomar cualquier valor dentro de un intervalo de números reales; las variables aleatorias cualitativas deben asumirse como discretas para su estudio como distribución de probabilidad, puesto que a cada posible valor podría asignársele un número entero.

Si la variable aleatoria es discreta, pero el rango es muy amplio, resulta más conveniente utilizar un modelo basado en variables aleatorias continuas.

La distribución de probabilidad se describe mediante una función de probabilidad, representada por $f(x)$. Se denomina función de probabilidad en el caso de variables discretas; si la variable es continua, se denomina función de densidad.

Existen muchos modelos de probabilidad. En el siguiente diagrama se sintetizan los más usados en temas administrativos, según el tipo de variable evaluada:



Antes de revisar las diferentes distribuciones de probabilidad se presenta este video, donde se revisan algunas propiedades que permiten manejar igualdades y desigualdades en situaciones que impliquen el uso de modelos de probabilidades.

<https://www.youtube.com/watch?v=SWvrOBxu6f0>

2.4.1 DISTRIBUCIÓN BINOMIAL:

Se maneja cuando se satisfacen las siguientes características:

- a) La variable que se estudia es discreta o es cualitativa.
- b) El experimento consiste en una sucesión de n ensayos o intentos idénticos.
- c) El resultado de cada ensayo se clasifica dentro de dos categorías mutuamente excluyentes: éxito o fracaso. El uso de esos términos es por conveniencia, pero no tienen la misma connotación de la vida real (éxito no necesariamente es lo que convenga).
- d) La probabilidad de éxito permanece constante en todos los ensayos.
- e) Los ensayos son independientes, lo que significa que la ocurrencia de uno de ellos no afecta el resultado de cualquier otro.

La función de probabilidad binomial puede escribirse como:

$$f(x) = p^x q^{n-x} {}_n C_x$$

donde x es el número de éxitos, n el número de ensayos, p es la probabilidad de éxito, q es la probabilidad de fracaso y el último término está dado por las combinaciones de x en n .

Esas probabilidades también pueden calcularse mediante un programa estadístico. Los diferentes modelos de probabilidades se encuentran en Excel en las funciones de la categoría Estadística (icono $f(x)$).

Para el caso del modelo Binomial debe emplearse la función **DISTR.BINOM.N**. Allí deben agregarse los siguientes argumentos:

Núm_éxito: es el número de éxitos en los ensayos.

Ensayos: es el número de ensayos independientes.

Prob_éxito: es la probabilidad de éxito en cada ensayo.

Acumulado: es un valor lógico; para calcular la función de distribución acumulativa debe digitarse en el cuadro la palabra VERDADERO (o 1); para hallar la función de probabilidad no acumulativa debe escribirse FALSO (o 0).

El número esperado (μ) es el valor (o valores) que tiene(n) mayor probabilidad. Lo anterior significa que para calcular el valor esperado puede multiplicarse el número de éxitos por la probabilidad de éxitos.

EJEMPLO 5

Registros de la Cámara de Comercio de Medellín informan que la probabilidad de que una microempresa antioqueña haya iniciado el proceso de internacionalización es 0,11 y se evalúa una muestra de 25 microempresas,

- ¿cuál es la probabilidad de que 5 hayan iniciado el proceso?
- ¿cuál es la probabilidad de que máximo 5 hayan iniciado el proceso?
- ¿cuál es la probabilidad de que por lo menos 7 hayan iniciado el proceso?

- d) ¿cuál es la probabilidad de que entre 12 y 20 hayan iniciado el proceso?
- e) ¿cuál es la probabilidad de que entre 12 y 20 no hayan iniciado el proceso?
- f) ¿cuál es la probabilidad de que más de 8 hayan iniciado el proceso?
- g) ¿cuál es la probabilidad de que menos de 15 no hayan iniciado el proceso?
- h) ¿cuál es el número esperado de empresas que han iniciado el proceso?

Solución:

a) $P(x=5)$

Función	DISTR.BINOM.N
Núm_éxito	5
Ensayos	25
Prob_éxito	0,11
Acumulado	0
$P(x = 5)$	0,0832 (8,3%)

b) $P(x \leq 5)$

Función	DISTR.BINOM.N
Núm_éxito	5
Ensayos	25
Prob_éxito	0,11
Acumulado	1
$P(x \leq 5)$	0,9501 (95,0%)

c) $P(x \geq 7) = 1 - P(x \leq 6)$

Función	DISTR.BINOM.N
Núm_éxito	6
Ensayos	25
Prob_éxito	0,11
Acumulado	1
$P(x \leq 6)$	0,9844
$P(x \geq 7)$	0,0156 (1,6%)

d) $P(12 \leq x \leq 20) = P(x \leq 20) - P(x \leq 11)$ con probab.de éxito= 0,11

Función	DISTR.BINOM.N
Núm_éxito	20
Ensayos	25
Prob_éxito	0,11
Acumulado	1
$P(x \leq 20)$	1

Función	DISTR.BINOM.N
Núm_éxito	11
Ensayos	25
Prob_éxito	0,11
Acumulado	1
$P(x \leq 11)$	0,999996

$$P(12 \leq x \leq 20) = 1 - 0,999996 = 0,000004 \text{ (0,00004\%)}$$

e) $P(12 \leq x \leq 20) = P(x \leq 20) - P(x \leq 11)$ con probab.de éxito= 0,89

Función	DISTR.BINOM.N
Núm_éxito	20
Ensayos	25
Prob_éxito	0,89
Acumulado	1
$P(x \leq 20)$	0,1331

Función	DISTR.BINOM.N
Núm_éxito	11
Ensayos	25
Prob_éxito	0,89
Acumulado	1
$P(x \leq 11)$	0,00000005

$$P(12 \leq x \leq 20) = 0,1331 - 0,00000005 = 0,1331 \text{ (13,3\%)}$$

f) $P(x > 8) = 1 - P(x \leq 8)$


Función	DISTR.BINOM.N
Núm_éxito	8
Ensayos	25
Prob_éxito	0,11
Acumulado	1
$P(x \leq 8)$	0,9991
$P(x > 8)$	0,0009 (0,09%)

g) $P(x < 15) = P(x \leq 14)$

Función	DISTR.BINOM.N
Núm_éxito	14
Ensayos	25
Prob_éxito	0,89
Acumulado	1
$P(x \leq 14)$	0,00003
$P(x < 15)$	0,00003

h) $\mu = 25 * 11\% = 2,75$ (aproximadamente 3)

Eso puede comprobarse al hacer un gráfico de las probabilidades para la situación descrita:



Allí se observa claramente que lo más probable es que dos empresas exporten. El gráfico se presenta solamente hasta 15 porque la probabilidad de que más de 15 empresas exporten es casi 0.

El ejercicio también puede solucionarse si se hacen cálculos de probabilidades para los resultados posibles y posteriormente se hacen las sumatorias necesarias. En el siguiente video se explica la forma:

<https://www.youtube.com/watch?v=Ldh-qM8pbr4>

2.4.2 DISTRIBUCIÓN HIPERGEOMÉTRICA:

Si el tamaño de la población es conocido, de ella se toma una muestra de tamaño conocido y se hace un muestreo sin reemplazo se violan las condiciones de un experimento binomial, ya que la probabilidad de éxito no es constante; por ello, es necesario plantear un tipo diferente de distribución.

Cuando se selecciona sin reemplazo una muestra aleatoria de tamaño n de una población de tamaño N y el interés recae en la probabilidad de seleccionar x éxitos de los k artículos considerados como éxitos en la población, se realiza un experimento hipergeométrico y su función de probabilidad viene determinada por:

$$f(x) = \frac{{}^k C_x \times {}^{N-k} C_{n-x}}{{}^N C_n}$$

El uso de la distribución hipergeométrica requiere el conocimiento de k y N .

En Excel debe emplearse la función **DISTR.HIPERGEOM.N**. Esta devuelve la probabilidad para una variable aleatoria que sigue una distribución hipergeométrica; deben agregarse los siguientes argumentos:

Muestra_éxito: número de éxitos en la muestra.

Núm_de_muestra: tamaño de la muestra.

Población_éxito: número de éxitos en la población.

Núm_de_población: tamaño de la población.

EJEMPLO 6

Una de las compañías evaluadas en los ejemplos anteriores utiliza un proceso de verificación de la calidad de sus productos antes de que se embarquen para exportación. Se preparan cajas de 25 artículos para su embarque y se prueba una muestra de tres en busca de defectuosos; si se encuentra alguno defectuoso toda la caja se regresa para verificar al 100%; de lo contrario se embarca.

- a) ¿Cuál es la probabilidad de que una caja que contiene tres artículos defectuosos se embarque?
- b) ¿Cuál es la probabilidad de que una caja que contiene solo un artículo defectuoso se regrese para su revisión?
- c) ¿Cuáles son las respuestas a las preguntas anteriores si se toma una muestra de cinco artículos?

Solución:

Las anteriores preguntas podrían resolverse en Excel, así:

a)

Función	DISTR.HIPERGEOM.N
Muestra_éxito	0
Núm_de_muestra	3
Población_éxito	3
Núm_de_población	25
Acumulado	0
$P(x = 0)$	0,6696 (67%)

b)

Función	DISTR.HIPERGEOM.N
Muestra_éxito	1
Núm_de_muestra	3
Población_éxito	1
Núm_de_población	25
Acumulado	0
$P(x = 0)$	0,12 (12%)

c)

Función	DISTR.HIPERGEOM.N
Muestra_éxito	0
Núm_de_muestra	5
Población_éxito	3
Núm_de_población	25
Acumulado	0
$P(x = 0)$	0,4956 (49,6%)

Función	DISTR.HIPERGEOM.N
Muestra_éxito	1
Núm_de_muestra	5
Población_éxito	1
Núm_de_población	25
Acumulado	0
$P(x = 1)$	0,2 (20%)

2.4.3 DISTRIBUCIÓN DE POISSON:

Este es el modelo de probabilidad más adecuado para eventos que ocurren aleatoriamente a través del tiempo o el espacio. La función de probabilidad de Poisson ($f(x)$) calcula la probabilidad de exactamente x ocurrencias independientes durante un período de tiempo dado, si los eventos ocurren independientemente y a una tasa constante. La función de la probabilidad de Poisson también representa el número de ocurrencias sobre áreas o volúmenes constantes.

De acuerdo con Walpole, Myers y Myers (1999), esta distribución supone:

a) Ritmo de llegada constante; eso significa que si se dice que llegan en promedio 10 clientes por hora se debe suponer que llega uno cada 6 minutos.

b) La posibilidad de dos ocurrencias simultáneas puede ser asumida como cero.

c) El número promedio de ocurrencias por unidad de tiempo o espacio se considera una constante. Si durante un mismo período existen momentos de muchas ocurrencias y otros de muy pocas, lo más apropiado es asumirlos como procesos separados; por ejemplo, si muchos usuarios utilizan el metro para transportarse de 7 a 8 a.m., pero muy pocos de 10 a 11 a.m. debe calcularse un promedio

por separado para cada uno de esos horarios y trabajarlos como procesos diferentes.

d) La probabilidad de que suceda determinado número de eventos en un proceso de Poisson depende únicamente de la longitud del intervalo observado y no de su ubicación (p. 136).

La distribución de probabilidad de la variable aleatoria de Poisson X , que representa el número de resultados que ocurren en un intervalo de tiempo, área, espacio o volumen específico se calcula así:

$$f(x) = \frac{e^{-\mu} (\mu)^x}{x!}$$

donde μ es el número promedio de resultados en el intervalo evaluado.

En Excel esta distribución se evalúa mediante la función **POISSON.DIST**.

En ese caso deben agregarse los siguientes argumentos:

x : es el número de sucesos.

Media: es el valor numérico esperado (media de la distribución en el período requerido).

Acumulado: igual a Binomial.



EJEMPLO 7

Muy cerca de la planta productora de una de las empresas evaluadas hay un pequeño minimercado que ofrece los productos que se hacen allí. Por un estudio elaborado los sábados de los últimos tres meses se ha encontrado que en promedio entran al minimercado 28,5 clientes por hora en ese día.

a) ¿Qué tan probable es que el próximo sábado entre las 3 y las 3:30 de la tarde lleguen al minimercado entre 10 y 15 clientes?

b) ¿Qué tan probable es que en una hora del próximo sábado entren por lo menos 50 clientes?

c) ¿Qué tan probable es que en un espacio de 10 minutos del próximo sábado no llegue ni una persona?

Solución:

a) $P(10 \leq x \leq 15) = P(x \leq 15) - P(x \leq 9)$

Función	POISSON.DIST
x	15
Media	14,25
Acumulado	1
$P(x \leq 15)$	0,6444

Función	POISSON.DIST
x	9
Media	14,25
Acumulado	1
$P(x \leq 9)$	0,0981

$P(10 \leq x \leq 15) = 0,6444 - 0,0981$ $= 0,5463 \text{ (54,6\%)}$
--

b) $P(x \geq 50) = 1 - P(x \leq 49)$

Función	POISSON.DIST
x	49
Media	28,5
Acumulado	1
$P(x \leq 49)$	0,99983
$P(x \geq 50)$	0,00017 (0,02%)

c) $P(x=0)$

Función	POISSON.DIST
x	0
Media	4,75
Acumulado	0
$P(x = 0)$	0,00865 (0,9%)

En el siguiente video se hace una aclaración acerca del empleo de la función no acumulada en el modelo Poisson:

<https://www.youtube.com/watch?v=aMtVerhmbmc>

2.4.4 DISTRIBUCIÓN NORMAL:

Es la más empleada para modelar experimentos aleatorios continuos porque describe ajustadamente muchos fenómenos naturales, industriales e investigativos; los errores en mediciones científicas se aproximan bien mediante la distribución normal.


Esta distribución puede obtenerse al considerar el modelo de una variable binomial cuando el número de ensayos tiende a infinito.

Existen varias metodologías para control y mejora de procesos que se basan en la distribución normal; por ejemplo, una que es ampliamente utilizada es la metodología seis sigma, que está centrada en la reducción de la variabilidad de los procesos. Como se mencionó al inicio del libro sigma es la desviación estándar, o sea que todo se reduce a que no se den productos que estén más de tres desviaciones estándar por encima o más de tres desviaciones por debajo, para llevar a obtener cero defectos.


También existe una metodología de control de calidad, donde se crean unas cartas de control basadas en la distribución normal y lo que se busca es establecer unos límites de control que no deben superarse; en caso de superarlos puede deducirse que el proceso está fuera de control, por lo que hay que definir estrategias para llevarlo nuevamente a control.

La distribución normal presenta las siguientes características:


- La gráfica de X (valores de la variable) contra frecuencia (o probabilidad) tiene forma de campana; eso significa que valores muy pequeños o muy grandes de la variable tienen poca probabilidad de ocurrir, mientras que valores intermedios tienen una mayor probabilidad.




- El punto más alto de la curva normal es la media, que también es la mediana y la moda de la distribución.



- El área total bajo la curva es 1 (o 100%).
- La curva es simétrica alrededor de la media; por lo tanto, el área a la izquierda de la media es 0,5 e igual a su derecha (50%-50%).



- El eje x es una asíntota horizontal, es decir, los extremos de la curva se prolongan al infinito en ambas direcciones.
- La desviación estándar determina el ancho de la curva. A mayores valores de σ se obtienen curvas más anchas y bajas (mayor dispersión de los datos).



En el siguiente video se comprueba esta última propiedad, además de mostrar la forma de obtener el gráfico:

Archivo con los datos para practicar:

Graficación Distribución Normal

En Excel se utilizan las siguientes funciones para aplicar la distribución normal:

DISTR.NORM.N: Devuelve la distribución acumulativa normal para la media y la desviación estándar especificadas.

X es el valor cuya distribución se desea obtener.

Pide también media y desviación estándar.

Acumulado: igual a Binomial

INV.NORM: Devuelve el inverso de la distribución acumulativa normal para la media y la desviación estándar especificadas.

Pide probabilidad (de que X sea menor o igual al valor predeterminado), media y desviación estándar.

Lo anterior significa que si se conoce un valor (o valores) de la variable y desea hallarse una probabilidad debe usarse la función **DISTR.NORM.N**, pero si se conoce una probabilidad (o un porcentaje) y debe calcularse un valor de x (la variable) se usa la función **INV.NORM**.

EJEMPLO 8

La empresa petrolera que lidera actualmente el sector de los hidrocarburos en Colombia extrajo (es también la que más exporta), durante el primer semestre del año anterior, una cantidad promedio de 707300 barriles diarios de petróleo. La distribución del número de barriles diarios extraídos diariamente se ajusta al modelo normal y tiene una desviación estándar de 105565 barriles/día.

- a) ¿Qué tan probable es que mañana se extraigan menos de 600000 barriles?
- b) ¿Qué tan probable es que mañana se extraigan más de un millón de barriles?
- c) ¿Qué tan probable es que mañana se extraigan entre 800000 y 950000 barriles?

d) ¿Qué tan probable es que mañana se extraigan menos de 550000 o más de 850000 barriles?


e) ¿Qué cantidad de barriles se extraen en el 5% de los días en que menos petróleo sacan?

f) ¿Qué cantidad de barriles se extraen en el 12% de los días en que más petróleo sacan?

g) ¿Cuántos barriles de petróleo se extraen en el 50% de los días más comunes en cuanto al número de barriles obtenidos? (dos valores simétricamente distribuidos alrededor de la media)


Solución:

a) $P(x < 600000)$




Función	DISTR.NORM.N
x	600000
Media	707300
Desv_ estándar	105565
Acumulado	1
$P(x < 600000)$	0,1547 (15,47%)

b) $P(x > 1000000)$



c) $P(800000 < x < 950000)$




Función	DISTR.NORM.N
x	950000
Media	707300
Desv_estándar	105565
Acumulado	1
$P(x < 950000)$	0,9892

Función	DISTR.NORM.N
x	800000
Media	707300
Desv_estándar	105565
Acumulado	1
$P(x < 800000)$	0,8101

$$P(800000 < x < 950000) = 0,9892 - 0,8101$$

$$= 0,1792 \quad (17,92\%)$$

d) $P(x < 550000) + P(x > 850000)$



Función	DISTR.NORM.N
x	550000
Media	707300
Desv_estándar	105565
Acumulado	1
$P(x < 550000)$	0,0681


Función	DISTR.NORM.N
x	800000
Media	707300
Desv_estándar	105565
Acumulado	1
$P(x < 850000)$	0,9118
$P(x > 850000)$	$1 - 0,9118$ $= 0,0882$

$$P(x < 550000) + P(x > 850000)$$

$$= 0,0681 + 0,0882$$


$$= 0,1563 \quad (15,63\%)$$

e)




Función	INV.NORM
Probabilidad	5%
Media	707300
Desv_estándar	105565
Respuesta	533661 barriles

f)



Función	INV.NORM
Probabilidad	88%
Media	707300
Desv_estándar	105565
Respuesta	831337 barriles

g)



Función	INV.NORM
Probabilidad	25%
Media	707300
Desv_estándar	105565
Respuesta	636097 barriles

Función	INV.NORM
Probabilidad	75%
Media	707300
Desv_estándar	105565
Respuesta	779000 barriles

Los días más “comunes” se extraen entre 636097 y 779000 barriles

Con frecuencia la distribución Normal se soluciona mediante la estandarización de la variable, que consiste en transformar todas las observaciones de cualquier variable aleatoria normal X en un nuevo conjunto de observaciones de una variable aleatoria Z con media 0 y varianza 1; todas las distribuciones normales pueden convertirse a “distribuciones normales estándar” restando la media de cada observación y dividiendo por la desviación estándar, así:

$$Z = \frac{x - \mu}{\sigma}$$

Si se quiere trabajar de esta forma debe utilizarse la función estadística **DISTR.NORM.ESTAND.N**, cuyos argumentos son Z y acumulado. Esto se menciona porque es muy común que los libros de

Estadística hablen de valores Z , pero es realmente lo mismo que el trabajo con la función **DISTR.NORM.N**, solo que con un paso adicional.

Por simple observación de la fórmula puede concluirse que si el valor de la variable es inferior a la media Z es negativo, mientras que si el valor de la variable es superior a la media Z es positivo.

Lo anterior puede deducirse porque la desviación estándar siempre es positiva, por lo que el signo de Z va a depender del signo del numerador.

EJEMPLO 9

En la empresa *Bamako* se utiliza una máquina de llenado automático; el volumen que deposita en latas de una bebida gaseosa tiene una distribución normal con media 150 mililitros y desviación estándar de 0,63 mililitros.

- a) ¿Cuál es la probabilidad de que el volumen depositado sea menor de 148,5 mililitros?
- b) ¿Cuál es la probabilidad de que el volumen depositado sea superior a 151,3 mililitros?
- c) Si se desechan todas las latas que contienen menos de 148 o más de 152 mililitros de bebida, ¿cuál es la proporción de latas desechadas?
- d) Calcule especificaciones que sean simétricas alrededor de la media, de tal forma que se incluya al 99% de todas las latas.

Solución:

$$a) P(X < 148,5) = P\left(Z < \frac{148,5 - 150}{0,63}\right) = P(Z < -2,38) = 0,0087$$

$$\begin{aligned} b) P(X > 151,3) &= P\left(Z > \frac{151,3 - 150}{0,63}\right) = P(Z > 2,06) = 1 - P(Z < 2,06) = 1 - 0,9803 \\ &= 0,0197 \end{aligned}$$

c) La probabilidad de que la lata no sea desechada es:

$$P(148 < x < 152) = P\left(\frac{148-150}{0,63} < Z < \frac{152-150}{0,63}\right) = P(-3,17 < Z < 3,17) \\ = 0,9992 - 0,0008 = 0,9984$$


Por lo tanto, la probabilidad de que sea rechazada es $1 - 0,9984 = 0,0016$

La probabilidad de que sean rechazadas también podría hallarse como:

$$2 \times P(x < 148) = 2 \times 0,0008 = 0,0016$$

Nota: La segunda forma solo puede utilizarse cuando los dos valores están igualmente alejados de la media.

d)



$$(Z > z) = 0,005 \rightarrow (Z < z) = 0,995 \rightarrow Z = 2,576$$

(El último valor fue obtenido con la función estadística INV.NORM.ESTAND)

$$Z = \frac{\hat{x} - \mu}{\sigma} \rightarrow x_1 = \mu + Z \times \sigma = 150 - 2,576(0,63) = 148,38 \text{ ml}$$

$$x_2 = \mu + Z \times \sigma = 150 + 2,576(0,63) = 151,62 \text{ ml}$$

¡PIENSA!

Resuelve este mismo ejercicio con las funciones directas de Excel

2.4.5 DISTRIBUCIÓN EXPONENCIAL

Es una distribución de probabilidad continua útil para describir el tiempo que se necesita para cumplir algo. Eso implica que es el equivalente continuo de la distribución de Poisson, lo que significa que “si en algún proceso las llegadas siguen una distribución de Poisson, el tiempo entre las llegadas debe seguir una distribución exponencial” (Anderson, 2016, 288).

Una probabilidad exponencial se calcula así:

$$P(t < t_0) = 1 - e^{-t_0 \times \mu},$$

donde μ es el promedio de sucesos por la unidad de tiempo.

La distribución exponencial se utiliza para medir tiempos de duración, tiempos de vida, tiempos de espera, etc. Es de gran utilidad en otras disciplinas como la teoría de colas.

Para trabajar con la distribución Exponencial en Excel se usa la función estadística **DISTR.EXP.N**, la cual incluye los siguientes argumentos:

X, que es el valor de la función, generalmente el tiempo que se tarda un evento.

Lambda, que es el promedio de eventos en el tiempo. La unidad de medida debe coincidir con la del valor X.

Acumulado, que funciona de manera similar a las otras distribuciones.

EJEMPLO 10

A un banco entran en promedio 54 clientes por hora y se pueden atender 45 clientes por hora.

a) ¿Qué tan probable es que en un espacio de un minuto lleguen 2 clientes o más?

b) ¿Qué tan probable es que un cliente se pueda atender en un minuto o menos?

Solución:

a) Se pregunta por el número de sucesos que ocurren en un espacio de tiempo, por lo que debe usarse la distribución de Poisson. Al banco entran en promedio 54 clientes por hora, es decir, 0,9 clientes por minuto (54/60); se pasa a minutos para que las unidades coincidan con las de la pregunta, aunque también se pudo pasar todo a horas.

$$(x \geq 2) = 1 - P(x \leq 1)$$

Función	POISSON.DIST
x	1
Media	0,9
Acumulado	1
$P(x \leq 1)$	0,7725
$P(x \geq 2)$	0,2275 (22,8%)

b) Se pregunta por el tiempo necesario para algo. Debe usarse la distribución exponencial y tener en cuenta que si el tiempo está en minutos, el promedio debe estar en la misma unidad; 45 clientes por hora es equivalente a 0,75 clientes por minuto (45/60).

Función	DISTR.EXP.N
x	1
Lambda	0,75
Acumulado	1
$P(t \leq 1)$	0,5276

EJEMPLO 11

El tiempo que tarda un empleado para tomar el pedido de un cliente en un restaurante sigue una distribución exponencial con una respuesta de atención al cliente de 4 minutos en promedio.

a) ¿Qué probabilidad hay de que un cliente deba esperar más de 5 minutos para que su pedido sea tomado?

b) Si un cliente va a ese restaurante los siete días de esta semana, ¿qué tan probable es que en 3 o más de ellos tenga que esperar por lo menos 5 minutos para que le tomen el pedido?

Solución:

a)

Función	DISTR.EXP.N
x	5
Lambda	0,25
Acumulado	1
$P(t \leq 5)$	0,7135
$P(t > 5)$	0,2865

Nota aclaratoria: Lambda es 0,25 porque está dada en clientes por minuto.

Se da el promedio $\frac{4 \text{ minutos}}{\text{Un cliente}}$, que es equivalente a decir $\frac{1 \text{ cliente}}{4 \text{ minutos}}$,

es decir, 0,25 clientes por minuto.

b) $P(x \geq 3) = 1 - P(x \leq 2)$

Función	DISTR.BINOM.N
Núm_éxito	2
Ensayos	7
Prob_éxito	0,2865
Acumulado	1
$P(x \leq 2)$	0,6775
$P(x \geq 3)$	0,3225

En el siguiente video se explica la aplicación de la distribución Exponencial en Excel y la manera de graficarla:

<https://www.youtube.com/watch?v=2miHexudWIw>

Archivo con los datos para practicar:

[Distribución Exponencial](#)

EJERCICIOS RESUELTOS

Te invito a que, antes de estudiar los videos donde se desarrolla cada problema, intentes resolver los ejercicios. De esta manera podrás evaluar la comprensión de los temas.

1. En el municipio de La Ceja está ubicada una fábrica de embutidos denominada *La Reyna*.

Uno de sus productos estrella es el jamón Reyna Oro, pero últimamente se han presentado muchos problemas en su proceso de empaclado por falta de estandarización. La etiqueta del empaque de jamón que sale al mercado dice que el peso es de 500 gramos.

En la planta se hizo un muestreo grande de paquetes de jamón y se encontraron los siguientes pesos:

Ejercicio resuelto 1 Probabilidades

Si se asume que esos datos se ajustan a una distribución normal,

a) ¿Qué tan probable es encontrar un paquete que pese menos de 475 gramos? ¿Qué problemas podrían generarse si esto ocurre?

b) ¿Qué tan probable es encontrar un paquete que pese más de 530 gramos? ¿Qué problemas podrían generarse si esto ocurre?

c) Por especificaciones de calidad sale al mercado el 95% de los paquetes. ¿Cuáles deben ser las especificaciones que se fijen para que eso ocurra? (aproxime a números enteros)

<https://www.youtube.com/watch?v=RTKdIGrewE8>

2. Guinea es una empresa que produce y comercializa pinturas. Algunas de sus materias primas deben ser importadas desde Canadá; debido a ello, sus utilidades se ven muy afectadas por el precio del dólar en el mercado.

Ejercicio resuelto 2 Probabilidades

a) El 77,1% de los meses de los últimos 4 años la empresa ha recibido utilidades superiores al promedio del sector de pinturas. Si se toma una muestra de 18 meses,

- ¿Cuál es la probabilidad de que por lo menos en 15 de ellos se reciban utilidades superiores al promedio del sector?

- ¿Qué tan probable es que entre 2 y 5 reciban utilidades inferiores al promedio del sector?

b) Se tomaron datos de los últimos 36 meses y se encontró que en promedio en ellos ha habido unas utilidades de 58850 millones de pesos colombianos, con una desviación estándar de 7780 millones de pesos colombianos y que tienen una distribución aproximadamente normal.

- ¿Qué tan probable es que en el próximo mes las utilidades estén entre 55000 y 72000 millones de pesos colombianos?

- ¿Qué utilidades se alcanzan en el 75% de los meses en que la utilidad es más “común”?

c) Guinea tiene un almacén donde comercializa sus pinturas. Si en un día común entran en promedio 35 personas por hora en el tiempo en que está abierto el almacén,

- ¿Qué tan probable es que mañana entren en todo el día 450 personas o más? (El almacén está abierto 12 horas al día).

Considera que mañana es un día de los clasificados como común.

- ¿Qué tan probable es que mañana entren 20 personas o menos por hora?

d) En Guinea se producen tres referencias de pinturas: A, B y C. De la referencia A se produce un 65% de lo producido en la Empresa, un 19% de la referencia B y el resto de la referencia C. El 1,7% de lo que se produce de la referencia A tiene algún problema en su consistencia, al igual que el 2,5% de la B y 4,2% de la C.

¿Qué porcentaje de la pintura originada en la empresa tiene problemas en su consistencia?

https://www.youtube.com/watch?v=tSdF_hFqR34

<https://www.youtube.com/watch?v=5s1wc1oEYdk>

3. El 80% de las empresas pequeñas del sector de alimentos no está preparada para un tratado de libre comercio con España, al igual que el 63% de las empresas medianas y 30% de las grandes. El 80% de las empresas de sector son pequeñas, el 15% son medianas y el resto son grandes.

Ejercicio resuelto 3 Probabilidades

a) ¿Cuál es la probabilidad de que una empresa no esté preparada para el TLC y sea pequeña?

b) ¿Qué porcentaje dice estar preparada para enfrentar ese tratado?

c) Si una empresa no está preparada para el TLC, ¿cuál es la probabilidad de que sea pequeña?

d) Si una empresa es pequeña, ¿cuál es la probabilidad de que esté preparada?

https://www.youtube.com/watch?v=g3_0qAx-vs0

EJERCICIOS PROPUESTOS

Inmediatamente después de los planteamientos de los ejercicios se encuentra un archivo de Excel con sus soluciones.

1. Según registros de la Cámara de Comercio de Medellín, el 88,9% de las empresas de Antioquia son Microempresas, el 10,2% son Pymes y el 0,9% corresponde a empresas grandes.

La misma fuente indica que solamente el 8% de las microempresas antioqueñas exportan parte de su producción, al igual que el 13,5% de las pymes y el 74% de las empresas grandes del Departamento.

a) Elabora tabla de contingencia.

b) Entre las empresas que no exportan, ¿qué porcentaje corresponde a microempresas?

2. Una de esas microempresas que fueron evaluadas produce chorizos vegetarianos. Por estándares empresariales, un chorizo producido en la Empresa debe pesar 300 gramos. Si pesa menos de 265 gramos o más de 335 gramos el chorizo no sale al mercado. Para evaluar el proceso se tomó una muestra de 150 chorizos y se registraron los pesos en la siguiente tabla:

Ejercicio 2_Probabilidades

Se encontró que los datos se distribuían de forma aproximadamente normal.

a) ¿Cuál es la probabilidad de que un chorizo producido por esa empresa no salga al mercado?

b) ¿Qué peso tiene el 15% de los empaques con peso más común?

3. A esa empresa llegan, en promedio, propuestas de 9 proveedores distintos al mes.

a) ¿Qué tan probable es que en un determinado mes lleguen 20 o más propuestas de proveedores?

b) ¿Qué tan probable es que en una quincena lleguen como máximo 3 propuestas de proveedores?

4. Cierta producto tiene una demanda que exhibe una variabilidad que sigue aproximadamente una distribución normal con media 185 unidades demandadas por día y una desviación estándar de 37,8 unidades demandadas por día.

- a) ¿Qué tan probable es que en un día se demanden más de 300 unidades?
- b) ¿Qué tan probable es que en un día se demanden entre 100 y 150 unidades?
- c) ¿A partir de qué cantidad de pedidos se encuentra el 10% de los días en que el producto se demanda menos?

5. Se elige una muestra de 50 empresas colombianas exportadoras. Se sabe por estadísticas de años anteriores que aproximadamente el 45% de las empresas colombianas exportadoras registra operaciones en varias ciudades.

- a) ¿Qué tan probable es encontrar al menos 30 empresas que tengan operaciones en varias ciudades?
- b) ¿Qué tan probable es encontrar entre 10 y 15 empresas que operen en varias ciudades?
- c) ¿Qué tan probable es encontrar máximo 10 empresas que operen en una sola ciudad?

6. Un embarque contiene 1000 artículos, de los cuales hay 20 defectuosos (lo sabe la empresa productora). La empresa que realiza las inspecciones toma una muestra aleatoria de 10 artículos y si encuentra por lo menos uno defectuoso rechaza el embarque, ¿cuál es la probabilidad de que el embarque se rechace?

7. La carretera que usa la empresa X para transportar sus productos hasta cierto pueblo del Departamento presenta, en promedio, 8 huecos grandes por kilómetro; si se presenta algún trayecto de un kilómetro que tenga 20 huecos o más, la carretera se considera intransitable. ¿Qué tan probable es que lo anterior se presente?

8. Se ha encontrado, por datos históricos, que el monto de negocios en las ferias de textiles que se han desarrollado en Colombia durante los últimos 5 años sigue aproximadamente una distribución normal con media 9,8 millones de dólares y desviación estándar de 8,7 millones de dólares.

- a) En la última feria de *Colombiatex*, realizada en Medellín, se efectuaron negocios por 33 millones de dólares; ¿hará parte del 5% de ferias textileras donde más negocios se han hecho?
- b) ¿Cuál es la probabilidad de que en una feria de este tipo se hagan negocios por más de 15 millones de dólares?

9. Los costos de servicio por mes en una agencia de viajes tienen una distribución aproximadamente normal, con promedio de \$150 millones y desviación estándar de \$6750000.

a) ¿Cuál es la probabilidad de que en el próximo mes los costos de servicio estén entre 120 y 170 millones de pesos?

b) ¿Por encima de qué valor están los costos de servicio en el 20% de los meses con mayores costos?

10. A una sucursal de cierto banco llegan en promedio 60 clientes por hora y un cajero puede atender en promedio 16 clientes en ese espacio de tiempo.

a) Si se supone que las llegadas se distribuyen aproximadamente como una distribución de Poisson, ¿cuál es la probabilidad de que en un espacio de 10 minutos lleguen tres clientes o menos?

b) Si se supone que los tiempos de servicio se distribuyen exponencialmente, ¿qué tan probable es que un cajero pueda atender a alguien en tres minutos o menos?

11. Los clientes de una empresa de comidas rápidas deben esperar en promedio 4 minutos para que su pedido sea tomado. Debes suponer que estos tiempos siguen una distribución exponencial.

a) ¿Qué probabilidad hay de que el próximo cliente sea atendido en menos de 2,5 minutos?

b) ¿Qué probabilidad hay de que el próximo cliente deba esperar entre 1 y 3 minutos para que su pedido sea tomado?

c) ¿Qué tan probable es que el próximo cliente tenga que esperar más de 10 minutos para que su pedido sea tomado?

12. *Luanda* es una empresa de la industria electrónica que recibe los componentes que son su materia prima en grandes lotes. Su esquema de control de calidad menciona que debería aceptar un lote si los componentes defectuosos no constituyen más del 1%; para probar un componente debe destruirlo, por lo que no resulta nada rentable apoyarse en grandes muestras; por eso se basa en una técnica de control denominada muestreo de aceptación, la cual se fundamenta en la toma de muestras aleatorias pequeñas. Su táctica consiste en elegir una muestra aleatoria de cinco unidades en cada lote que va a probar y aceptarlo si no encuentra ningún componente defectuoso.

a) ¿Cuál es la probabilidad de no encontrar ningún elemento defectuoso si el lote tiene 1% de componentes defectuosos? ¿Qué pasaría si la muestra es de 15 unidades?

b) ¿Qué tan probable es que se acepte un lote que realmente tiene 2% de unidades defectuosas? ¿Qué pasaría si la muestra es de 15 unidades?

c) ¿Qué tan probable es que se rechace un lote que realmente tiene 5% de unidades defectuosas? ¿Cuál es esa probabilidad si la muestra es de 15 unidades?

d) ¿Si te contratan como Jefe de Calidad estarías tranquilo con ese esquema de aceptación que tiene actualmente la empresa? ¿Por qué? ¿Consideras que el tamaño de la muestra debe aumentarse?

13. Por estadísticas anteriores se conoce que el 90% de los negocios que son franquicias pasan de los diez años en el mercado, mientras que el 29% de los negocios totalmente nuevos sobreviven por más de diez años (Ángel, 2010, p. 13).

Para verificarlo, una empresa de estadísticas evaluó los casos de 395 empresas, de las cuales 108 eran franquicias; de ellas, 92 sobrevivían todavía a los diez años. De las que no eran franquicia, encontró que 204 habían cerrado antes de los diez años de funcionamiento.

a) Según el último estudio, ¿cuál es la probabilidad de que una empresa –sea franquicia o no– sobreviva diez años o más en el mercado?

b) Según los datos encontrados, ¿qué tan probable es que una franquicia sobreviva menos de diez años en el mercado? ¿Qué tan probable es que un negocio que no es franquicia sobreviva ese tiempo? ¿Parece estar eso en armonía con el estudio detallado previamente?

14. En cierta empresa se fabricaron durante la semana 50 estaciones de juego para video. Cuarenta de ellas funcionaron perfectamente y las demás tenían algún defecto. Se seleccionó al azar una muestra de 5; ¿cuál es la probabilidad de que al menos 4 de ellas funcionaran perfectamente?

15. En cierta empresa se afirma que la proporción de unidades defectuosas es su producción es 3%. Una persona compró 25 de sus productos y encontró 5 con defectos.

a) ¿Cuál es la probabilidad de que eso ocurra si se considera que la afirmación de la empresa es correcta?

b) ¿Qué puede concluirse?

16. Una compañía exporta parte de su producción y tiene un programa de verificación de sus productos antes de exportarlo. Preparan contenedores con 100 artículos cada uno y se prueba una muestra de 8 artículos; si se encuentran por lo menos dos con defectos se devuelve todo el contenedor.

a) ¿Cuál es la probabilidad de que se embarque un contenedor con 5 artículos defectuosos?

- b) ¿Cuál es la probabilidad de que un contenedor que tiene dos artículos defectuosos se devuelva?
- c) ¿Qué opinas del proceso de muestreo?

17. Se llevó a cabo una investigación sobre el proceso de internacionalización de las Pymes de Antioquia; en dicha investigación se evaluó si la formación académica de los dueños está relacionada con el inicio de dicho proceso. Se obtuvo la siguiente información sobre una muestra de 500 pymes

Probabilidad marginal, condicional y conjunta

Si se pretende extender los hallazgos a todas las Pymes de Antioquia:

- a) ¿Cuál es la probabilidad de que la empresa no haya iniciado el proceso de internacionalización?
- b) Si una empresa no ha iniciado el proceso de internacionalización, ¿qué tan probable es que sus dueños tengan una formación académica escasa?
- c) Si los dueños de la empresa tienen una formación académica escasa, ¿qué tan probable es que su empresa no haya iniciado el proceso de internacionalización?
- d) ¿Qué tan probable es que una pyme de Antioquia no haya iniciado el proceso de internacionalización y tenga dueños con una formación académica escasa?


RESPUESTAS A EJERCICIOS PROPUESTOS

[Descargar archivo Excel](#)

3. ESTADÍSTICA INFERENCIAL

El objetivo básico de la estadística inferencial consiste en extraer información aplicable a toda una población con base en los resultados obtenidos a partir de una muestra.

Constantemente vemos en revistas y periódicos afirmaciones como “el 75% de los colombianos apoya la labor del presidente” o “el 7% de las empresas colombianas exportan parte de su producción” y generalmente a nosotros no nos han preguntado nada o nuestra empresa no ha sido objeto de recolección de datos al respecto. Esos valores son obtenidos a partir de muestras y con base en las distribuciones de probabilidades puede generalizarse para toda la población colombiana; para que eso sea justificable la muestra tiene que ser representativa, tanto en cantidad como en calidad.



Por todo lo anterior, es necesario resaltar que para aplicar herramientas estadísticas inferenciales es indispensable delimitar claramente la población objetivo desde el inicio y que la muestra que se tome como base para hacer las inferencias sí represente a todo el conjunto; por ejemplo, si se quiere sacar una conclusión para toda la población colombiana, en la muestra debe haber personas de diferentes ciudades, diferentes estratos sociales, diferente sexo, diferentes edades, etc. O si por ejemplo el interés recae en el estudio de cierta actividad empresarial hay que determinar desde antes de recoger datos el tamaño de las empresas objeto de estudio, su ubicación geográfica y todos los aspectos que sea posible; se debe garantizar, por ejemplo, que si el estudio es sobre las empresas colombianas no se recojan datos solamente entre empresas de una pequeña región.

Asimismo se puede requerir verificar o contrastar un supuesto o hipótesis. Es por ello que en este capítulo se ha dispuesto un conjunto de herramientas para hacer estimaciones científicas sobre las variables que se quiera valorar o sobre las cuales se desea probar una hipótesis.

Para hacer generalizaciones sobre la población a partir de lo que se encuentre en una muestra, la Estadística se apoya en la teoría de probabilidades

Pero para garantizar la generalización es necesario que la muestra sea representativa y que se haya hecho un adecuado diseño de muestreo. Es de suma importancia tener en cuenta que solo se puede generalizar si se cumplen todas las características de la selección apropiada de la muestra (que se mencionará más adelante); de lo contrario, las conclusiones que se saquen solamente pueden ser asumidas para los elementos de la muestra que se haya seleccionado.

Al respecto, Triola (2013) menciona “Si los datos muestrales no se reúnen de forma adecuada, resultarán tan inútiles que ningún grado de tortura estadística podrá salvarlos” (p. 4).

Para que la muestra sea representativa deben cumplirse simultáneamente tres características:

- Debe ser aleatoria (o por lo menos parcialmente aleatoria), es decir, que no sea escogida por la persona que hace la investigación, sino que en su selección intervenga el azar. Si el investigador elige su muestra, puede recoger información muy importante, pero el muestreo no sería probabilístico y por lo tanto no podrían hacerse generalizaciones.

Si la población es finita y se tiene una base de datos con todos sus elementos debe generarse una cantidad de números aleatorios según el tamaño óptimo de muestra (puede hacerse con la función **ALEATORIO.ENTRE**); esa será la posición de los elementos que harán parte de la muestra. Una manera rápida de seleccionar la muestra se basa en el uso de la función **ÍNDICE**.

Dicho proceso se explica en el siguiente video:

<https://youtu.be/apFKB414h3I>

Archivo con los datos para practicar:

[Función índice](#)

Nota: Es necesario que los números aleatorios generados sean pegados como valores porque la función **ALEATORIO.ENTRE** es volátil, lo que significa que se recalcula cuando se modifica cualquier celda y, por lo tanto, la lista de números estaría cambiando permanentemente.

Si la población es infinita debe garantizarse que cada elemento se seleccione en forma independiente (Anderson, 2016, p. 303)

- Debe tener un tamaño adecuado, ya que si es muy pequeña los resultados serán poco confiables, pero si es muy grande puede conducir a un costo logístico más alto de lo necesario; por eso lo esencial es buscar el equilibrio y es ahí donde entra en juego el criterio del administrador, de acuerdo con la relevancia para su organización de los resultados de las estimaciones.

Al determinar el tamaño ideal de muestra se debe tener en cuenta el tamaño de la población, pero


nunca corresponde a un porcentaje específico de ella; una muestra del 40% de la población puede ser muy pequeña si la población es de 50 elementos, pero una muestra de 1% resulta muy grande si la población es de 40 millones de elementos.

- Debe ser espejo de la población, o sea que cualquier elemento que haga parte de la población objetivo debe ser susceptible de hacer parte de la muestra. Por esa razón, lo primero que debe hacerse es delimitar claramente la población objetivo de tal forma que sí alcance a cubrirse en forma completa; por ejemplo, si una investigación se define como “Proceso de internacionalización de las empresas colombianas”, en la muestra deben estar incluidas empresas de diferentes tamaños, diferentes sectores, diferentes zonas geográficas, etc.; lo anterior exigiría una infraestructura muy completa, por lo que puede ser más inteligente delimitar más la población y definirla como “Proceso de internacionalización de las pymes de alimentos del sur del Valle de Aburrá” (o, en general, cualquier zona más específica).

Lo ideal sería, entonces, que la muestra contenga las características poblacionales en la misma proporción; pero por obvias razones, si se toman muestras eso es imposible garantizarlo.

La estadística inferencial incluye dos procesos:

- Estimación, que consiste en predecir el valor más probable de una característica poblacional.
- Prueba de hipótesis, que consiste en verificar un supuesto lanzado antes de reunir información estadística.



Ejemplo Diferencia conceptual entre ambos procesos:

A los empleados de una empresa se les inscribió en una capacitación con una nueva máquina de pulido para optimizar los tiempos que tardaban en este proceso, ya que algunos clientes se quejaban por demo-

ra en la entrega de los pedidos. Se tienen datos de tiempos de algunos empleados de la empresa antes y después de la capacitación.

Estimación: Predice el promedio de la mejora en los tiempos después de la capacitación.

Prueba de hipótesis: Los dueños de la empresa suponen que la capacitación hará que los tiempos que tardan los empleados para este proceso mejorará por lo menos en 30 minutos. Comprueba mediante los datos si parece que eso no se cumplió o si no hay base estadística para refutarlo.

Para el desarrollo y comprensión de la mayoría de los temas de Estadística inferencial se estudiará el siguiente caso:

Dos administradores recién egresados inauguraron el año pasado un establecimiento de comidas basado en el sabor de la canela en un centro comercial de Medellín.

3.1 ESTIMACIÓN

En el anterior capítulo se manejó información de muestras aleatorias tomadas de una población conocida; pero lo más importante es coleccionar información sobre la población a partir de muestras tomadas de ella. Eso es lo que se conoce como **estimación**.

Con base en estimaciones se determinan presupuestos, planes de negocios, inversiones y pronósticos.

A un valor calculado con los datos de una muestra se le llama **estadígrafo o estadístico**; un estadígrafo no es un valor fijo, ya que puede tener varios resultados diferentes según la muestra seleccionada, aunque la población de la cual se extrajo la muestra sea la misma. Ese estadígrafo es usado como **estimador** para predecir un valor característico de una población.

El valor característico de la población se denomina **parámetro**, que es un valor fijo, pero generalmente desconocido, ya que rara vez se puede determinar exactamente su valor, debido a la dificultad práctica de observar todas las unidades de una población.

Dicha estimación puede hacerse mediante estimación puntual, que consiste en asumir que el valor del parámetro es exactamente igual al valor del estadígrafo calculado.

Algunos estimadores puntuales son:

- La proporción muestral ($\hat{p}$), usado como estimador de la proporción poblacional (p).

- La media muestral ($\bar{X}$), usado como estimador del valor esperado poblacional (μ).
- La varianza de la muestra (σ_{n-1}^2), usado como estimador de la varianza de la población (σ_n^2).

Aunque esta es quizá una manera muy común de expresar una estimación, da lugar a muchas preguntas; por ejemplo, no indica la cantidad de información sobre la cual se basa la estimación y no dice nada acerca del posible tamaño del error (y siempre que se toman muestras existe algún error). Puede observarse que este método de estimación ignora la importancia del tamaño de la muestra, ya que sería igual si la muestra es de 5 o de 500 elementos.

En consecuencia, se opta por un segundo método de estimación denominado **estimación por intervalos**, que indica la precisión de una estimación; dicha idea de precisión es definida por el error estándar, que es la desviación estándar de la distribución de las medias de las muestras.

La técnica de este tipo de estimación consiste, entonces, en asociar a cada muestra un intervalo que tiene una alta probabilidad de contener el verdadero valor del parámetro; se le denomina **intervalo de confianza**. Este parámetro será habitualmente una proporción en el caso de variables cualitativas, y la media o la varianza para variables cuantitativas.

Este método sí tiene muy presente que la muestra empleada sea de un tamaño adecuado; si es demasiado grande se desperdicia tiempo y dinero, y, si es muy pequeña, las conclusiones resultantes no son confiables. Además, está demostrado estadísticamente que muestras de mayor tamaño son menos variables que muestras más pequeñas.

El tamaño de la muestra depende de tres factores:

- Si la población fuente de la muestra se considera infinita o finita; se supone finita si es de un tamaño conocido y se considera infinita si es de un tamaño desconocido o es muy grande. Si es posible, lo ideal es establecer ese tamaño poblacional porque las muestras requeridas son de menor tamaño.

- **El nivel de confianza**, que se denota como $1-\alpha$ (uno menos alfa) y es la probabilidad de que la estimación hecha se ajuste a la característica poblacional evaluada, es decir, es la probabilidad de que el verdadero valor del parámetro caiga en el intervalo de confianza establecido (más adelante se aclarará el significado de intervalo de confianza). Se determina subjetivamente, lo que significa que no es producto de ningún cálculo, sino que depende del criterio del investigador, pero debe ser un valor cercano a 100%, generalmente 90 o 95%, ya que si es extremadamente alto (99%) el tamaño de muestra que se necesita crecería exageradamente.

- **El margen de error** (e), que es una medida de la imprecisión que se está dispuesto a aceptar al hacer una estimación. También se determina subjetivamente, pero debe ser un valor pequeño, generalmente inferior o igual a 5%, pero si se baja demasiado el tamaño de muestra que se necesita sería muy grande.

Lo que se fija es un máximo; eso significa que el error del intervalo de confianza establecido (que corresponde a la mitad de la amplitud del intervalo) no puede exceder de lo que se fija como margen de error.

Cuando la encuesta tiene solamente preguntas cuantitativas el margen de error no corresponde a un porcentaje, sino a un espacio evaluado en la misma unidad de medida, pero que también se fija arbitrariamente; por ejemplo, si se está calculando un intervalo de confianza de algo que está

medido en dólares, puede fijarse un margen de error de x dólares y según eso se fija el tamaño de la muestra. Por eso, si se incluyen variables cuantitativas medidas en diferentes unidades, deben plantearse varios márgenes de error.


Para calcular el tamaño apropiado de muestra se debe hacer una estimación de p. Para ello debemos basarnos en un valor $\hat{p}$ (proporción de la muestra) de una muestra anterior o en el establecimiento de $\hat{p}$ a partir de una muestra piloto (y se determina cuántas observaciones adicionales se necesitan para estimar p con una exactitud predeterminada) o haciendo una estimación subjetiva (en este caso, debe conocerse muy bien lo que se hace).

Otro enfoque para seleccionar el tamaño de muestra (el más utilizado) consiste en maximizar la ecuación, teniendo en cuenta que $p \times q$ es máximo cuando p y q tienen un valor de 0,5 (50%).

En este libro se utilizarán herramientas digitales para obtener el tamaño de muestra, pero si se va a calcular de manera manual, el tamaño apropiado de la muestra si proviene de una población infinita es:

$$n = \left(\frac{Z}{e} \right)^2 \times p \times q$$

El valor Z corresponde a la estandarización de la distribución normal y se calcula con la función INV.NORM.ESTAND. Por ejemplo, si el nivel de confianza es 90% ($1-\alpha$), $\alpha/2$ corresponde al 5%, por lo que Z es -1,645 (INV.NORM.ESTAND. con probabilidad 5% o 0,05).



Si la población es finita, el tamaño de la muestra que debe seleccionarse es:

$$n = \frac{(Z_{\alpha/2})^2 \times p \times q \times N}{(N - 1)e^2 + (Z_{\alpha/2})^2 \times p \times q}$$

Excel no permite hacer directamente el cálculo del tamaño de muestra, por lo que el autor desarrolló una plantilla que permita hacerlo; dicha plantilla está diseñada de tal manera que pueda calcularse en forma directa el tamaño apropiado de una muestra según el nivel de confianza y el margen de error definidos, al igual que el margen de error si se usa una muestra de un tamaño determinado; la plantilla se encuentra a continuación:

Tamaño de muestra

En este video se explica el uso de la plantilla Tamaño de muestra:

<https://www.youtube.com/watch?v=E7HqWKZ5kfg>

Nota aclaratoria: En la plantilla también se incluye un apartado para calcular el tamaño requerido de muestra cuando las variables que se van a evaluar son cuantitativas. Su uso se aclarará con el ejemplo 4.

EJEMPLO 1

Los dueños de un establecimiento de comidas hicieron antes de la apertura una investigación de mercados para determinar qué productos ofrecer. Para tal efecto planearon la realización de una encuesta y en los resultados quieren tener un nivel de confianza de 90% y un margen de error de 5%, ¿cuál debe ser el tamaño de la muestra a utilizar?

Solución:

La población debe considerarse como infinita porque no se sabe cuántos clientes potenciales puede tener el establecimiento.

TAMAÑO MUESTRAL PARA DIFERENTES NIVELES DE CONFIANZA Y MÁRGENES DE ERROR AL ESTIMAR UNA PROPORCIÓN EN POBLACIONES INFINITAS

Margen de error	99%	95%	90%
1,00%	16588	9604	6764
1,50%	7373	4269	3007
2,00%	4147	2401	1691
2,50%	2654	1537	1083
3,00%	1844	1068	752
3,50%	1355	784	553
4,00%	1037	601	423
4,50%	820	475	335
5,00%	664	385	271

Por lo tanto, la muestra debe ser por lo menos de 271 personas.

EJEMPLO 2

Los dueños del negocio anterior planean abrir un pequeño local en un sector de Medellín muy visitado por turistas extranjeros; el mercado meta está formado por los turistas alojados en ese sector, que se calcula en una población flotante de aproximadamente 1300 personas. Para acceder a ellos se quiere hacer una encuesta y en los resultados se quiere tener un nivel de confianza de 90% y un margen de error de 3,5%, ¿cuál debe ser el tamaño de la muestra a utilizar?

Solución:

En este caso la población debe considerarse como finita.

TAMAÑO MUESTRAL PARA DIFERENTES NIVELES DE CONFIANZA Y MÁRGENES DE ERROR AL ESTIMAR UNA PROPORCIÓN EN POBLACIONES FINITAS

Tamaño población	1300
Prob. de ocurrencia	0,5

Valor de Z (fijo)	2,5758293	1,95996398	1,64485363
	Nivel de confianza		
Margen de error	99%	95%	90%
1,00%	1206	1146	1091
1,50%	1106	997	908
2,00%	990	844	736
2,50%	873	705	591
3,00%	763	587	477
3,50%	664	490	388
4,00%	578	411	320
4,50%	503	348	266
5,00%	440	297	225

La muestra debe ser por lo menos de 388 personas.



EJEMPLO 3

Si antes de abrir el nuevo local deciden hacer la encuesta a 30 turistas, ¿de qué tamaño es el margen de error si se considera ese nivel de confianza de 90%? ¿Lo consideras aceptable?

Solución:

Tamaño de muestra	30	23,5%	17,9%	15,0%
-------------------	----	-------	-------	-------

Eso no es aceptable porque es considerablemente alto (Es de 15% y no debería ser mayor a 5%)

EJEMPLO 4

Para vigilar la calidad de su servicio, una empresa que se dedica al comercio electrónico selecciona una muestra aleatoria de clientes cada mes; se establece contacto con cada cliente muestreado, se le hace una serie de preguntas acerca de la calidad del servicio y se determina una calificación de satisfacción por cliente muestreado entre 0 y 100. Las encuestas anteriores han demostrado que, aunque la media cambia mes a mes, la desviación estándar de las calificaciones ha tendido a estabilizarse en 20.

a) ¿Qué tan grande se requiere una muestra si queremos tener 95% de confianza de que el error de estimación no excederá de 2?

b) Si se estima que la empresa tiene 1800 clientes, ¿qué tan grande debe ser la muestra si se consideran los parámetros anteriores?

Solución:

TAMAÑO MUESTRAL PARA DIFERENTES NIVELES DE CONFIANZA Y MÁRGENES DE ERROR (En valor absoluto) AL ESTIMAR UNA MEDIA ARITMETICA EN POBLACIONES INFINITAS.

Desviación Estándar	20			
	Valor de Z (fijo)	2,5758293	1,95996398	1,64485363
Nivel de confianza				
Margen de error (Valor Absoluto)	99%	95%	90%	
1	2654	1537	1083	
1,5	1180	683	481	
2	664	385	271	
2,5	425	246	174	
3	295	171	121	

a) La muestra debe ser por lo menos de 385 elementos.

TAMAÑO MUESTRAL PARA DIFERENTES NIVELES DE CONFIANZA Y MÁRGENES DE ERROR (Valor Absoluto) AL ESTIMAR UNA MEDIA ARITMÉTICA EN POBLACIONES FINITAS

Tamaño población	1800
Desviación Estándar (Valor Absoluto)	20

Valor de Z (fijo)	2,575829304	1,95996398	1,64485363
	Nivel de confianza		
Margen de error	99%	95%	90%
1	1073	830	677
1,5	713	496	380
2	485	317	236
2,5	344	217	159
3	254	157	113
3,5	194	118	85

b) La muestra debe ser mínimo de 317 elementos.

Cuando se hace una encuesta no es importante únicamente el número de personas que sean interrogadas. Todo tiene que determinarse de manera muy inteligente; es necesario diseñar muy bien cada pregunta y decidir claramente a quién se le van a hacer esas preguntas (población objetivo). No hay una forma única, pero lo más importante es que todos los detalles se hagan con una intencionalidad clara y con sumo cuidado; por ejemplo, hay que tener especial cuidado con la redacción de cada pregunta porque puede inducir sesgo.

Valga aclarar, por último, que una encuesta constituye una herramienta sumamente valiosa, pero, como implica incertidumbre, siempre existe la posibilidad de llegar a conclusiones equivocadas.

Es muy común que cuando se quiera hacer una inferencia se use un muestreo aleatorio estratificado. Cuando se hace de esta forma se divide la población en un determinado número de grupos (estratos), luego se elige el tamaño de muestra conveniente según las especificaciones requeridas y se divide proporcionalmente de acuerdo a la frecuencia relativa (porcentaje) de cada estrato en la población.

De acuerdo con Kelmansky (2009) “es importante hacer un muestreo estratificado si se sospecha que existe poca variabilidad dentro del estrato, pero mucha variabilidad entre estratos” (p. 36).

EJEMPLO 5

Se está desarrollando una investigación entre pequeñas y medianas empresas industriales del Valle de Aburrá. Fueron censadas 856 empresas de confecciones, 1057 empresas de alimentos, 165 empresas metalúrgicas y 1456 empresas de otros sectores. ¿Cuál debe ser el tamaño de la muestra seleccionada si en la investigación se quiere tener un nivel de confianza de 95% y un margen de error de 4%?

Solución:

Se censaron en total 3534 empresas; de ellas, 24,2% es de confecciones, 29,9% es de alimentos, 4,7% son metalúrgicas y el 41,2% pertenece a otros sectores.

En la plantilla se encuentra que la muestra debe ser de 514 empresas. Teniendo en cuenta las proporciones, en la muestra deben incluirse 124 empresas de confecciones, 154 de alimentos, 24 metalúrgicas y 212 de otros sectores.

También es frecuente que se haga un muestreo por conglomerados, en el que la población se divide en grupos (conglomerados); luego se elige una muestra aleatoria de conglomerados y finalmente se evalúan todos los elementos de cada conglomerado seleccionado en la muestra (muestreo por conglomerados en una etapa) o se toman muestras aleatorias de cada conglomerado (muestreo por conglomerados en dos etapas).

EJEMPLO 6

Se va a hacer un estudio de las empresas ubicadas en los barrios de Medellín; en dicho estudio se quiere hacer un muestreo por conglomerados y se encontró que en Medellín hay registrados 254 barrios. Al tomar las muestras se desea tener un nivel de confianza de 90% y un margen de error de 7%. Diseñe el proceso de muestreo.

Solución:

En la plantilla se encuentra que la muestra inicial debe ser de 90 barrios. Se construirá un listado de esos 254 barrios y, de acuerdo con el método explicado anteriormente, se seleccionarán aleatoriamente 90 de ellos; luego se elegirá una muestra en cada uno de ellos, de acuerdo al margen de error y el nivel de confianza elegidos, y de acuerdo a la cantidad de habitantes de cada uno de esos barrios.

CONSTRUCCIÓN DE INTERVALOS DE CONFIANZA:

Un intervalo de confianza puede ser bilateral o unilateral y, en cualquiera de los casos, existen sutiles diferencias en su construcción si la población origen es finita o si es infinita.


Un intervalo de confianza, si es bilateral, se expresa mediante dos valores: L_{inf} (límite inferior) y L_{sup} (límite superior), de tal manera que la siguiente proposición de probabilidad es verdadera:

$$P(L_{inf} \leq \theta \leq L_{sup}) = 1 - \alpha$$


El intervalo de confianza resultante se conoce como intervalo de confianza de $100(1 - \alpha)\%$ para el parámetro desconocido θ (por ejemplo, intervalo de confianza de 95%). Las cantidades L_{inf} y L_{sup} reciben los nombres de **límites de confianza inferior y superior**, respectivamente.


Si es unilateral presenta solamente uno de los límites y el otro extremo es infinito o menos infinito.

Intervalo de confianza Bilateral




Intervalo de confianza Inferior





Si se recopilara un número infinito de muestras aleatorias y se calculara un intervalo de confianza del $n\%$ para cierto parámetro para cada una de las muestras, entonces ese porcentaje de esos intervalos contendría el verdadero valor de dicho parámetro. Por ejemplo, si se construye un intervalo de confianza del 90%, ese porcentaje de las posibles muestras generaría un intervalo de confianza que contenga el verdadero valor.

Aunque ya se había mencionado antes, es muy importante aclarar que error y margen de error no es lo mismo. El margen de error es algo que se fija antes de seleccionar la muestra y el error se encuentra después de calcular el intervalo de confianza; el margen de error es un máximo, por lo que el error (que es la mitad de la diferencia entre los límites del intervalo de confianza) debe ser menor o igual.



Obviamente, entre más amplio sea el intervalo de confianza, mayor es la seguridad de que realmente el intervalo contenga el verdadero valor, pero se aumenta el error. Lo ideal es, entonces, un intervalo de confianza relativamente pequeño con una confianza grande, lo que se logra aumentando el tamaño de la muestra evaluada.

Al interpretar un intervalo de confianza debe nombrarse el nivel de confianza; también es absolutamente necesario que se diga que es una estimación y no afirmar algo rotundamente. Por ejemplo, si con un nivel de confianza de 90% se obtuvo un intervalo de confianza para la media entre 5 y 6,25 millones de dólares para el monto de exportaciones de empresas colombianas a Grecia en el próximo año, debe aclararse ese nivel de confianza, que es un promedio y que se trata de una estimación.

Errores comunes en la interpretación de intervalos de confianza:

- No mencionar el nivel de confianza.
- No mencionar que es un promedio o una proporción.
- No mencionar que se trata de una estimación.
- Asegurar que los valores para los elementos variarán entre los valores del intervalo de confianza.
- No mencionar claramente la población objeto de estudio o extrapolar resultados.
- Decir que esa estimación es para los elementos de la muestra, ya que es para todos los elementos de la población. La información para los elementos muestrales no se estima, sino que puede hallarse exactamente por medio de la Estadística Descriptiva.

Se presentarán métodos para encontrar intervalos de confianza para medias y proporciones. Para aplicar dichos métodos, al igual que los de prueba de hipótesis, debe garantizarse que los datos tengan una distribución aproximadamente normal.

3.1.1 ESTIMACIÓN DE LA MEDIA DE UNA POBLACIÓN

Para estimar μ , el estadístico utilizado es $\bar{X}$, lo que significa que la media poblacional se estima a partir de la media muestral.

Inicialmente se fija el nivel de confianza. Lo ideal es que este intervalo sea lo más pequeño posible; por ello lo mejor es tomarlo simétrico con respecto a la media ya que allí es donde se acumula más masa en una distribución normal. Así, las dos colas de la distribución (zonas más alejadas de la media) tendrán áreas iguales.

La construcción de un intervalo de confianza se basa en la distribución de las medias muestrales. Si la muestra tomada no es muy pequeña, tal distribución se fundamenta en el **Teorema del límite**

central, que afirma que:

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

Dicho teorema demuestra, de acuerdo con Anderson (2016) que la distribución de las medias muestrales se puede aproximar con una distribución normal de probabilidades cuando el tamaño de la muestra es de por lo menos 30 elementos (p. 315)

La diferencia con el Z planteado en el capítulo anterior es muy sencilla: es mucho más difícil hallar un valor de la media alejado de la media poblacional en una muestra que para un valor individual; mirémoslo con un ejemplo:

EJEMPLO 7

Una empresa fabrica focos que tienen una duración con media de 800 horas y desviación estándar de 35 horas.

- a) Encuentre la probabilidad de que un foco que alguien compró dure menos de 780 horas.
- b) Encuentre la probabilidad de que una muestra de 50 focos tenga una vida promedio de menos de 780 horas.

Solución:

a)

$$Z = \frac{780 - 800}{35} = -0,57 \quad \leftrightarrow \quad P(X < 780) = 0,2843$$

b)

$$Z = \frac{780 - 800}{35/\sqrt{50}} = -4,04 \quad \leftrightarrow \quad P(\bar{X} < 780) = 2,67 * 10^{-5}$$

Conclusión: que un foco de esa empresa tenga una duración tan corta es poco probable, pero que una muestra relativamente grande tenga un promedio de duración tan bajo es casi imposible.

La construcción de un intervalo de confianza se basa en la distribución de las medias muestrales. La siguiente plantilla permite el cálculo de intervalos de confianza; se presenta dicha plantilla porque Excel no permite calcular directamente todos los tipos de intervalos.

Cálculo Intervalos de confianza

<https://www.youtube.com/watch?v=g0LRNj1xFwA>

EJEMPLO 8

Diez meses después de inaugurado el establecimiento, los dueños deciden hacer una encuesta para evaluar el nivel de satisfacción de sus clientes con el servicio que brindan. Pidieron calificar el servicio de 0 a 10 (0 implica un pésimo servicio y 10 un excelente servicio); las calificaciones asignadas por los clientes se ven en el archivo de Excel.

Calificaciones servicio

Construya un intervalo de confianza de 90% para la calificación promedio.

Solución:

A partir de los datos se calcula una calificación promedio de 7,727 con una desviación estándar de 1,919.

Media	7,727
Desv. Estándar	1,919
Alfa	10%
Tamaño muestra	271

INTERVALO DE CONFIANZA BILATERAL	
POBLACIÓN INFINITA	
Intervalo de confianza para la media	
Límite Inferior	7,54
Límite Superior	7,92
Error	0,19

Se determina, entonces, que con un nivel de confianza de 90% se estima que los clientes del establecimiento (en general, no los encuestados) evalúan el servicio prestado con una calificación promedio que está entre 7,54 y 7,92.

Cuando el tamaño de la muestra es pequeño (menos de 30 unidades) debe emplearse otro procedimiento porque “si se utilizan muestras pequeñas el riesgo de inferir estadísticos falsos es mayor” (Hoyos, 2010, pág. 174); para producir un intervalo de confianza válido debe hacerse una hipótesis más fuerte con respecto a la población de interés y es que ella está distribuida normalmente. Esto conduce a intervalos de confianza basados en la **distribución t de Student**.

La apariencia de la curva t es similar a la distribución Normal (también es simétrica y unimodal), pero tiene colas más amplias que la normal. La distribución t depende de un parámetro denominado **grados de libertad**, que corresponde al tamaño de la muestra menos una unidad (por ejemplo, si la muestra es de 20 elementos el número de grados de libertad es 19); a medida que aumenta el número de grados de libertad, la distribución t se aproxima más a la distribución normal.

Para hallar valores t se emplea la función **INV.T**, la cual devuelve el inverso de la distribución acumulativa t. Los únicos argumentos solicitados son Probabilidad y Grados de libertad. Para mayor facilidad todo el procedimiento se incluye también en la plantilla.

EJEMPLO 9

Una pequeña empresa dedicada a la producción y comercialización de guacamole desea estudiar los precios de sus competidores de la misma ciudad, para lo cual reunió los precios de 16 de ellos para envases de guacamole de 200 gramos. En la tabla siguiente están dichos precios en COP:

Precios guacamole

Determine un intervalo de confianza de 95% para el precio promedio de los envases de guacamole de 200 gramos.

Solución:

Media	5320
Desv. Estándar	614,84
Alfa	5%
Tamaño muestra	16

INTERVALO DE CONFIANZA BILATERAL	
POBLACIÓN INFINITA	
Intervalo de confianza para la media	
Límite Inferior	4992
Límite Superior	5648
Error	328

Con un nivel de confianza de 95% se estima que el precio promedio en que las empresas de la ciudad venden los envases de guacamole de 200 gramos está entre \$4992 y \$5648.

Debe tenerse muy presente que este intervalo de confianza supone que el muestreo se hace sobre una población normal; esta hipótesis es válida en muchas situaciones prácticas, pero si es muy alejada de la realidad deben emplearse métodos diferentes que no están considerados dentro del alcance de este libro.

3.1.2. ESTIMACIÓN DE LA PROPORCIÓN POBLACIONAL

Si queremos estimar el parámetro p , nos debemos basar en un experimento binomial.

Además, se debe tomar como estimador puntual de p la proporción de éxitos obtenidos en las n pruebas, es decir:

$$\hat{p} = \frac{X}{n}$$

La distribución del número de éxitos es binomial, y puede ser aproximada a la normal cuando el tamaño de la muestra n es grande y p no es una cantidad muy cercana a cero o uno.

EJEMPLO 10

En la encuesta en que se hizo la pregunta sobre la evaluación del servicio también se hizo la siguiente pregunta: ¿Estaría dispuesto a adquirir su producto a través de una aplicación móvil?

Aplicación móvil

Determine intervalo de confianza de 90%. Luego determine intervalo de confianza de 95%, suponiendo que la proporción de clientes que utilizarían la aplicación es la misma y que también es igual el tamaño de la muestra usada.

Solución:

La variable estudiada es cualitativa, por lo que el intervalo de confianza a establecer es para proporciones.

La proporción muestral (estimación de p) de los clientes que dijeron que sí usarían la aplicación es:

$$\hat{p} = \frac{94}{271} = 0,3469 \text{ (34,69\%)}$$

Estimación de p	34,69%
Estimación de q	65,31%
Alfa	10,0%
Tamaño muestra	271

POBLACIÓN INFINITA	
INTERVALO DE CONFIANZA BILATERAL	
Intervalo de confianza para la proporción	
Límite Inferior	29,9%
Límite Superior	39,4%

Lo anterior indica que se puede tener un “90% de confianza” de que entre el 29,9 y el 39,4% de todos los clientes del establecimiento estarían dispuestos a adquirir su producto a través de una aplicación móvil.

Estimación de p	34,69%
Estimación de q	65,31%
Alfa	5,0%
Tamaño muestra	271

POBLACIÓN INFINITA	
INTERVALO DE CONFIANZA BILATERAL	
Intervalo de confianza para la proporción	
Límite Inferior	29%
Límite Superior	40,4%

Y se puede tener un “95% de confianza” de que entre el 29 y el 40,4% de los clientes estarían dispuestos a conseguirlos de esa manera.

Según lo que se había dicho, el error para el intervalo de 90% de confianza es 4,75% $((39,4-29,9)/2)$ y el error para el intervalo de 95% es 5,7% $((40,4-29)/2)$.

¡PIENSA!

Por definición el error no debe ser mayor que el margen de error en un caso específico. ¿Por qué en el último caso el error en el intervalo de confianza es superior a 5%?

Puede concluirse, entonces, que la precisión y el nivel de confianza están relacionados en forma inversa, lo que indica que al aumentar el nivel de confianza disminuye la precisión. Esto equivale a señalar que cuando se incrementa el nivel de confianza, el intervalo de confianza se torna más amplio y, por lo tanto, dice menos sobre el parámetro que se quiere estimar.

EJEMPLO 11

Se va a hacer una encuesta para conocer qué porcentaje de las *mipymes* de alimentos de Sabaneta están exportando parte de su producción.

a) Se identificó que en Sabaneta hay 563 *mipymes* de alimentos; si en los resultados se quiere tener un nivel de confianza de 90% y un margen de error de 5%. ¿Cuál debe ser el tamaño de la muestra a utilizar?

b) Si ya se hizo esa encuesta y se encontró que el 35,7% de esas empresas están exportando. Establezca un intervalo de confianza de 90% para la proporción de *mipymes* de Sabaneta que exportan.

Solución:

a)

Tamaño población	563
Prob. de ocurrencia	0,5

Margen de error	Nivel de confianza		
	99%	95%	90%
1,00%	545	532	520
1,50%	524	498	475
2,00%	496	457	423
2,50%	465	413	371
3,00%	432	369	323
3,50%	398	328	280
4,00%	366	291	242
4,50%	334	258	210
5,00%	305	229	183

b)

Estimación de p	35,7%
Estimación de q	64,3%
Alfa	10,0%
Tamaño muestra	183

INT. DE CONF. BILATERAL - POBLACIÓN FINITA	
Tamaño de la población	563
Intervalo de confianza para la proporción	
Límite Inferior	30,9%
Límite Superior	40,5%

Es posible obtener intervalos de confianza unilaterales para μ haciendo $L_{\text{inf}} = -\infty$ o $L_{\text{sup}} = +\infty$ y ubicando alfa a un solo lado. Estos intervalos se incluyen en la misma plantilla que viene manejándose.

EJEMPLO 12

Una entidad bancaria seleccionó una muestra aleatoria de 30 días y registró el número de reclamos de sus usuarios en cada uno de ellos. Dichos registros fueron:

Reclamos de usuarios

Establezca un intervalo de confianza unilateral, de tal manera que tenga una confianza aproximada de 90% de que el promedio de reclamos diarios en la entidad no supere un valor determinado.

Solución:

Media	21,2
Desv. Estándar	6,332
Alfa	10%
Tamaño muestra	30

POBLACIÓN INFINITA	
Intervalo de confianza superior para la media	
Límite Inferior	infinito negativo o cero
Límite Superior	22,68

Es decir, se tiene una confianza de 90% en que el promedio de reclamos no supera los 22,7 por día.

EJEMPLO 13

Se va a hacer una encuesta para conocer qué porcentaje de las mipymes de alimentos de Sabaneta están exportando parte de su producción. Se identificó que en Sabaneta hay 563 mipymes de alimentos; en los resultados se quiere tener un nivel de confianza de 90% y se identificó anteriormente que la muestra a usar debe ser por lo menos de 183 empresas

Si ya se hizo esa encuesta y se encontró que el 35,7% de esas empresas están exportando. Establezca un intervalo de confianza unilateral inferior de 90% para la proporción de mipymes de Sabaneta que exportan.

Solución:

Estimación de p	35,7%
Estimación de q	64,3%
Alfa	10,0%
Tamaño muestra	183

POBLACIÓN FINITA	
Tamaño de la población	563
Intervalo de confianza inferior para la proporción	
Límite Inferior	32,0%
Límite Superior	infinito positivo

Es decir, se tiene una confianza de 90% en que la proporción de las mipymes de alimentos de Sabana que están exportando parte de su producción es por lo menos del 32%.

Nota: Debería evitarse la estimación de proporción con la distribución t porque cuando son muy pocos elementos no deberían calcularse porcentajes.


3.2. PRUEBAS DE HIPÓTESIS CON UNA POBLACIÓN

Una hipótesis se define como una explicación tentativa o suposición adoptada provisionalmente para explicar ciertos hechos y guiar la investigación de otros; en palabras sencillas, es algo que se afirma antes de reunir datos.

La hipótesis es llamada estadística si consiste en un enunciado respecto a un parámetro de una o más poblaciones como media, desviación estándar o proporción.

Si se quiere probar la validez de la hipótesis se lleva a cabo un experimento y la hipótesis es rechazada si los valores obtenidos para el equivalente muestral del parámetro son tan grandes o tan pequeños que la probabilidad de que ocurran si la hipótesis es cierta es bastante remota; si los datos son muy probables, la hipótesis es “no rechazada”. Eso implica que se rechaza una hipótesis cuando la probabilidad de obtener los resultados que se observan en la muestra es muy pequeña si la hipótesis es verdadera o, dicho de otra forma, si la hipótesis nula fuera verdadera la diferencia entre la característica muestral y la característica hipotética equivalente debería ser pequeña, de tal manera que dicha diferencia pueda ser atribuible al azar.

Para hacer una prueba de hipótesis deben llevarse a cabo ciertos procedimientos, que son detallados en el siguiente esquema:



- **Identificar parámetro de interés:** lo primero que debe hacerse es establecer claramente, según el contexto, cuál es el parámetro de interés (si es la proporción, la media o la desviación estándar).

- **Plantear la hipótesis nula y la alternativa:** en cualquier investigación deben plantearse dos hipótesis, que se denominan **hipótesis nula** (H_0) e **hipótesis alternativa** (H_1) y que de alguna manera reflejarán esa idea *a priori* que tenemos y que pretendemos contrastar con la “realidad”.

La hipótesis nula se denomina así por ser el punto de partida y siempre debe incluir una igualdad; es la hipótesis que se trata de contrastar, de forma que al final del proceso, la rechazaremos o no. La hipótesis alternativa es el complemento de la nula; por lo tanto, el rechazo de la hipótesis nula supone el no rechazo de la hipótesis alternativa (o viceversa).

Según lo anterior, la hipótesis nula puede ser con $=$, $\leq$ o $\geq$. En los respectivos casos, la hipótesis alternativa debe ser con $\neq$, $>$ o $<$.

EJEMPLO 14

Hipótesis 1: EL 20% de las empresas colombianas exportan a Estados Unidos o a países europeos.

$$H_0: p = 20\% \quad H_1: p \neq 20\%$$

Hipótesis 2: AL MENOS EL 20% de las empresas colombianas exportan a Estados Unidos o a países europeos

$$H_0: p \geq 20\% \quad H_1: p < 20\%$$

Hipótesis 3: NO MÁS DEL 20% de las empresas colombianas exportan a Estados Unidos o a países europeos

$$H_0: p \leq 20\% \quad H_1: p > 20\%$$

La única manera de asegurar la veracidad o falsedad de una hipótesis estadística con certeza absoluta consiste en evaluar toda la población. Como lo que se hace generalmente es tomar una muestra, solamente puede hablarse de sospechas y, por ende, siempre existe la posibilidad de una conclusión errónea. El rechazo de H_0 significa simplemente que hay una pequeña probabilidad de obtener la información muestral observada cuando, de hecho, la hipótesis es verdadera y no necesariamente que dicho planteamiento sea falso.

La decisión de rechazar o no la hipótesis nula está basada en la elección de una muestra tomada al azar y por tanto es posible tomar decisiones erróneas. Los errores que se pueden cometer se clasifican como sigue:

- Si se rechaza la hipótesis nula cuando realmente es verdadera. Esto se conoce como error tipo I; la probabilidad de cometerlo se simboliza con α (alfa) y es lo que se conoce como nivel de significancia.

- Si no se rechaza la hipótesis nula cuando realmente es falsa. Esto se conoce como error tipo II y la probabilidad de cometerlo se denota como β .

En lenguaje estadístico:

$$\alpha = P(\text{error tipo I}) = P(\text{rechazar } H_0 \mid H_0 \text{ es V})$$

$$\beta = P(\text{error tipo II}) = P(\text{aceptar } H_0 \mid H_0 \text{ es falsa})$$

Los errores tipo I y II están relacionados: una disminución en la probabilidad de cometer uno de ellos siempre da como resultado un aumento en la probabilidad del otro, siempre que el tamaño muestral sea constante. En general, si el tamaño de muestra se aumenta, se reducen tanto α como β .

EJEMPLO 15

Una agencia de viajes planea desarrollar una propaganda para televisión si el promedio de clientes es por lo menos 15 al día en temporada fría. Para estimar dicho promedio, tomó una muestra aleatoria de 25 días de estos últimos tres meses (temporada fría); los datos que encuentre se usarán para probar las siguientes hipótesis: $H_0: \mu \geq 15$; $H_1: \mu < 15$

a) ¿Cuál es el error de tipo I en este caso? ¿Cuáles serían sus consecuencias?

b) ¿Cuál es el error de tipo II en este caso? ¿Cuáles serían sus consecuencias?

Solución:


a) Existe un error de tipo I cuando se concluye que dicho promedio no es mayor o igual a 15 clientes cuando realmente lo es. Podría perderse la oportunidad de proyectar el comercial y ganar nuevos clientes.

b) Existe un error de tipo II cuando se concluye que dicho promedio es mayor o igual a 15 clientes cuando realmente no lo es. En ese caso, se proyectará el comercial cuando el plan inicial indica que no se justificaría.

- **Seleccionar nivel de significancia (alfa):** es la probabilidad de rechazar la hipótesis nula cuando realmente es verdadera. Se elige subjetivamente (no es producto de ningún cálculo), pero debe ser un valor bajo, generalmente 5 o 10%.

- **Formular la regla de decisión:** con base en el nivel de significancia, en el valor hipotético del parámetro y asumiendo que los datos poblacionales siguen una distribución normal, deben establecerse una región crítica (o de rechazo) y una región de aceptación. Si la muestra que se toma es muy pequeña (de tamaño inferior a 30) no debe utilizarse la distribución normal, sino la distribución t de Student.

La prueba de hipótesis debe hacerse bilateral si es importante detectar diferencias a partir del valor hipotético del parámetro que se encuentren a su derecha o a su izquierda; en este caso la hipótesis alternativa se plantea con $\neq$, por ejemplo, $\mu \neq \mu_0$. En una prueba de este tipo, la región crítica se separa en dos partes, generalmente con la misma probabilidad en cada cola, por lo que el nivel de significancia se divide en ambos extremos.





La región correspondiente a la zona de aceptación (región azul claro) puede calcularse con la función **INV.NORM.ESTAND** si la muestra usada es de 30 elementos o más y se va a presentar la región en términos de valores Z; el único argumento de esta función es la probabilidad. El límite inferior se halla con una probabilidad de $\alpha/2$ y el límite superior de dicha región, con una probabilidad de $1-\alpha/2$. Por ejemplo, si el nivel de significancia es 10%, el límite inferior se halla con una probabilidad de 5% y el límite superior se halla con una probabilidad de 95%. En dicho caso la región de aceptación está dada por la zona comprendida entre los siguientes valores de Z:

$(-1,645 \text{ y } 1,645)$, la región crítica de la izquierda está dada por la región

$(-\infty, -1,645)$ y la región crítica de la derecha está dada por la región $(1,645, \infty)$.

Si la muestra es de menos de 30 elementos debe usarse la función **INV.T**, que, como se había mencionado antes, además de probabilidad tiene también como argumento los grados de libertad ($n - 1$). Entonces, si por ejemplo el nivel de significancia es 10% y la muestra tiene 15 elementos, el límite inferior de la región de aceptación se calcula con probabilidad de 5% y 14 grados de libertad; eso significa que el límite inferior es -1,761; el límite superior es 1,761. Eso implica que la región de aceptación es $(-1,761 \text{ a } 1,761)$ y las regiones críticas son $(-\infty \text{ a } -1,761)$ y $(1,761 \text{ a } \infty)$.

Ahora, si la afirmación implica alguna dirección, es decir, si lo que se quiere demostrar es que el parámetro es mayor o menor que un determinado valor, lo apropiado es hacer una prueba unilateral. Si la hipótesis nula es $\mu > \mu_0$, la región de rechazo debe encontrarse en la cola inferior y, si es $\mu < \mu_0$, la región crítica se encontrará en la cola superior, así:



Si la prueba es de cola superior para hallar la región de aceptación solo se encuentra el límite superior, pues dicha región empieza en menos infinito ($-\infty$); dicho límite se encuentra usando la función **INV.NORM.ESTAND** con probabilidad $1-\alpha$, ya que en este caso α no se reparte en dos regiones. Esto se aplica si la muestra es de por lo menos 30 elementos; si tiene menos debe usarse la función **INV.T** y tener en cuenta los grados de libertad.

Si la prueba es de cola inferior la región de aceptación no tiene límite superior; el límite inferior se encuentra con las funciones **INV.NORM.ESTAND** o **INV.T** (según el tamaño de la muestra) con probabilidad igual al valor de α .

EJEMPLO 16

Plantear las regiones de aceptación de las pruebas de hipótesis en cada uno de los siguientes casos. Para todos debe considerarse un nivel de significancia de 5% y que se usa una muestra de 50 elementos:

Hipótesis nula 1: EL 20% de las empresas colombianas exportan a Estados Unidos o a países europeos.

Solución: La prueba debe ser bilateral. Los límites de la región de aceptación se encuentran así:

LÍMITE INFERIOR
Función: INV.NORM.ESTAND
Probabilidad: 2,5%
Lím. Inferior: -1,96

LÍMITE SUPERIOR
Función: INV.NORM.ESTAND
Probabilidad: 97,5%
Límite superior: 1,96

Región de aceptación: $(-1.96, 1.96)$

Hipótesis nula 2: Al menos el 20% de las empresas colombianas exportan a Estados Unidos o a países europeos.

Solución: La prueba debe ser unilateral de cola inferior. En la parte superior la región de aceptación no tiene límite; el límite inferior se encuentra así:

LÍMITE INFERIOR
Función: INV.NORM.ESTAND
Probabilidad: 5%
Lím. Inferior: -1,645

Región de aceptación: $(-1.645, \infty)$

La región de aceptación también puede calcularse en términos de la variable, mediante el establecimiento de valores críticos; eso se explicará detalladamente cuando se estudie la plantilla Pruebas de Hipótesis.

No es necesario hacer una prueba de hipótesis cuando los resultados muestrales no caen en el lado de la región crítica, es decir, cuando confirman directamente lo manifestado por la hipótesis nula. En este caso se concluye directamente que la hipótesis nula no debe rechazarse, aunque en realidad no debería descartarse que pueda deberse a un error muestral. Por ejemplo, si se lanza la hipótesis de que la calificación promedio dada por los clientes al servicio es por lo menos 8 y en la muestra se encuentra un promedio de 8.14; o si se lanza la hipótesis de que la calificación promedio es menor o igual a 8 y en la muestra se obtiene un promedio de 7.75.

- **Tomar una muestra, calcular estadístico de prueba, comparar y decidir:** finalmente debe tomarse una muestra, preferiblemente aleatoria para garantizar una buena estimación de los parámetros poblacionales, y se calculan los datos necesarios para el contraste, es decir, la media de la muestra o su proporción (también podría ser su desviación estándar, pero no se está considerando el caso).

De acuerdo a la hipótesis que se esté probando, el estadístico de prueba puede ser:

$$\frac{\bar{X} - \mu}{\sigma_{n-1}/\sqrt{n}} \quad \text{(para media)}$$

$$\frac{\hat{p} - p}{\sqrt{\frac{p \cdot q}{n}}} \quad \text{(para proporción)}$$

Debe comprobarse si el resultado del estadístico de prueba cae en la región crítica o en la de aceptación y, según eso, se rechaza o no la hipótesis nula, respectivamente.

La decisión de rechazar o no la hipótesis nula puede variar según el nivel de significancia elegido; por eso en algunos casos es importante evaluar la contundencia de la prueba, lo cual puede hacerse mediante el **valor p**, que es la probabilidad de obtener un valor para el estadístico de prueba tan improbable o más improbable que el obtenido con la muestra; por lo tanto el **valor p** es el nivel de significancia más bajo que llevaría al rechazo de la hipótesis nula. Eso significa que cuanto más pequeño sea el **valor p**, mayor será la evidencia a favor de la hipótesis alternativa (en contra de la hipótesis nula).

Si la decisión se basa en un valor p no es necesario establecer región crítica; se rechaza la hipótesis nula si el **valor p** es menor o igual que el nivel de significancia que se desea porque ambas cosas conducen a lo mismo; sin embargo, en la plantilla se incluyen ambas para inducir ambos conceptos. Por ejemplo, si en un caso determinado el **valor p** es 8,5%, la hipótesis nula se rechaza con un nivel de significancia de 10%, pero no debe rechazarse con un nivel de significancia de 5%.

Si por ejemplo el valor p es 0,0003 (0,03%) significa que si la hipótesis nula fuera cierta obtendríamos aproximadamente 3 de cada 10000 veces un valor tan extremo o más extremo que el que hayamos obtenido en la muestra recolectada.

En palabras de Kelmansky (2009) el nivel de significancia identifica “qué tan pequeño debe ser el valor p para declarar que la diferencia entre el valor especificado en la hipótesis nula y el valor observado es estadísticamente significativa” (p. 237). Por eso la expresión clave en una prueba de hipótesis es “**diferencia estadísticamente significativa**”, es decir, puede suceder que con dos muestras diferentes no se alcance el valor sugerido por la hipótesis, pero que una conduzca al rechazo de la hipótesis nula y la otra no, debido a que una diferencia sea significativa y la otra se declare como poco significativa porque podría ser debida al proceso de muestreo; con el primer ejemplo se mostrará este hecho numéricamente.

La plantilla que se presenta a continuación permite el desarrollo de pruebas de hipótesis; se presenta dicha plantilla porque Excel solo permite la realización directa de algunas pruebas.

Pruebas de Hipótesis

<https://www.youtube.com/watch?v=HE49cAZXLCg>

Nota: En la plantilla también se destacan los valores críticos superior e inferior para medias y proporciones; dichos valores corresponden a la región de aceptación, no en términos de Z , sino en las unidades de los valores originales.

EJEMPLO 17

Antes de la prueba donde los clientes calificaron el servicio en el establecimiento con una nota entre 0 y 10 los dueños suponían que el servicio iba a ser evaluado con una calificación promedio de 8,5 o superior. Pruebe dicha hipótesis con un nivel de significancia de 5%.

a) Con la muestra dada anteriormente.

Calificaciones servicio

b) Con una muestra que tiene la misma desviación estándar, pero cuyo promedio es 8,33.

Solución:

$H_0: \mu \geq 8,5$ (Los dueños suponen que la calificación promedio va a ser 8,5 o superior)

$H_1: \mu < 8,5$

a) La calificación promedio fue 7,727 con una desviación estándar de 1,919.

Como la hipótesis nula es con mayor o igual, la prueba que debe hacerse es de cola inferior.

PRUEBA DE COLA INFERIOR PARA MEDIA	
DISTRIBUCIÓN NORMAL (MUESTRA GRANDE)	
n	271
Media muestra	7,727
Desv. estándar	1,919
Alfa	5%
Media Hip	8,5
Estadístico de prueba	-6,631154774
Decisión	RECHAZAR HO
Valor p	0,000000002%

Con un nivel de significancia de 5% se concluye que la calificación promedio no es la que los dueños suponían inicialmente. Como el valor p es muy inferior al valor de alfa (nivel de significancia) puede considerarse que el rechazo de la hipótesis nula es muy contundente.

b)

PRUEBA DE COLA INFERIOR PARA MEDIA	
n	271
Media muestra	8,33
Desv. estándar	1,919
Alfa	5%
Media Hip	8,5
Estadístico de prueba	-1,458339342
Decisión	NO RECHAZAR HO
Valor p	7,2%

Con un nivel de significancia de 5% se concluye que la calificación promedio es la que los dueños suponían inicialmente; sin embargo, la prueba no es muy contundente, ya que el *valor p* supera por muy poco el valor de alfa y en este caso no debe rechazarse la hipótesis nula con un alfa de 5%, pero

si por ejemplo el alfa fuera 10% ya sí sería rechazada porque ya alfa es mayor que el *valor p*. Mirémoslo cuantitativamente:

PRUEBA DE COLA INFERIOR PARA MEDIA	
n	271
Media muestra	8,33
Desv. estándar	1,919
Alfa	10%
Media Hip	8,5
Estadístico de prueba	-1,458339342
Decisión	RECHAZAR HO
Valor <i>p</i>	7,2%

EJEMPLO 18

Los dueños del Establecimiento aseguran que el 80% de los clientes califican el servicio como bueno. Probar esa afirmación a partir de una prueba de hipótesis con base en el archivo que se presenta a continuación y un nivel de significancia de 10%

Calificación clientes propios

Solución:

Ho: $p = 80\%$

H1: $p \neq 80\%$

PRUEBA DE DOS COLAS PARA PROPORCIÓN	
n	281
Proporción muestra	70,82%
Alfa	10%
Proporción hip	80%
Estadístico de prueba	-3,847121034
Decisión	RECHAZAR HO
Valor p	0,012%

Con un nivel de significancia de 10% puede afirmarse que la proporción es estadísticamente diferente a la que suponen los dueños; el valor p indica que si la hipótesis nula fuera verdadera la probabilidad de encontrar una muestra de ese tamaño con esa proporción de clientes que califiquen el servicio como bueno sería 0,012%.

EJEMPLO 19

Una firma comisionista de bolsa estima que el volumen promedio de sus transacciones por día es de 1100 millones de pesos colombianos; para verificarlo recolectó la información de los últimos 20 días. Las cantidades están dadas en millones de pesos colombianos y están dadas en la siguiente base de datos:

Firma comisionista

Desarrolla una prueba de hipótesis para verificar lo dicho previamente.

Solución:

$H_0: \mu = \$1100$ millones de pesos

$H_1: \mu \neq \$1100$ millones de pesos

Se debe hacer una prueba para media con población infinita y debe usarse la distribución t porque la muestra es de menos de 30 elementos.

PRUEBA DE DOS COLAS PARA MEDIA	
n	20
Media muestra	1057,9975
Desv. estándar	305,896411
Alfa	
Media Hip	1100
Estadístico de prueba	-0,614066997
Decisión	#¡NUM!
Valor p	54,6%

Conclusión: la hipótesis no debe rechazarse para ninguno de los niveles de significancia habituales.

3.3. PRUEBA DE HIPÓTESIS CON DOS POBLACIONES

3.3.1. PRUEBA DE HIPÓTESIS DE LA DIFERENCIA DE PROPORCIONES

No es poco común que quiera establecerse el contraste de dos proporciones para establecer si son similares o si una sí supera a la otra por la diferencia que se supone; por ejemplo, si se quiere comparar el porcentaje de producción defectuosa de dos máquinas: puede ser que quiera comprobarse si las proporciones de defectuosos son estadísticamente iguales o si la proporción de defectuosos de la máquina A supera por lo menos en 2% (por ejemplo) a la proporción en la máquina B.

Prueba de dos colas: $H_0: p_1 - p_2 = d_0$

$$H_1: p_1 - p_2 \neq d_0$$

Prueba de cola inferior: $H_0: p_1 - p_2 \geq d_0$ $H_1: p_1 - p_2 < d_0$

Prueba de cola superior: $H_0: p_1 - p_2 \leq d_0$ $H_1: p_1 - p_2 > d_0$

De manera similar a los anteriores casos, en cualquiera de las pruebas debe calcularse un estadístico de prueba; en esta ocasión, el estadístico de prueba se basa en la diferencia de las dos proporciones muestrales y se mide de esta forma:

$$\frac{(\hat{p}_1 - \hat{p}_2) - d_0}{\sqrt{\hat{p}\hat{q}\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$$

Donde d_0 es la diferencia hipotética entre las proporciones poblacionales y

$$\hat{p} = \frac{x_1 + x_2}{n_1 + n_2}$$

EJEMPLO 20

Supóngase que en el establecimiento que se viene evaluando hicieron la encuesta sobre la calificación de los clientes al servicio prestado, pero las respuestas posibles eran únicamente “Bueno”, “Regular” o “Malo”; una encuesta similar se hizo en un negocio de la competencia. Pruebe la hipótesis de que entre los dos establecimientos no hay diferencia en la proporción de personas que califican el servicio como malo.

Los datos de las encuestas están en el siguiente archivo:

[Calificaciones propio-competencia](#)

Solución:

$$H_0: p_1 - p_2 = 0$$

$$H_1: p_1 - p_2 \neq 0$$

En el propio calificaron mal 15 de 281, mientras que en la competencia califican mal 16 de 150; debes comprobarlo mediante Estadística Descriptiva.

PRUEBA DE DOS COLAS

x1	15
x2	16
Tamaño de muestra 1	281
Tamaño de muestra 2	150
Estimación de p1	5,34%
Estimación de p2	10,67%
Estimación de q1	94,66%
Estimación de q2	89,33%
Diferencia hipotética	0,0%
Estadístico de prueba	-2,040
Valor p	4,1%

Como no se proporciona un valor de alfa, la prueba se basa en el valor p. Los valores de alfa son generalmente 5 o 10% y el valor p es inferior; eso nos lleva a pensar que las dos proporciones no deben considerarse similares.

3.3.2. PRUEBA DE HIPÓTESIS DE LA DIFERENCIA DE MEDIAS

Pueden presentarse dos situaciones diferentes: diseño de muestras pareadas y diseño de muestras independientes.

3.3.2.1. DISEÑO DE MUESTRAS PAREADAS

En este caso, cada unidad experimental recibe ambas condiciones poblacionales. Por ejemplo, para probar la eficacia de una capacitación a los técnicos de una empresa pueden evaluarse los tiempos para hacer una determinada tarea antes y después de la capacitación a cada uno de los individuos de una muestra.

Para la prueba de hipótesis, el interés recae sobre la distribución de las diferencias en el valor calculado. Para expresarlo más formalmente, se investiga si la media de la distribución de las diferencias de los valores calculados es 0 (si se supone igualdad) o cualquier otro valor hipotético; por lo tanto, la muestra se construye de las diferencias para cada unidad experimental.

$$\text{Prueba de dos colas: } H_0: \bar{d} = d_0$$

$$H_1: \bar{d} \neq d_0$$

$$\text{Prueba de cola inferior: } H_0: \bar{d} \geq d_0 \quad H_1: \bar{d} < d_0$$

$$\text{Prueba de cola superior: } H_0: \bar{d} \leq d_0 \quad H_1: \bar{d} > d_0$$

El estadístico de prueba es:

$$t = \frac{\bar{d} - d_0}{S_d / \sqrt{n}},$$

donde $\bar{d}$ es la media de las diferencias, S_d es su desviación estándar, n es el número de observaciones y d_0 es la diferencia hipotética.

EJEMPLO 21

Al personal del Establecimiento le imparten unas charlas de atención al cliente. Luego se hizo una encuesta a 15 clientes asiduos y se les pidió que calificaran el servicio; esos mismos clientes habían calificado el servicio antes del proceso de capacitación. Eso se hizo con el fin de evaluar si el proceso había surtido efecto; los dueños considerarán que el proceso fue eficaz si el promedio de las calificaciones mejora por lo menos en 1,5. Según los datos que se presentan en el siguiente archivo, ¿podría

afirmarse que el proceso fue efectivo?

Charlas de capacitación

MUESTRAS PAREADAS	
PRUEBA DE COLA INFERIOR	
n	15
Media diferencias	0,6667
Desv. Estándar	1,04654
Alfa	
Diferencia hipotética	1,5
Estadístico de prueba	-3,083835326
Decisión	
Valor p	0,40%

La prueba demuestra que la calificación sí mejoró después de la capacitación, pero no satisfizo la expectativa inicial, por lo que el proceso no debe evaluarse como eficaz.

3.3.2.2. DISEÑO DE MUESTRAS INDEPENDIENTES

El estadístico de prueba es:

$$\frac{(\overline{X_1} - \overline{X_2}) - d_0}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Donde d_0 es la diferencia hipotética entre las medias poblacionales.

EJEMPLO 22

Como evaluación del proceso de capacitación a través de las charlas de atención al cliente se hizo el siguiente experimento: hace un mes, cuando aún no se habían brindado las charlas, se pidió a una muestra de 100 clientes que calificaran el servicio; hoy, después de las capacitaciones, se pidió a otro grupo de 100 clientes que calificaran el servicio. Si los dueños consideran que el proceso fue eficaz si el promedio de las calificaciones mejora por lo menos en 1,5 después de la capacitación, ¿podría afirmarse que el proceso fue efectivo?

Calificaciones Independiente

Hipótesis nula: $\mu_1 - \mu_2 \geq 1,5$

Hipótesis alternativa: $\mu_1 - \mu_2 < 1,5$

MUESTRAS INDEPENDIENTES
PRUEBA DE COLA INFERIOR

Media muestra 1	7,47
Media muestra 2	6,41
Diferencia hipotética	1,5
Desv. Estándar 1	1,84
Desv. Estándar 2	2,5469
Tamaño de muestra 1	100
Tamaño de muestra 2	100
Alfa	5%
Estadístico de prueba	- 1,40
Decisión	NO RECHAZAR H0
Valor p	8,0674%

La prueba muestra que la calificación sí mejoró después de la capacitación; aunque en la muestra se nota una diferencia menor que lo presupuestado, la diferencia no es estadísticamente significativa como para evaluar el proceso como ineficaz.

Es muy importante que se diferencie claramente cuándo deben considerarse muestras pareadas y cuándo muestras independientes: en el primer caso dos acciones poblacionales diferentes recaen sobre los mismos elementos, mientras que en el caso de muestras independientes las dos acciones recaen sobre elementos diferentes.

De acuerdo con todo lo expuesto anteriormente, la relación entre pruebas de hipótesis y cálculo de intervalos de confianza es muy estrecha, pues una hipótesis nula debe rechazarse si no cae dentro del intervalo de confianza para el mismo período con un alfa similar. Por ejemplo, cuando en el ejemplo 18 se menciona que “Los dueños del Establecimiento aseguran que el 80% de los clientes califican el servicio como bueno” y se pide probar esa afirmación con un nivel de significancia de 10%, una muestra de 281 elementos y una proporción muestral de 70,82%, habría sido similar calcular un intervalo de confianza con un nivel de confianza de 90% y evaluar si el 80% cae dentro del intervalo; en este caso el intervalo es (66,4% a 75,3%), lo que lleva a concluir que la hipótesis debe rechazarse. La prueba de hipótesis tiene la ventaja del valor p como evidencia del grado de contundencia de la prueba.

EJERCICIOS RESUELTOS

Te invito a que, antes de estudiar los videos donde se desarrolla cada problema, intentes resolver los ejercicios. De esta manera podrás evaluar la comprensión de los temas.

1. Desea evaluarse el grado de favorabilidad de los grandes ejecutivos colombianos frente a los tratados de libre comercio. Se hizo una encuesta a 500 de ellos en la que se indagó acerca de su actitud al respecto; los resultados se muestran en el siguiente archivo:

[Ejercicio resuelto 1 Inferencial](#)

a) Estima con un 90% de confianza su grado de favorabilidad frente a los TLC. Un censo que se desarrolló a principios de este año encontró que en el país hay 27250 grandes ejecutivos.

b) En una revista de amplia circulación nacional se afirmó la semana anterior que por lo menos el 60% de los grandes ejecutivos colombianos está a favor de los tratados de libre comercio. Según lo encontrado en la encuesta, ¿crees que es cierto lo que se dice allí? Para dar tu respuesta realiza la prueba de hipótesis correspondiente.

<https://www.youtube.com/watch?v=QyB-VxgLP6s>

2. Una empresa comercializa una bebida refrescante en un envase en cuya etiqueta se puede leer que el contenido es de 250 centímetros cúbicos. El Departamento de Consumo toma aleatoriamente 25 envases y encuentra los siguientes contenidos:

[Ejercicio resuelto 2 Inferencial](#)

a) ¿Puede afirmarse con un nivel de significancia de 5% que no se está vendiendo el contenido indicado?

b) ¿De qué tamaño debió haber sido la muestra tomada para que los resultados fueran plenamente confiables? Considera un margen de error de 5%

¡PIENSA!

- **¿Qué pasaría si el experimento no es realizado por el Departamento de Consumo sino por la empresa productora?**
- **¿Qué pasaría si la media es 246,2 centímetros cúbicos, la desviación estándar es la obtenida previamente y el nivel de significancia es 5%? ¿Qué pasa si la media y la desviación estándar de la muestra son esas pero el nivel de confianza es 10%? ¿Qué puede concluirse?**
- **Con las condiciones iniciales de nivel de significancia y desviación estándar de la muestra, ¿cuál debe ser la media muestral para que no se rechace la hipótesis nula?**

3. A los empleados de una empresa se les inscribió en una capacitación con una nueva máquina de pulido para optimizar los tiempos que tardaban en este proceso, ya que algunos clientes se quejaban por demora en la entrega de los pedidos. Los tiempos que tardaba cada empleado antes y después de la capacitación se muestran en el siguiente archivo (datos en horas).

[Ejercicio resuelto 3 Inferencial.xlsx](#)

Establece las hipótesis para verificar si la capacitación para mejorar el tiempo promedio de pulido dio resultado. Usa una significancia del 5% para hacer la prueba.

<https://www.youtube.com/watch?v=BeDzq2LTDEs>

EJERCICIOS PROPUESTOS

Inmediatamente después de los planteamientos de los ejercicios se encuentra un archivo de Excel con sus soluciones.

1. Se va a hacer una investigación entre pequeñas y medianas empresas industriales del Valle de Aburrá para evaluar sus niveles de exportación.

a) Según datos de Cámara de Comercio se estima que en el Valle de Aburrá hay 26255 empresas de ese tipo. Si en la investigación se quiere tener un nivel de confianza de 95% y un margen de error de 5%, ¿de qué tamaño debe ser la muestra elegida?

b) Se afirma que las pequeñas y medianas empresas industriales del Valle de Aburrá hacen exportaciones en promedio por 150 millones de pesos mensualmente. Se tomó una muestra del tamaño hallado en el ítem a) y se encontró un promedio de 132,5 millones de pesos y una desviación estándar de 88,7 millones de pesos. Con un nivel de significancia de 0.1, verifica la veracidad de la hipótesis lanzada.

2. Un emprendedor colombiano visitó Suiza e identificó una oportunidad de nuevo negocio. Planea, entonces, lanzar un nuevo producto alimenticio en toda Colombia.

a) Para hacer la investigación de mercado planea la realización de una encuesta. Si en los resultados se quiere tener un nivel de confianza de 90% y un margen de error de 4%; ¿cuál debe ser el tamaño de la muestra a utilizar?

b) Luego de hacer el muestreo al número de personas hallado en el ítem a) se encontró que el 17,6% mostró interés en el nuevo producto ofrecido. Establece un intervalo de confianza de 90% para la proporción de personas colombianas que comprarían el nuevo producto. Interpreta dicho intervalo. ¿Qué pasaría con el error si se mantiene el mismo tamaño de muestra, pero el nivel de confianza sube a 95%?

3. Unas estudiantes de Administración van a presentar un plan de empresa sobre la comercialización en Colombia de hojas de estevia secas y molidas.

a) Dentro de la metodología plantean la realización de una encuesta. Si en los resultados se quiere tener un nivel de confianza de 90% y un margen de error de 5%, ¿cuál debe ser el tamaño de la muestra a utilizar? ¿Qué características debe tener esa muestra que se tome?

b) Si deciden hacer la encuesta a 60 personas, ¿de qué tamaño es el margen de error si se considera ese nivel de confianza de 90%? ¿Lo consideras aceptable?

c) El mercado meta es la población de Colombia con problemas de diabetes u obesidad. Luego de hacer el muestreo al número de personas hallado en el ítem a) que tienen esas características se encontró que un 64,6% de ellas afirmó que sí consumen o consumirían el nuevo producto ofrecido. Establece un intervalo de confianza de 90% para la proporción de personas diabéticas u obesas de Colombia que consumen o consumirían estevia. Interpreta dicho intervalo.

4. Maquila de Oriente es una empresa que se encarga de cortar y distribuir piezas de tela para indumentaria deportiva. La empresa cuenta con dos máquinas automáticas para hacer los cortes de tela. Para hacer un control de calidad, se tomó una muestra de cada una de las máquinas. Las medidas de los cortes (medidos en cm) se muestran en las tablas.

Ejercicio 4_Inferencial

a) Encuentra un intervalo de confianza del 90% para la medida promedio de los cortes de cada una de las máquinas. Interpreta los resultados. Con nivel de confianza de 90% y margen de error de 5%, ¿de qué tamaño debería ser la muestra para obtener resultados confiables?

b) Un corte se considera defectuoso si mide menos de 1,44 cm o más de 1,8 cm. El mecánico encargado del mantenimiento dice que en la máquina 1 el 5% de los cortes es defectuoso y en la máquina 2 el 12% presenta defectos. Establece la hipótesis para cada máquina y utilice una significancia del 5% para validar lo que dice el mecánico. Interpreta los resultados y especifica cuáles son las regiones

de aceptación y rechazo.

5. En la siguiente tabla se registra el número de productos vendidos por una muestra de 32 de los 265 vendedores de cierta empresa durante el mes anterior:

Ejercicio 5 Inferencial

a) Determina un intervalo de confianza del 90% para la cantidad promedio de productos vendidos por cada vendedor durante el mes anterior.

b) La Gerencia lanzó la hipótesis de que los vendedores de la Empresa logran vender como máximo 1800 productos por mes en promedio. Según los resultados del mes anterior para la muestra tomada, ¿parecería que eso es cierto? Demuéstralo planteando el desarrollo de una prueba de hipótesis, utilizando un nivel de significancia de 10%.

6. Consultores en Calidad S.A.S asesora a sus clientes acerca de procedimientos estadísticos y de muestreo para el control de sus procesos de fabricación. Consultores en Calidad S.A.S hizo una asesoría a una empresa internacional fabricante de cerveza para investigar el éxito de su cerveza principal en un nuevo país; se realizó una encuesta donde se preguntaba a los consumidores si consideraban que esta cerveza importada era mejor que las marcas nacionales (ver las respuestas en la tabla)

Ejercicio 6 Inferencial

a) Para esta encuesta ¿de qué tamaño es el margen de error si se considera un nivel de confianza del 90%? ¿Lo consideras aceptable?, ¿qué propondrías para lograr el nivel de confianza mencionado?

b) Establece un intervalo de confianza de 95% para la proporción de personas de dicho país que prefieren la marca de cerveza importada. Interpreta dicho intervalo.

7. Consultores en Calidad S.A.S A realizó una asesoría a una productora de arepas, ya que algunos clientes se quejaban por demora en la entrega de los pedidos. Para disminuir el tiempo de producción se les inscribió en una capacitación en Six sigma (Metodología para mejora de procesos). El tiempo en horas que tardaba cada empleado en la fabricación de un lote de arepas antes y después de la capacitación se muestra en la tabla.

Ejercicio 7 Inferencial

a) Halla medias y coeficientes de variación antes y después de la capacitación. Establece una comparación a partir de los coeficientes de variación.

b) Establece las hipótesis para verificar si la capacitación para mejorar el tiempo promedio de pro-

ducción de un lote de arepas dio resultado. Usa un nivel de significancia del 5% para hacer la prueba.

8. Un contador cree que los problemas de flujo de efectivo de una empresa son resultado directo del lento proceso de cobro de las cuentas por cobrar; dice que al menos el 70% de las actuales cuentas por cobrar tienen más de dos meses; una muestra de 120 cuentas por cobrar indica que hay 78 con más de dos meses. Prueba la afirmación del contador con un nivel de significancia de 0,05 y halle el valor p .

9. Algunas empresas medianas exportan parte de su producción a países del Grupo Andino. Para estimar el monto de esas exportaciones se hizo un muestreo entre 100 empresas medianas tomadas aleatoriamente entre las que exportaban y se averiguó a cuánto ascendían sus exportaciones en el último mes. Se encontró un promedio de 7500 dólares y una desviación estándar de 3260 dólares.

a) Encuentra un intervalo de confianza del 90% para la verdadera media.

b) ¿Cuál sería ese intervalo si el nivel de confianza es 95% y el tamaño muestral no cambia? Concluye

c) ¿Cuál sería ese intervalo si el nivel de confianza sigue siendo 90%, pero el tamaño de muestra se duplica? Concluye

10. Aprovechando un tratado firmado recientemente algunas pymes de alimentos han comenzado a exportar a países de Lejano Oriente. Las exportaciones de 25 de esas empresas seleccionadas aleatoriamente ascienden a los siguientes montos (en miles de dólares) en el último año:

Ejercicio 10 Inferencial

El Presidente de la República afirmó ayer que el promedio de exportaciones de empresas de las características señaladas es al menos de 200000 dólares en el último año. Según esa muestra, ¿parece que eso es cierto? Compruébalo mediante una prueba de hipótesis.

11. La Cámara de Comercio afirmó que las microempresas de Medellín presentan ventas totales promedio de 12 millones de pesos por día. Para comprobarlo se tomó una muestra aleatoria de 25 microempresas y se registraron sus ventas diarias promedio (en millones de pesos), así:

Ejercicio 11 Inferencial

Con un nivel de significancia de 5%, ¿parece que es cierto lo que afirmó la Cámara de Comercio?

12. Una empresa pequeña de confecciones utiliza dos máquinas para el proceso de corte; quiere evaluar si la proporción de cortes defectuosos es similar en ambas máquinas. Para tal efecto evaluó dos muestras de 150 elementos cada una en cada máquina y clasificó los cortes como defectuosos o no defectuosos, de acuerdo con ciertos límites de tolerancia establecidos previamente. Los resultados están en el siguiente archivo:

Ejercicio 12 Inferencial

Elabora una prueba de hipótesis para evaluar si hay diferencia entre las proporciones. Para dar tu respuesta bázate en un valor p .

13. El director de marketing de una compañía de bebidas energizantes decide contratar una agencia de investigación de mercados para conocer el reconocimiento de la marca de bebidas en la ciudad de Bogotá.

La agencia de mercados realiza el estudio y le informa al director que el 32% de las personas de la ciudad reconoce la marca.

Para dicho estudio encuestaron a 227 personas, y afirman la proporción hallada tiene un margen de error del 4%, con un nivel de confianza del 95%.

El director de marketing no está satisfecho con la información suministrada por la agencia. ¿Por qué?

- a. El director sabe que el tamaño de muestra debió ser mayor para asegurar lo que la agencia le está informando
- b. El director considera que se hicieron más encuestas de las necesarias y que de hecho con menos encuestas se pudo establecer el mismo margen de error y el mismo nivel de confianza.
- c. El director sabe que el número de personas a encuestas eran exactamente 385
- d. En realidad no es claro el motivo de insatisfacción, la información suministrada es correcta.

14. El director de marketing de la empresa *Buyumbura* decide contratar una agencia de investigación de mercados para conocer el reconocimiento de su marca en la ciudad de Bogotá. A continuación se encuentran los resultados de esa encuesta:

Ejercicio 14 Inferencial

a) ¿De qué tamaño debería ser la muestra para que el margen de error sea 4,5% si se considera un nivel de confianza de 90%? Como la agencia utilizó una muestra de 120 personas, ¿cuál es el margen de error?

b) Establece un intervalo de confianza bilateral de 90% de confianza para la proporción de bogotanos que no conocen la marca. Interpreta dicho intervalo. ¿Cuál es el error del intervalo?

c) Se establece la hipótesis de que la marca es conocida por lo menos por el 75% de los bogotanos. Plantea hipótesis nula y alternativa. ¿Dicha hipótesis debe rechazarse o no? ¿De qué valor es el estadístico de prueba?

15. Se quiere estimar la proporción de empleados de una empresa grande que tienen un fuerte sentido de pertenencia con la empresa; por obvias razones la encuesta fue secreta y, por lo tanto, los encuestados no registraban su nombre en la encuesta diligenciada.

a) La empresa funciona en varias ciudades del país y tiene 2250 empleados; se tomó una muestra de 10% y se encontró que 172 de los encuestados manifestaron tener un alto sentido de pertenencia. Calcula e interpreta un intervalo de confianza con un nivel de confianza que consideres pertinente para la proporción de empleados de la empresa que tienen un fuerte sentido de pertenencia.

b) Con ese mismo nivel de confianza, encuentra el tamaño de muestra requerido para que el error no sea superior a 3%.

c) Los directivos de la Empresa consideran que por lo menos el 90% de los empleados presentan un alto sentido de pertenencia con la empresa. ¿Los resultados de la encuesta parecen verificar esa hipótesis o parecen demostrar lo contrario?

RESPUESTAS A EJERCICIOS PROPUESTOS


[Descargar archivo Excel](#)

4. ANÁLISIS DE REGRESIÓN Y CORRELACIÓN

Se estudiará en este capítulo la interrelación entre dos o más variables; aunque una alta asociación entre variables no necesariamente implica que una sea causa de la otra, un análisis de regresión sí puede conducir en muchos casos a ejercer acciones sobre una variable para influir sobre otra.

Frecuentemente se hace necesario en las empresas hacer predicciones sobre ventas, presupuestos o cualquier otra variable que impacte en las organizaciones y en la toma de decisiones.

Adicionalmente se hace necesario saber si hay relación entre algunas variables tales como publicidad y ventas, tiempo y costos u otras variables. De forma que si se puede establecer una correlación se hace posible encontrar un modelo que permita realizar predicciones o entender el comportamiento de dichas variables.



También se considerarán los casos en los que la variable independiente es el tiempo; esto es llamado Serie cronológica y constituye un importante aporte de la Estadística, principalmente como registro histórico o como punto de apoyo para hacer proyecciones.

La regresión es el estudio de la relación o asociación entre dos o más variables; por ejemplo, cuando se evalúa cómo se comportan algunas variables del negocio de acuerdo al comportamiento de los indicadores financieros. Para evaluar cómo es esa relación puede emplearse un procedimiento estadístico llamado análisis de regresión.

Cuando se hace un análisis de regresión el primer paso consiste en la construcción de un diagrama de dispersión, que es una gráfica en la que cada par (x_i, y_i) está representado con un punto en un sistema de coordenadas bidimensional, formando una nube de puntos; de acuerdo con la forma de

esa nube de puntos se elige el modelo más apropiado (o modelos –porque podrían ser varios-). El gráfico presenta la siguiente estructura:



El proceso para obtenerlo se explica en el siguiente video:

<https://www.youtube.com/watch?v=BLQqg5rFoWo>

Archivo con los datos para practicar:

Diagrama de Dispersión

Es de suma importancia la selección de las variables, pues si no se hace bien podrían obtenerse resultados engañosos.

Se debe hacer una distinción entre las variables en lo que respecta a su papel en el proceso, así:

- Variable independiente, regresora o explicativa (x): se controla en el proceso y es la supuesta causa; los experimentos manipulan variables independientes para ver sus efectos sobre variables dependientes. Se representa en el eje horizontal del diagrama de dispersión.
- Variable dependiente, respuesta o explicada (y): es el resultado producido por la acción de una variable independiente; si lo que se realiza es un experimento, esta es la variable que no se controla. Se representa en el eje vertical de un diagrama de dispersión.

Ejemplos Diferencia conceptual entre variables dependiente e independiente:

- Se quieren explicar las ventas de una empresa únicamente en función de su inversión en publicidad. Para ello se tomó una muestra y se hizo el respectivo análisis.

Variable independiente: Inversión en publicidad.

Variable dependiente: Ventas.

- *Zambia* es una empresa que produce y comercializa pinturas. Algunas de sus materias primas deben ser importadas desde Canadá; debido a ello, sus utilidades se ven muy afectadas por la tasa de cambio del dólar. Se presenta una base de datos con el precio promedio del dólar en el mes y las utilidades de *Zambia* en ese tiempo.

Variable independiente: Tasa de cambio del dólar

Variable dependiente: Exportaciones.

- Se desea evaluar el comportamiento de las ventas de una empresa en función del precio propio y del precio de la competencia.

Variables independientes: Precio propio y precio de la competencia.



Variable dependiente: Ventas.

La relación que se ajusta a un conjunto de datos experimentales se caracteriza con una ecuación que se denomina ecuación de regresión y describe en forma razonable el comportamiento de la variable respuesta, dados los valores de las variables regresoras.


Dicha relación puede ser directa o inversa. Es directa si al aumentar el valor de la variable independiente, también aumenta el valor de la variable dependiente; es inversa si al aumentar el valor de la variable independiente, el valor de la variable dependiente disminuye. Estos conceptos no deben confundirse con relaciones directa o inversamente proporcionales, pues es casi imposible que se presente proporcionalidad en un caso que implique incertidumbre.

Según sea la variabilidad de los datos (nube de puntos) en el diagrama de dispersión puede darse


alguna de las siguientes relaciones: Lineal, Logarítmica, Exponencial, Polinómica, entre otras.





SIN RELACIÓN



REGRESIÓN EXPONENCIAL





La regresión puede ser:

- Simple: si involucra únicamente dos variables (una independiente y una dependiente).
- Múltiple: si involucra tres variables o más (una dependiente y varias independientes).

Para el estudio de los temas de Análisis de regresión se estudiará el siguiente caso:

Senegal nace en 1995 en Sabaneta, Antioquia, Colombia y produce diferentes artículos de cuero. En 2002 iniciaron sus exportaciones a Estados Unidos; hoy exportan a 16 países del mundo. En el Valle de Aburrá tiene diez tiendas.

4.1 REGRESIÓN LINEAL SIMPLE

La regresión es muy utilizada para interpretar situaciones reales, pero comúnmente se hace de mala forma; por ello es necesario realizar una selección adecuada de las variables que van a originar las ecuaciones de la regresión, ya que tomar variables que no tengan relación en la práctica arrojará un modelo carente de sentido. También es muy común que, cuando se hace un análisis de regresión, todo se ajuste al modelo lineal; este debe utilizarse solamente si la nube de puntos del gráfico de dispersión lo sugiere, es decir, si la nube de puntos no se aleja mucho de una línea recta.

Cuando se da una relación lineal entre dos variables (x y y) el valor estimado de y está dado por:

$$\hat{y} = A + Bx,$$


donde A es el punto de corte de la recta estimada con el eje y (valor esperado de y cuando x vale 0) y B es la pendiente, que mide el cambio promedio en y cuando x aumenta en una unidad; eso significa que la pendiente es siempre el valor que acompaña a x .

Si por lógica el punto de corte debe coincidir con el origen de las coordenadas (0,0), al hacer la regresión en Excel debe marcarse la opción **Señalar intersección**.


La adecuación del modelo de regresión se puede medir con el coeficiente de determinación (R^2), que expresa la proporción de la variación total en los valores de la variable y que se puede explicar mediante los cambios en los valores de x . El nivel de ajuste del modelo también puede medirse con el coeficiente de correlación (r), que es la raíz cuadrada de R^2 con el signo de la pendiente; el coeficiente de correlación puede tener cualquier valor entre -1 y 1; pero su valor absoluto debe ser cercano a 1 para poder considerar un buen ajuste (preferiblemente superior a 0,8).

Si se tiene duda sobre varios modelos se debe preferir aquel cuyo coeficiente de correlación es más cercano a 1 o a -1.


VALOR DE r	SIGNIFICADO
1	Correlación positiva perfecta
-1	Correlación negativa perfecta
Cercano a 0	Sin correlación
Positivo y alto	Relación directa entre variables (a medida que aumenta x , también aumenta y). La relación es más fuerte mientras mayor sea r
Negativo y alto en valor absoluto	Relación inversa entre variables (a medida que aumenta x , y disminuye). La relación es más fuerte mientras más cercano sea r a -1





Correlación positiva: $0 < r < 1$



Correlación negativa perfecta: $r = -1$





Obviamente, como el coeficiente de determinación es el cuadrado del coeficiente de correlación, siempre va a ser positivo. Como r puede tomar un valor entre -1 y 1 , el coeficiente de determinación tomará valores entre 0 y 1 (mientras más se acerque a 1 , más adecuado es el modelo).

Es importante aclarar que la correlación no implica causalidad, es decir, el hecho de encontrar que dos variables estén altamente correlacionadas no implica necesariamente que una sea la causa de la otra, aunque por consideraciones lógicas o teóricas puede sospecharse una relación de causalidad en muchos casos. Por ejemplo, si estamos evaluando la utilidad de varias empresas frente a la formación académica del gerente general de cada una, medida por los años dedicados a la educación formal, y se encuentra un alto coeficiente de correlación entre las dos variables, no puede concluirse que la utilidad de la empresa sea consecuencia de la formación académica de su gerente.

Muchas veces puede presentarse una relación espuria, que es una relación matemática entre acon-

tecimientos que no tienen ninguna conexión lógica; con esto debe tenerse sumo cuidado porque en algunas ocasiones se sacan conclusiones que pueden no ser reales.

De otro lado, las variables que se evalúan y la manera de medirlas deben ser seleccionadas muy inteligentemente. En el caso que se mencionó, la cantidad de años dedicados a la academia no es sinónimo de calidad, entonces no mide realmente lo que se pretende medir.

Cuando se hace un análisis de regresión también pueden encontrarse **valores esperados** para cualquiera de las variables.

Si se conoce un valor de la variable independiente y quiere establecerse el valor correspondiente para la variable dependiente puede utilizarse la función **PRONÓSTICO** si la situación se ajusta al modelo lineal. Dicha función solicita los siguientes argumentos:

X, que es el valor conocido para la variable dependiente.

Conocido_y, que es el rango de datos de la variable dependiente.

Conocido_x, que es el rango de datos de la variable independiente.

Utilizar dicha función es equivalente a reemplazar el valor de x en la ecuación de regresión.

Si lo que se conoce es un valor de la variable dependiente y quiere establecerse el valor correspondiente para la variable independiente debe despejarse la variable x en la ecuación de regresión y reemplazar el valor conocido de y .

EJEMPLO 1

Se quieren explicar las ventas de *Senegal* únicamente en función de los gastos en publicidad (ambas variables en millones de pesos). Para ello se tomó una muestra de diez tiendas y se encontró lo siguiente:

Ejemplo 1_Regresión

Halla una ecuación de regresión apropiada e interpreta los parámetros.

<https://www.youtube.com/watch?v=xGcE20dyjI0>

Si en el mes siguiente, Senegal piensa invertir 250 millones de pesos en publicidad y se desea estimar las ventas, debe reemplazarse 250 como valor de x en la ecuación de regresión porque lo que se

conoce es un valor para la variable independiente, así:

$$\begin{aligned}y &= 13,548x + 968,2 \\y &= 13,548(250) + 968,2 \\y &= 4355,2 \text{ millones de pesos}\end{aligned}$$

Ahora, si planteamos el problema al revés y nos preguntamos, por ejemplo, cuánto debe invertir *Senegal* en publicidad para alcanzar unas ventas de 5500 millones de pesos, de acuerdo con la relación anterior, debemos despejar la variable x porque lo que se conoce es un valor para la variable dependiente:

$$x = \frac{y - 968,2}{13,548} \rightarrow x = \frac{5500 - 968,2}{13,548} = 334,5 \text{ millones de pesos}$$

Cuando se habla de costos y la ecuación de regresión es lineal el punto de corte es equivalente a los costos fijos y la pendiente es equivalente al costo variable o costo adicional por unidad producida.

EJEMPLO 2

En Senegal reunieron datos sobre volumen de producción y costos totales de cierta referencia de una chaqueta con el fin de estimar costos de acuerdo a ciertos volúmenes de producción programados. Se obtuvo la siguiente muestra:

Ejemplo 2 Regresión

- Estima la ecuación de regresión y analiza los parámetros.
- Estima el costo total si se producen 640 chaquetas de esa referencia.

Encuentra la solución en el siguiente video:

https://www.youtube.com/watch?v=6y8wLQ_dZUQ

4.2 OTROS MODELOS

Un diagrama de dispersión de los datos o un valor de R^2 no muy alto o consideraciones teóricas inherentes al estudio científico pueden sugerir la necesidad de utilizar un modelo diferente al lineal.

Cuando no existían tantas herramientas tecnológicas no era muy fácil aplicar una regresión que no fuera lineal, por ejemplo exponencial, ya que había que aplicar logaritmo natural a cada valor de y para después hacer la regresión, pero hacer eso hoy es tan directo como aplicar la regresión lineal, y sin embargo son muchos los textos y cursos universitarios que solamente aplican el método lineal.

Si se usa un modelo inadecuado los resultados obtenidos van a carecer de sentido. Lo más importante es tener en cuenta que el análisis de regresión nos sirve para tomar decisiones y, si para tomarlas nos vamos a basar en algo incorrecto, toda la cadena va a ser carente de sentido.

Puede ocurrir, por ejemplo, que las ventas de una empresa estén creciendo a pasos agigantados; si para tomar ciertas decisiones nos basamos en un modelo lineal, estaríamos subestimando la situación; por ejemplo, si se contrata cierto número de empleados con base en los resultados obtenidos de ese modelo lineal, podrían resultar insuficientes, así al hallar el coeficiente de correlación, este no sea muy alejado de 1.

Se mostrarán únicamente las ecuaciones para algunos de los más utilizados:

Regresión	Forma funcional
Exponencial	$y = Ae^{Bx}$
Logarítmica	$y = A + B \ln x$
Polinomial de segundo grado o cuadrática	$y = Cx^2 + BX + A$

Si se quiere encontrar un valor esperado con un ajuste diferente al lineal no puede emplearse la función **PRONÓSTICO**; siempre es necesario reemplazar ya sea el valor de x o el valor de y en la ecuación de regresión. Como en este último caso se debe despejar la variable x , puede ser necesario despejar una ecuación logarítmica, exponencial o polinomial.

EJEMPLO 3

En el siguiente ejemplo se muestra el costo por unidad de un bolso para dama producido por Senegal, según la cantidad de unidades que se produzcan:

Ejemplo 3 Regresión

Realiza una regresión apropiada para predecir el costo por unidad de acuerdo a una cantidad específica de unidades producidas.

<https://www.youtube.com/watch?v=Ie5D4z-nP9k>



EJEMPLO 4

Senegal ha hecho una expansión de su planta productiva. Esas adecuaciones le han permitido tener un incremento en la producción y han hecho posible el incursionar en nuevas líneas; además ha contribuido a la generación de empleo porque ha sido necesario contratar más empleados fijos. Sin embargo, está demostrado que no siempre el hecho de contratar muchos empleados se refleja en un aumento significativo de la producción; por eso en la Empresa se decidió hacer un análisis de regresión entre la producción y el número de trabajadores.

Ejemplo 4 Regresión

Halla una ecuación de regresión que describa la situación.

<https://www.youtube.com/watch?v=XHg2F-Agk6k>

Si, por ejemplo, se quiere calcular la producción aproximada cuando en planta se tienen 85 trabajadores solamente hay que reemplazar el valor 85 en lugar de x en la ecuación; por lo tanto:

$$y = 847,49 \ln(85) - 1755,8 = 2009,3 \text{ millones de pesos}$$

Pero si lo que se pretende es calcular el número de trabajadores que debe haber en planta para que la producción en cierto día sea equivalente a 2300 millones de pesos, habría que despejar el valor de x , ya que lo conocido es un valor de y , así:

$$\ln(x) = \frac{2300 + 1755,8}{847,49} = 4,78566119$$

$$x = e^{4,78544119} = 120 \text{ trabajadores}$$

El número de Euler (e) corresponde en Excel a la función **EXP**, por lo que esta última operación puede hacerse como = EXP (4,78566119)

EJEMPLO 5

En el área de producción de la Empresa también quieren estudiar la relación del número de trabajadores en planta y el porcentaje de productos defectuosos. Reunieron los siguientes datos:

Ejemplo 5 Regresión

Describa dicho comportamiento a partir de una ecuación de regresión.

<https://www.youtube.com/watch?v=SAAnVsaDHB18>

Con base en los dos últimos ejercicios haga un análisis conjunto y plantee estrategias dirigidas al jefe de producción de la Empresa.

Siempre debe tenerse presente que al hacer un análisis de regresión no debe extrapolarse, es decir, no es conveniente hallar valores esperados para puntos que están fuera del rango de los datos originales y, si decide hacerse, deben ser valores no muy retirados. Al hacer el análisis es necesario ser muy lógicos; por esa razón, es preciso, a veces, ajustar a un modelo, así este no tenga el más alto coeficiente de determinación; un ejemplo claro sucede con la regresión polinomial de segundo grado, ya que su gráfico es una parábola y si no se establece el vértice podrían obtenerse valores esperados carentes de sentido.

4.3 REGRESIÓN MÚLTIPLE

Como se mencionó antes, el análisis de regresión múltiple evalúa la relación entre una variable dependiente y dos o más variables independientes.

La ecuación de regresión múltiple estimada es:

$$\hat{y} = A + B_1X_1 + B_2X_2 + \dots + B_nX_n$$

Lo anterior significa que, por lo menos en estadística no muy avanzada, la regresión múltiple siempre se ajusta al modelo lineal.

El coeficiente A representa el valor esperado de y si todas las variables independientes asumen un valor de cero.

Cada uno de los coeficientes B indica el cambio promedio en la variable dependiente debido a un cambio en una unidad en la variable respectiva, mientras las demás variables independientes permanecen constantes.

Para mayor claridad se adiciona el siguiente video:

<https://www.youtube.com/watch?v=9l4bordTpuI>

Archivo con los datos para practicar:

[Regresión Múltiple](#)

El coeficiente de correlación múltiple debe ser alto, pero como no hay una alternativa diferente al modelo lineal, se aceptan coeficientes, aunque no sean muy altos. Si dicho coeficiente (r) es bajo, el análisis de regresión múltiple no resulta apropiado y por eso lo mejor es hacer regresión simple entre la variable dependiente y cada variable independiente.

Cuando se hace un análisis de regresión múltiple puede resultar interesante resaltar el coeficiente de correlación entre cada par de variables; para ello se utiliza la matriz de correlación, que es una disposición de igual número de filas y columnas en cuyos encabezados se destacan las variables implicadas; eso significa que en su diagonal van unos (coeficiente de correlación de cada variable consigo misma) y esa diagonal se convierte en eje de simetría para los otros valores (porque el coeficiente de correlación entre A y B es el mismo que el coeficiente de correlación entre B y A) (Johnson, 1998, p. 10).

La construcción de dicha matriz en Excel se explica en el siguiente video:

<https://www.youtube.com/watch?v=sm44wOHQkKU&feature=youtu.be>

Inclusive, aunque no es frecuentemente usada en un análisis de regresión múltiple, la construcción de una matriz de correlación puede ser un punto de partida apropiado para establecer la pertinencia de un análisis de regresión múltiple, pues dicho análisis no tendría mucho sentido si la relación de una de las variables independientes es débil respecto a la variable dependiente; también podría sugerir que dicha variable independiente deba eliminarse del estudio.

4.4 SERIES CRONOLÓGICAS

Es un conjunto de mediciones de cierto fenómeno registrado secuencialmente en el tiempo para observar el comportamiento de la variable; dichos registros deben hacerse en intervalos regulares, que

pueden ser días, meses, años, horas, etc. También se denominan series de tiempo.

Los histogramas son muy útiles para mostrar la variabilidad de los datos; sin embargo, no pueden mostrar la variación en el tiempo. El primer paso para analizar una serie de tiempo consiste en graficarla. En la representación gráfica de las series temporales se utilizan los **diagramas de líneas**; en el eje de las abscisas se representa el tiempo t y en el eje de las ordenadas, los valores de la magnitud observada $x(t)$. Se obtiene así una serie de puntos $(t, x(t))$ que, unidos, proporcionan una visión dinámica de la evolución del fenómeno que se esté analizando.

Se trata, por tanto, de un caso particular de análisis de regresión donde la variable independiente es el tiempo (t) y la variable dependiente es la magnitud de interés (y) .

La siguiente es la estructura de un diagrama de líneas:



El proceso para obtener el diagrama de líneas se explica en este video:

https://www.youtube.com/watch?v=eqed_NsC55s

Archivo con los datos para practicar:

[Diagrama de línea](#)

No deben confundirse diagrama de dispersión y diagrama de líneas, aunque si en el primero se unen los puntos son exactamente iguales estéticamente; desde el punto de vista matemático son muy distintos si los datos de tiempo están dados en forma cuantitativa (por ejemplo si son años), ya que el diagrama de dispersión toma esos datos como cantidades y por eso la pendiente de la ecuación de regresión y el coeficiente de determinación son los mismos, pero el punto de corte es muy distinto; si los datos de tiempo están dados en años, el punto de corte correspondería al año cero, lo

que carece totalmente de sentido.

Para mayor claridad, se presentan los dos diagramas en una misma situación, aunque el que debe usarse es solamente el de líneas. Observe que las ecuaciones son diferentes.

AÑO	VENTAS (Millones de dólares)
2010	8,2
2011	8,1
2012	9,5
2013	10,1
2014	10,3
2015	11,5
2016	11,9




Diagrama de dispersión




Diagrama de líneas

La suposición básica fundamental en el análisis de series de tiempo es que los factores que han influido en el pasado o en el presente en los patrones continuarán haciéndolo más o menos en la misma forma en el futuro. Eso significa que los datos históricos son usados para pronosticar posibles valores futuros.

En cualquier análisis estadístico se debe diferenciar entre datos transversales y series temporales de datos; en los datos transversales no importa el tiempo en que se recojan (por ejemplo los datos de una encuesta), mientras que las series de tiempo son grupos de datos cuantitativos que se obtienen en períodos con intervalos regulares en el transcurso del tiempo.

Una presentación de BioMates.net (s.f.) dice:

El tratamiento numérico de las *series temporales* es variado y la metodología a utilizar en cada caso depende de los objetivos planteados por el analista. En general, se puede decir que de una secuencia cronológica puede interesar adquirir un conocimiento *descriptivo o diagnóstico*, en el sentido de poder detectar la dinámica generadora del fenómeno bajo estudio (si este es el objetivo, solamente se hace un análisis gráfico, que incluye gráfico y evaluación de los componentes); o un conocimiento *predictivo o pronóstico*, si se pretende deducir de los datos registrados hasta el momento, cómo será el comportamiento futuro.

Usualmente una serie cronológica muestra una correlación entre observaciones adyacentes; a partir de eso se usan técnicas especiales para hacer modelos y análisis.

4.4.1 IMPORTANCIA DE LAS SERIES CRONOLÓGICAS

- Sirven para hacer pronósticos o proyecciones, ya que pueden hacerse estimados y predicciones del futuro con base en tendencias y modelos del pasado. La planeación a futuro es un aspecto primordial para cualquier administración, ya que es muy importante poder “anticipar el futuro” y desarrollar estrategias apropiadas; a partir de las proyecciones podría, por ejemplo, planificarse compras y demanda. El realizar proyecciones a futuro nos plantea la posibilidad de tener luces sobre lo que vendrá, le da a un profesional del área administrativa herramientas únicas para sortear el mercado en el que trabaja y planear estrategias para lograr estas proyecciones; nada puede garantizarnos el éxito, ya que es necesario tener en cuenta que influyen una serie de variables que, si se ignoran, cualquier proyección podría convertirse en una pérdida total de tiempo.

No es tan importante la proyección como un número (eso puede hacerlo un programa). Lo más importante para un administrador son las estrategias que implemente para lograr que lo que se proyecte suceda realmente (si es conveniente) o evitar que suceda (si no conviene). Es claro que siempre implica algún riesgo, pero si nos “adelantamos” al futuro, podremos tomar decisiones más asertivas, claras y veraces.

No deben hacerse proyecciones a muy largo plazo, especialmente si la serie cronológica analizada no presenta una tendencia muy definida.

A esa proyección se le debe agregar innovación y permanecer abiertos a los cambios; dichas proyecciones no deben convertirse en una regla, sino que deben ser proyecciones dinámicas. Debe tenerse en cuenta que un análisis de series cronológicas no debe convertirse en el reemplazo de unas fórmulas, sino que tiene mucho de arte.

Hay que establecer muy bien cuál es el objetivo al hacer las proyecciones: si este es puramente de carácter histórico, no hay ningún problema en proyectar como se ha mencionado. Pero si dicha proyección va a ser fuente de indicadores que van a utilizarse para tomar decisiones a futuro, puede ser conveniente combinar el análisis de regresión con técnicas cualitativas. Eso implica que los datos hay que estudiarlos con profundidad.

- Son útiles para planeación y control.

- Facilitan la comparación de datos que ocurren en momentos diferentes en el tiempo.

- Pueden servir como registros históricos valiosos. Por ejemplo, para estudiar el comportamiento a lo largo del tiempo de una variable macroeconómica o el comportamiento de una acción.


¡PIENSA!

¿Para qué más le podría servir una serie cronológica a un profesional de tu área?

4.4.2 COMPONENTES DE UNA SERIE DE TIEMPO:

Tendencia: patrón de movimientos general o persistente, a largo plazo; puede ser alcista, a la baja o neutra (horizontal).


La tendencia representa el comportamiento predominante de la serie. Esta puede ser definida vagamente como el cambio de la media a lo largo de un periodo.



Ese desplazamiento gradual es, generalmente, el resultado de factores a largo plazo, como cambios en la población, tecnología o preferencias del consumidor.

Para establecer una línea de tendencia que sea significativa para una serie cronológica, el período tiene que ser suficientemente largo.

Algunas veces se da una ruptura de tendencia, que es cuando la serie trae una tendencia definida y cambia bruscamente. En ese caso, si se quiere hacer pronósticos hay que tener en cuenta únicamente el último tramo.



(Se observa una ruptura de tendencia después del dato 15)

Un ejemplo claro de ruptura de tendencia se presenta cuando entre dos países se firma algún acuerdo comercial.

Componente cíclico: fluctuaciones a largo plazo más o menos periódicas que se repiten regularmente cada cierto período (generalmente cada día, cada semana, cada mes o cada año).

Estacionalidad: patrón regular que se repite en un período específico. Se trata de un componente que es causado debido a la influencia de ciertos fenómenos que se repiten periódicamente (las estaciones, los fines de semana, las horas pico, etc); por ejemplo, ventas altas en el mes de diciembre de todos los años evaluados.

No deben confundirse estacionalidad y ciclos; la estacionalidad es un comportamiento que se repite en un período específico (por ejemplo, aumentos o disminuciones los sábados si la serie está dada en días o los diciembres si está dada en meses o al mediodía si está dada en horas del día), mientras que los ciclos son fluctuaciones que se repiten cada cierto espacio de tiempo y por lo tanto incluyen todo el período (por ejemplo ciclos mensuales si en el diagrama de líneas se observa que cada mes se repite aproximadamente lo mismo o ciclos anuales o ciclos trimestrales).

Es muy frecuente que al haber ciclos haya también estacionalidad, pero eso no es absolutamente necesario, ya que puede haber estacionalidad y que no se presenten ciclos.

Componente irregular: son movimientos que no muestran ninguna regularidad. Se debe a factores a corto plazo, imprevisibles y no recurrentes que afectan la serie de tiempo: huelgas, terremotos, inundaciones, problemas políticos circunstanciales, entre otros; recoge la influencia que ejercen sobre la serie circunstancias aleatorias o accidentales.

Como no presenta un comportamiento sistemático a corto, mediano o largo plazo, no se puede

predecir de ninguna forma. Si la serie que se esté estudiando no es muy larga, se recomienda la eliminación de las observaciones anómalas y se evita así la influencia de factores esporádicos en los resultados del análisis final de la serie.

Es importante destacar la diferencia entre un componente irregular y una ruptura de tendencia; si algún acontecimiento influye sobre una serie cronológica e implica algún cambio a partir de él, estamos ante una ruptura de tendencia, pero si simplemente constituye un punto aislado mas no hace que se cambie la tendencia, estamos en presencia de factores irregulares.

En el siguiente video se aclarar algunos asuntos relacionados con el análisis de componentes de una serie cronológica:

https://www.youtube.com/watch?v=sEndY_-ejyo

Archivo con los datos para practicar:

[Análisis de componentes de una serie cronológica](#)

El análisis gráfico de una serie temporal consiste en describir las pautas de regularidad que sigue cada uno de sus componentes, con el fin de conocer la serie para el período para el que se tienen datos y poder predecir así su evolución futura. Se deben detectar, entonces, puntos de la serie que se escapan de lo normal (**outliers**); un *outlier* es una observación de la serie que corresponde a un comportamiento anormal del fenómeno (sin incidencias futuras) o a un error de medición y por lo tanto se debe omitir antes de analizar la serie.

Nota: aunque el coeficiente de determinación sea muy alto, no es muy conveniente utilizar una ecuación polinomial para proyectar porque son curvas poco predecibles; en cualquier caso, si decide hacerse una proyección a partir del ajuste al modelo polinomial debe verificarse muy bien si el resultado tiene lógica. Nunca debe proyectarse a un plazo medianamente largo con una polinómica; si decide usarse debe ser a muy corto plazo.

4.4.3 EMPLEO DEL ANÁLISIS DE REGRESIÓN EN PRONÓSTICOS

Cuando se hacen pronósticos pueden utilizarse métodos cualitativos, es decir, basados en el juicio y la intuición. En muchos casos, estos son los únicos métodos disponibles, sobre todo en aquellos casos en los cuales no es posible conseguir datos certeros; su naturaleza no científica hace que sean difíciles de estandarizar y de validar su precisión. Por ello, siempre que sea posible es más adecuado basarse en métodos cuantitativos, pero para que resulte algo lógico deben conocerse muy bien las variables elegidas y estas deben ser juiciosamente escogidas; además deben establecerse unos posibles pronósticos de acuerdo con el diagrama de líneas.

Una vez trazado el diagrama de líneas debe escogerse una porción de los datos más recientes que se ajuste a alguno de los modelos conocidos; a partir de eso se hace la proyección, lo que implica que pueden hacerse muchos análisis diferentes y que ante una misma situación pueden existir varias ecuaciones de proyección adecuadas y por lo tanto diferentes proyecciones adecuadas.

Pueden presentarse varios casos; de cada uno se mostrará un ejemplo:

1. Si se presenta una tendencia durante todo el recorrido conocido se hace un análisis de regresión simple, según el modelo más adecuado (lineal, exponencial, cuadrática...).

EJEMPLO 6

Cierta empresa desarrolla, fabrica y vende productos para acceso a redes. Los siguientes datos son las ventas anuales (en millones de dólares) del año 1 al 14:

1	2	3	4	5	6	7	8	9	10	11	12	13	14
0,5	0,9	1,6	2,9	2,8	5,4	6,2	13	21	26	43	57	93	126

a) Deduce una ecuación de regresión para esta serie de tiempo.

b) Pronostica las ventas en los años 15 y 16.

https://www.youtube.com/watch?v=mwRde_939BA

Archivo con los datos para practicar:

[Serie de tiempo Tendencia](#)

2. Si hay una ruptura de tendencia y se quiere hacer pronósticos hay que tener en cuenta únicamente el último tramo.

<https://www.youtube.com/watch?v=LuroaI1XTSo>

Archivo con los datos para practicar:

[Ruptura de tendencia](#)

3. Si en la serie se detecta estacionalidad o ciclos, deben tenerse en cuenta esos aspectos al hacer un pronóstico. Por ejemplo, si se nota que en una serie cronológica existe estacionalidad en los meses y desea establecerse un pronóstico para un diciembre próximo, deben tenerse únicamente en cuenta los datos correspondientes a ese mes.

Archivo con los datos para practicar:

Estacionalidad

4. Si no hay una tendencia definida ni ciclos ni estacionalidad deben emplearse otros métodos para hacer proyecciones, como por ejemplo media móvil, suavizamiento exponencial, Índice de fuerza relativa, variación porcentual, métodos cualitativos, entre otros. Eso sucede, por ejemplo, con el precio del dólar y con el precio diario de las acciones; estos métodos serán tenidos en cuenta más adelante en otra sección.

4.4.4 OTRAS HERRAMIENTAS PARA HACER PRONÓSTICOS

Ocurre muchas veces que ningún modelo de regresión se ajusta a los datos de una serie de tiempo; en dichos casos hay que buscar métodos alternativos si quiere hacerse alguna proyección. Algunos de esos casos son:

4.4.4.1 VARIACIÓN PORCENTUAL: Para hacer una proyección pueden promediarse las n variaciones porcentuales anteriores y se asume que ese es el crecimiento o decrecimiento del valor que va a proyectarse (crecimiento si el promedio de las variaciones porcentuales es positivo o decrecimiento si es negativo); no hay ninguna condición para determinar ese valor de n . Por obvias razones, únicamente puede hacerse pronóstico para un período.

No sobra recordar que una variación porcentual se calcula de la siguiente manera:

$$\text{Variación porcentual} = \frac{\text{Valor final} - \text{Valor inicial}}{\text{Valor inicial}} \times 100$$

EJEMPLO 7

Los siguientes datos resumen el valor de los activos soberanos implícitos de cierto país, medidos en miles de millones de dólares.

Variación porcentual

Encuentre las variaciones porcentuales mes a mes y elabore una proyección del monto de activos soberanos implícitos de ese país para el próximo mes, teniendo en cuenta las últimas cinco variaciones porcentuales.

4.4.4.2 MEDIA MÓVIL: Es un método de suavizamiento, pero no es propiamente regresión. Puede hacerse de manera simple o ponderada.

La media móvil simple consiste en promediar los n valores más recientes para pronosticar el dato del siguiente período. n es un número que el analista determina subjetivamente (generalmente tres o más, pero no un valor alto).

Para ponderar se le da un valor porcentual mayor a la información más reciente y así sucesivamente hasta sumar un 100% (dichos valores porcentuales también pueden determinarse de manera subjetiva).

EJEMPLO 8

Los siguientes datos resumen el valor de los activos soberanos implícitos de cierto país, medidos en miles de millones de dólares.

Media móvil

Elabore una proyección mediante media móvil del monto de activos soberanos implícitos de ese país para el próximo mes.

<https://www.youtube.com/watch?v=4z07jumCIG8>

4.4.4.3 MÉTODOS CUALITATIVOS: Cuando en la serie cronológica ha ocurrido algún cambio que hace poco creíble un pronóstico hecho por uno de los métodos anteriores o cuando no es posible contar con datos históricos es válido hacer un pronóstico por un método cualitativo. Existen muchos métodos cualitativos interesantes; en este libro no se profundizará en ellos, pero se invita a consultarlos; algunos son el método de Delphi, el juicio de expertos, la elaboración de escenarios futuros e incluso métodos intuitivos.

En muchos casos puede resultar conveniente combinar métodos de regresión con métodos cualitativos o con otros métodos cuantitativos diferentes a regresión para hacer proyecciones.

El autor de este libro no conoce una herramienta estadística específica que permita hacerlo, pero propone una herramienta sencilla que pretenden resultar muy lógica.

Por ejemplo, si estamos estudiando el monto de las exportaciones de Colombia a un país asiático y se espera que a principios del año 15 se firme un tratado de libre comercio entre ambas naciones, resulta evidente que una proyección basada únicamente en resultados de períodos anteriores se quedaría corta. Se podría entonces consultar el promedio de crecimiento de las exportaciones a otros países con los cuales Colombia ha firmado este tipo de tratados y suponer que ese mismo crecimiento se puede aplicar al país en cuestión.

EJEMPLO 9

Los siguientes han sido los montos de las exportaciones de Colombia a un país asiático (en millones de dólares):

1	2	3	4	5	6	7
547,5	512,3	697,3	496,6	577,3	693,3	731,3

8	9	10	11	12	13	14
808,3	873,5	963,5	1.016,50	1.098,00	1.195,30	1.302,50


Hacer proyecciones por regresión para los próximos tres años. Se espera que a principios del año 15 se firme un tratado de libre comercio entre Colombia y ese país.

Solución:

El siguiente es el gráfico de la situación:



Un buen ajuste se logra seleccionando datos desde el año 6 y aplicando el modelo exponencial:



Proyecciones para los próximos tres años:


Año	15	16	17
Proy. (Mill. dólar)	1404,1	1520,0	1645,4

Para hacer un ajuste más real se podría investigar la variación en las exportaciones hacia países con los cuales se ha firmado un tratado de libre comercio. Supongamos que se hizo dicha consulta y se halló un 29% de crecimiento en las exportaciones.

Año	15	16	17
Proy. (Mill. dól.)	1811,3	1960,8	2122,6

Aunque en general no deben graficarse las proyecciones, se hará una excepción en este caso para hacer más notoria la situación:

Debido a ello, podría ser racional ajustar las proyecciones en un 29%; quedarían así:



Inclusive, si se detecta que el crecimiento después de la firma de un tratado no es igual para todos los años que siguen (por ejemplo, si en promedio el crecimiento para el primer año no es tan grande como en el segundo) podría hacerse la diferenciación para las proyecciones.

Para hacer proyecciones de precios de acciones también resultaría insuficiente aplicar únicamente análisis de regresión; en esa situación también es necesario combinar métodos cuantitativos (análisis técnico: estudio de los movimientos del mercado principalmente mediante el uso de gráficos estadísticos de precios) y métodos cualitativos (análisis fundamental: noticias y factores macroeconómicos).

Por último, no está mal si el método aplicado para hacer proyecciones es netamente subjetivo, pero eso implica un conocimiento absoluto de la situación que se esté evaluando.

En todo caso, debe tenerse en cuenta que las proyecciones se pueden afectar por diversos factores internos de la organización y otros factores externos (económicos, sociales, culturales, ambientales, entre otros).

Aunque son útiles, no debe desconocerse que las herramientas evaluadas en este capítulo no son absolutamente confiables para hacer proyecciones en todas las situaciones porque solamente se basa

en resultados históricos, pero no se incluyen otras variables (por ejemplo de tipo macroeconómico) que pueden afectar como el comportamiento en el tiempo de la TRM, del PIB y de la inflación. Por eso hay que ser muy lógicos y analíticos a la hora de hacer un estudio de este tipo.

Es innegable que el futuro es incierto; lo que se trata es de prever la evolución de una situación que sufre variaciones en el tiempo para tratar de conocer con anticipación situaciones del futuro que probablemente ocurrirán; pero finalmente lo que se busca siempre es tratar de reducir el impacto de la incertidumbre.

EJERCICIOS RESUELTOS

Te invito a que, antes de estudiar los videos donde se desarrolla cada problema, intentes resolver los ejercicios. De esta manera podrás evaluar la comprensión de los temas.

1. *Guinea* es una empresa de Medellín que produce y comercializa pinturas. Algunas de sus materias primas deben ser importadas desde Canadá; debido a ello sus utilidades se ven muy influenciadas por la tasa de cambio del dólar. A continuación se encuentra una base de datos con la tasa de cambio promedio del dólar en el mes y las utilidades de *Guinea* en ese tiempo

Ejercicio resuelto 1 Regresión

a) Calcula una ecuación de regresión que muestre cómo se relacionan la tasa de cambio del dólar (variable independiente) y la utilidad (variable dependiente). Supón modelo lineal.

¿Cuáles son el coeficiente de correlación, la pendiente y el punto de corte? Interpretalos.

b) Si para el próximo mes se proyecta una tasa de cambio promedio de \$2750 por dólar, ¿cuáles serán las utilidades esperadas si se supone el precio del dólar como única variable que influye? ¿Qué otras variables podrían influir sobre las utilidades?

c) Halla una ecuación de regresión apropiada para hacer proyecciones de las utilidades. Haz proyecciones para septiembre y diciembre del año 3.

<https://www.youtube.com/watch?v=Dt6MhwuSPEg>

2. La utilidad de *Guinea* se ve muy influenciada por la tasa de cambio del dólar y por las importaciones totales de pintura desde el extranjero a Colombia. A continuación se encuentra una base de datos con la tasa de cambio promedio del dólar en el mes, las importaciones de pintura y las utilidades de *Guinea* en ese tiempo

Ejercicio resuelto 2 Regresión

a) Halla una ecuación de regresión que permita determinar cómo inciden la tasa de cambio del dólar y las importaciones de pintura sobre las utilidades de la empresa Guinea. ¿Cómo es la relación de la utilidad con cada una de las variables independientes? ¿Qué indican esas relaciones?

b) ¿Cuál es el cambio promedio en la utilidad por cada peso que aumente la tasa de cambio del dólar si las importaciones de pintura en el país no cambian?

<https://www.youtube.com/watch?v=rPjNzJj0YWI>

3. Los siguientes han sido los montos de las exportaciones de Colombia a un país africano (en dólares)

Ejercicio resuelto 3 Regresión

Pronostica las exportaciones de Colombia hacia ese país en los años 14 y 15.

<https://www.youtube.com/watch?v=LQZ3IUpV2g>

4. Se registraron los ingresos operacionales mensuales (en pesos) durante los últimos meses de una empresa muy pequeña, así:

Ejercicio resuelto 4 Regresión

a) Construye un diagrama de línea.

b) Encuentra las variaciones porcentuales mes a mes y elabore un pronóstico para los ingresos operacionales del mes de abril del año 3 teniendo en cuenta las cinco últimas variaciones porcentuales.

c) Haz un pronóstico de los ingresos operacionales para abril del año 3 según media móvil

<https://www.youtube.com/watch?v=ayvtgdKiYwY>

EJERCICIOS PROPUESTOS

Inmediatamente después de los planteamientos de los ejercicios se encuentra un archivo de Excel con sus soluciones.

1. En el siguiente cuadro se muestra una comparación de las utilidades operacionales de *Ruanda* y las del principal competidor (ambas en millones de pesos)

Ejercicio 1 Regresión

- a) Halla una ecuación de regresión conveniente para la utilidad operacional mensual de *Ruanda* a través de estos 24 meses. Haz una proyección para diciembre del año 3.
- b) Halla una ecuación de regresión conveniente para la utilidad operacional de la empresa competidora a través de estos 24 meses. Haz una proyección para diciembre del año 3.
- c) Haz un gráfico de línea comparativo de las utilidades operacionales de ambas empresas; comenta. Si las utilidades operacionales de *Ruanda* proyectadas para diciembre de este año todavía son inferiores a las de su competidor, proyecta el mes para el que se espera que las superen.

2. La empresa *Túnez*, que elabora y vende un producto de consumo masivo, hizo un reporte del número de unidades vendidas de su producto en los últimos meses. También registró sus costos operacionales durante esos mismos meses

Ejercicio 2 Regresión

- a) Calcula una ecuación de regresión que muestre cómo se relacionan el número de unidades vendidas (variable independiente) y los costos operacionales. Supón modelo lineal.
- b) Interpreta el coeficiente de correlación, la pendiente y el punto de corte.
- c) Si el presupuesto para abril del año 3 plantea unos costos operacionales de 3450 millones de pesos, ¿cuántas unidades se espera fabricar y vender en ese mes?

3. Tú eres el Jefe de mercadeo y ventas de la empresa de confecciones *Zambia*, una empresa que fabrica calcetines. Para definir precios y unos programas de descuentos se registraron datos durante los últimos 15 meses acerca de las unidades producidas y los costos para producirlas (dados en millones de pesos) respecto a un tipo específico de calcetines. Se tomaron estos datos porque se ha comprobado que no se presenta ninguna estacionalidad muy evidente.

Ejercicio 3 Regresión

- a) Calcula una ecuación de regresión que muestre cómo se relacionan las unidades producidas y los costos; supón modelo lineal. Si se van a producir 21000 unidades en el próximo mes, ¿cuáles son los costos esperados?
- b) Halla una ecuación que revele el comportamiento de las unidades producidas a través de este tiempo. Haz una proyección de las unidades producidas para febrero del año 3.

4. Los siguientes datos muestran las inversiones extranjeras en Colombia y el monto de sus exportaciones (ambos en millones de dólares) durante los últimos trimestres:

Ejercicio 4 Regresión

a) Construya un diagrama de dispersión, tomando la inversión extranjera como variable independiente. ¿Parece que existe alguna correlación entre las dos variables? Encuentre el coeficiente de correlación para confirmar su aseveración.

b) Si existe correlación entre las dos variables, encuentre una ecuación de regresión apropiada

5. Tú eres el jefe del departamento comercial de una empresa de alimentos dietéticos ubicada en Medellín. El gerente desea observar cómo se ven afectadas las ventas de la Empresa, según los gastos en publicidad.

Para ello se registraron datos durante los últimos 17 meses; esos datos se revelan a continuación:

Ejercicio 5 Regresión

a) Calcule una ecuación de regresión que muestre cómo se relacionan los gastos en publicidad (variable independiente) y las ventas. Suponga modelo lineal

b) Interprete el coeficiente de correlación, la pendiente y el punto de corte

c) Si el presupuesto de febrero del próximo año plantea la inversión de 1025 millones de pesos en publicidad, ¿cuáles son las ventas estimadas para el mes?

6. Para proyectar las unidades demandadas de un producto en relación con el precio del producto en el mercado se construye una ecuación de regresión en la que se relaciona la cantidad de unidades demandadas (x) con el precio en el mercado (y). La ecuación obtenida es $y = -x + 120$. De acuerdo con esta ecuación es correcto concluir que:


a) Entre el precio y las unidades demandadas hay una relación directa

b) La diferencia entre el precio y las unidades demandadas es 120

c) Entre el precio y las unidades demandadas hay una relación inversa

d) Entre el precio y las unidades demandadas no existe relación alguna

7. Para proyectar las unidades demandadas de un producto en relación con su precio en el mercado se hace un análisis de regresión en el que se relaciona la cantidad de unidades demandadas con el precio en el mercado. El siguiente gráfico representa la situación:



La ecuación que más se ajusta es:

a) $\hat{y} = 100 - 100x$

b) $\hat{y} = 100 + 100x$

c) $\hat{y} = 220 - 7x$

d) $\hat{y} = 220 + 7x$

JUSTIFICA TU RESPUESTA

8. La empresa *Abuya* fabrica cierto producto. Sus directivos creen que la cantidad vendida de ese producto depende de su precio y del precio de un producto similar que vende la competencia (dados en dólares). Se desea contar con una ecuación que relacione la cantidad vendida (en miles de unidades) con los precios de ese producto. La tabla siguiente es una lista de precios en 10 ciudades:

Ejercicio 8 Regresión

a) Encuentre e interprete la matriz de correlación.

b) Determina la ecuación estimada de regresión que se pueda usar para predecir la cantidad vendida, con los precios del competidor y de *Abuya* como variables independientes.

c) Interpreta los coeficientes B1 y B2

d) Pronostica la cantidad vendida en una ciudad donde ese producto es vendido por *Abuya* por 160 dólares y por la competencia por 170 dólares.

9. Un estudio del área de gestión humana de Maquila del Oriente quiere determinar si existe alguna relación entre los años de experiencia de sus empleados en el área de pulido y el tiempo que les lleva pulir una pieza. Para ello, tomó una muestra en la que cada empleado decía sus años de experiencia puliendo (variable regresora) y se tomó el tiempo que tardaba (en horas) para pulir un corte estándar. Los resultados se muestran en la tabla.

Ejercicio 9 Regresión

a) Encuentra la ecuación de regresión que mejor explique la relación entre los años de experiencia y el tiempo de pulido.

b) Calcula e interpreta los valores de punto de corte, pendiente y coeficiente de correlación. Estima cuánto tiempo se tardaría una persona que lleve 10 años en la empresa.

10. Tú eres el jefe del departamento comercial de una empresa de alimentos dietéticos ubicada en Medellín. Desea observar cómo se ven afectadas las ventas de la Empresa, según los gastos en publicidad. Para ello registró datos durante los últimos 17 meses; esos datos se registran a continuación:

Ejercicio 10 Regresión

a) Haz un diagrama de línea que muestre la evolución de la inversión en publicidad a través del tiempo.

b) Encuentra una ecuación que sea útil para proyectar la inversión en publicidad en futuros períodos.

c) Haz una proyección de la inversión en publicidad para marzo del año 3 en caso de continuar con la misma política de gastos publicitarios

11. La gerencia de una empresa embotelladora de bebidas refrescantes quiere desarrollar un método para determinar los costos de entrega a los clientes, con base en el tiempo de entrega. Se cree que el tiempo de entrega depende del número de cajas a entregar; para construir el modelo se registraron los pedidos de 20 clientes ubicados en un mismo sector, así:

Ejercicio 11 Regresión

a) Halla una ecuación de regresión que ajuste lo evaluado.

b) Interpreta pendiente y punto de corte.

c) Predice el tiempo de entrega para 150 cajas de bebida.

d) Determina el coeficiente de correlación y explica su significado.

e) ¿Sería apropiado utilizar el modelo para predecir el tiempo de entrega para un cliente que recibirá 500 cajas de bebida refrescante? ¿Por qué?

12. Eres el propietario del restaurante Chilaquiles, uno de los restaurantes más grandes del país entre los restaurantes de comida mexicana. En el siguiente cuadro se muestra una comparación de las utilidades operacionales de Chilaquiles y las del principal competidor (ambas en millones de COP)

Ejercicio 12 Regresión

a) Construye un gráfico que muestre el comportamiento de la utilidad mensual de Chilaquiles a través de este tiempo. Halla una ecuación de regresión conveniente para el caso y haz una proyección para marzo del año 4.

b) Haz un gráfico de línea comparativo de las utilidades de ambos restaurantes. Comenta.

13. El Gerente de Recursos Humanos de una empresa grande debe presentar un informe anual al Gerente General de la Empresa en el que se presente un estudio de los salarios de los empleados de oficina. Pretende emplear el tiempo de servicio (en meses) como variable explicativo del salario (en millones de COP). Se tomaron los siguientes datos para todos los empleados de la oficina:

Ejercicio 13 Regresión

Haz un análisis de regresión. Si ningún modelo se ajusta, explica qué otras variables piensas que se deberían tener en cuenta.

14. Eres el propietario del restaurante Chilaquiles, uno de los restaurantes más grandes del país entre los restaurantes de comida mexicana. En el siguiente cuadro se muestran las utilidades operacionales de Chilaquiles en los últimos meses (en millones de COP).

Ejercicio 14 Regresión

a) Haz una proyección para febrero del año 4 según las últimas 5 variaciones porcentuales.

b) Haz una proyección para febrero del año 4 según media móvil (n=5)

c) ¿Es posible hacer una proyección para marzo del año 4 basados en una de las dos técnicas anteriores?

RESPUESTAS A EJERCICIOS PROPUESTOS

[Descargar archivo Excel](#)

Notas complementarias: Números índice

Un profesional del área administrativa cuenta con una serie de herramientas estadísticas llamadas indicadores o razones, que es el resultado de la relación numérica entre dos cantidades que proceden, generalmente, de cuentas del balance general o del estado de resultados.

Esta es la manera más frecuente para analizar los estados financieros e inclusive cualquier proceso recurrente dentro de la corporación; estos indicadores permiten encontrar los puntos fuertes o débiles de una empresa, determinando la tendencia y evolución del desempeño en el tiempo, con el fin de tomar decisiones que permitan corregir las desviaciones financieras que se están saliendo de los pronósticos realizados al momento de hacer la planeación de la compañía.

En general, las magnitudes socioeconómicas varían en el tiempo y en el espacio; frecuentemente deben establecerse comparaciones de dichas magnitudes en dos o más periodos de tiempo o en dos o más zonas geográficas.

Un número índice es una medida estadística que recoge la evolución relativa en el periodo t de una magnitud económica (como precio y producción) de un conjunto de bienes o productos respecto de un periodo base o de referencia; también permite comparar una magnitud económica en una zona geográfica respecto a una zona de referencia. Por tanto, permiten comparar el estado de un fenómeno económico en dos situaciones diferentes y es una herramienta imprescindible en los estudios de coyuntura.

Para establecer un número índice deben fijarse un **Período base o de referencia**, que es un período de tiempo fijado arbitrariamente que se toma como origen de las comparaciones y un **Período actual o corriente**, que es el período de tiempo que se compara con el período base.

$$I(H) = \frac{H_t}{H_0}$$

Donde: H_t el valor de la variable en el momento t .
 H_0 el valor de la variable en el momento 0.

El índice así definido nos da el tanto por uno en que se ha modificado la magnitud H desde el período 0 al período t .

Por ejemplo, si el precio del transporte público pasa de 1800 pesos a 2200 pesos en un año, el índice nos daría como resultado:

$$I(H) = \frac{2200}{1800} = 1,2222$$

Esto indica que adicional al valor base (período base), el precio del transporte público subió 22,22% en el último año.

De la misma manera, si el precio del aguacate pasa de 2500 pesos el kilo a 2100 pesos en un mes, el índice nos daría como resultado

$$I(H) = \frac{2100}{2500} = 0,84$$

Esto indica, que por debajo al valor base (período base), el precio del aguacate disminuyó 16% en el último mes (el resultado se encuentra 0,16 por debajo de la unidad).

Fuentes

<http://www.eco.uva.es/estadmed/datos/indices/indices.htm>

Se hará énfasis en los números índices simples, que se refieren a un solo artículo o concepto, lo cual se traduce a trabajar con una variable unidimensional. Son simples relaciones o porcentajes entre los valores de un artículo o concepto correspondientes a dos épocas o lugares que desean compararse; la comparación se realiza entre el valor correspondiente a un período fijo (período base) y el valor alcanzado por la magnitud en cualquier otro momento t .

Dada una serie temporal, los números índices se obtienen dividiendo cada uno de los valores de la variable en cada momento por el valor que tomó la variable en el instante de referencia, denominado período base.

Referencias bibliográficas

Anderson, D., Sweeney D., Williams, T. (2016). *Estadística para negocios y economía*. México, D.F.: Cengage Learning Editores.

Ángel, B. (2010). Cartilla de Investigación y empresarismo. Sabaneta: Institución Universitaria Ceipa.

BioMates.net (s.f.). Procesamiento estadístico de datos biomédicos. Series temporales. Consultado en

<http://www.sgapeio.es/INFORMEST/VICongreso/taller/applets/biomates/ser/ser.htm>

Chen, D. Q., Preston, D. S., & Swink, M. (2015). How the Use of Big Data Analytics Affects Value Creation in Supply Chain Management. *Journal of Management Information Systems*, 32(4), 4-39. doi:10.1080/07421222.2015.1138364. Consultado en

<http://search.ebscohost.com/login.aspx?direct=true&db=bth&AN=114514526&lang=es&site=ehost-live>

Facultad de Ciencias Económicas y Empresariales. (s.f.). Número índices. Consultado en:

<http://www.eco.uva.es/estadmed/datos/indices/indices.htm>

Hoyos B. (2010). El ABC de la estadística. Caldas, Antioquia: Editorial Artes y Letras

Jaramillo F. (2003). *Distribuciones de probabilidad*. Consultado en

estadisticaue.awardspace.com/est1ce/t_dispro.doc

Johnson, R. & Wichern D. (1998). *Applied Multivariate Statistical Analysis*. New Jersey, USA: Prentice Hall.

Kelmansky D. (2009). *Estadística para todos. Estrategias de pensamiento y herramientas para la solución de problemas*. Buenos Aires, Argentina: Colección Las ciencias naturales y la matemática.

López, J. *La moda del Big data: ¿En qué consiste en realidad?* (27 de febrero de 2014). El Economista. Consultado en

<http://www.eleconomista.es/tecnologia/noticias/5578707/02/14/La-moda-del-Big-Data-En-que-consiste-en-realidad.html>

Mercadoforex.net (sin información). Gráfico de velas. Consultado en

<http://mercadoforex.net/grafico-velas>

Miller, T. & Kim, A. (2016). *Puntos destacados del Índice 2016 de Libertad Económica*. The Heritage Foundation. Consultado en

http://www.heritage.org/index/pdf/2016/book/Highlights_Spanish.pdf

Montgomery D. y Runger G. (1996). *Probabilidad y estadística aplicadas a la ingeniería*. México, D.F.: McGraw-Hill Interamericana Editores.

New Media Consortium (2017). Tendencias clave que aceleran la adopción de nuevas tecnologías en la educación superior. Recuperado de :

<https://www.nmc.org/publication/nmc-horizon-report-2017-higher-education-edition-spanish/tendencias-clave-que-aceleran-la-adopcion-de-nuevas-tecnologias-en-la-educacion-superior/>

Triola M. (2013). *Estadística*. México, D.F.: Pearson.

Walpole R., Myers R. y Myers S. (1999). *Probabilidad y estadística para ingenieros*. México, D.F.: Pearson Prentice Hall.

World Economic Forum (2016). The Global Competitiveness Report 2016-2017. Consultado en

http://www3.weforum.org/docs/GCR2016-2017/05FullReport/TheGlobalCompetitivenessReport2016-2017_FINAL.pdf

Yaqoob, I. et al (2015). Big data: from beginning to future. *International Journal of Information Management*, 36, 2016, 1231-1247. Consultado en

http://ac.els-cdn.com/S0268401216304753/1-s2.0-S0268401216304753-main.pdf?_tid=da-d7246e-960a-11e6-a568-00000aab0f27&acdnat=1476888584_6e1a58d1285e6b61d4e3f29fa338091d